# Master 2 Info & Maths-Info

# Bases de données spécialisées

Cristina Sirangelo
IRIF, Université Paris Cité
cristina@irif.fr

# Sémantique RDFS

Credits (materiel, transparents et exemples empruntés)
- Transparents du cours LODAS , Bernd Amman, Univ. Pierre et Marie Curie
- Transparents du cours “Semantic technologies” Univ. Of Oslo
- MOOC FUN INRIA Web Semantique - Corby, Gandon, Faron
- Livre : Foundations of Semantic Web Technologies - Hitzler, Krotzsch, Rudolf
- Livre : Web data management - Abiteboul, Manolescu, Rousset, Senellart

# Rappel : ontologie (ou base de connaissance)

- Rappel : une ontologie K
  - est définie sur un **vocabulaire** (ou **schema**) ⟨C,P⟩: i.e. l'ensemble C des classes et l'ensemble P des propriétés qu'elle décrit
  - K comprends :
    - Un ensemble A de **faits**, c-a-d un ensemble d'instances des classes et des propriétés de C∪P

      (en RDF : des triplets **<s rdf:type c>** avec **c** ∈ C

      et des triplets **<s p o>** avec **p** ∈ P)

    - Un ensemble T de **contraintes** c-a-d des relations entre classes et propriété du vocabulaire ⟨C,P⟩

      (en RDFS : des triplets **<s p o>** avec **s,o** ∈ C∪P

      et **p** ∈ { `rdfs: subClassOf, rdfs:subPropertyOf,`

      `rdfs:domain, rdfs:range` } )

# Rappel : exemple d'ontologie RDFS

- Syntaxe = P ={ :auteur, :createur}  C={ :Objet, :Document, :Agent, :Personne}
  - sous forme de graphe

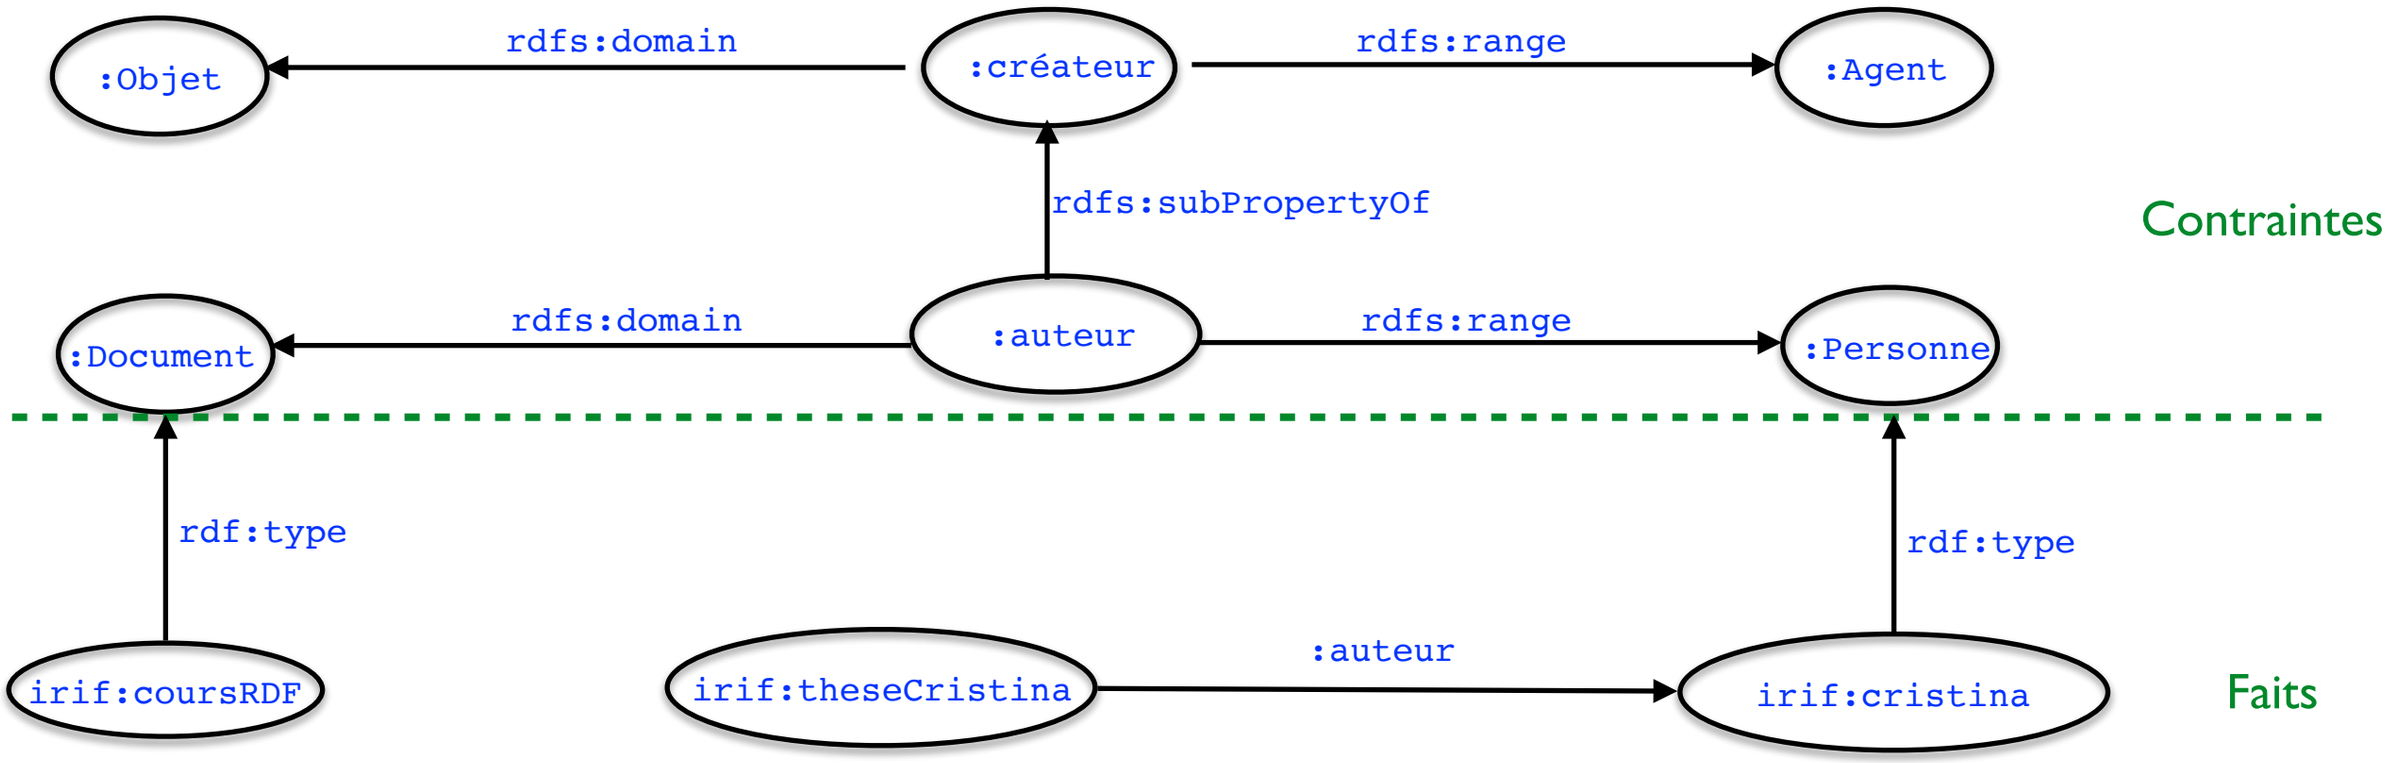


- sous forme de triplets (équivalent)

Contraintes

```
:createur rdfs:domain :Objet
:createur rdfs:range :Agent
:auteur rdfs:domain :Document
:auteur rdfs:range :Personne
:auteur rdfs:subPropertyOf :createur
```

Faits

```
irif:theseCristina :auteur irif:cristina
irif:cristina rdf:type :Personne
irif:coursRDF rdf:type :Document
```

# Sémantique d'une ontologie

- Une ontologie (par exemple RDFS) est une description syntaxique (un ensemble de triplets décrivants les faits et les contraintes)
- Mais on peut lui associer une sémantique :
  - Intuitivement une ontologie représente toutes les façon possibles de "peupler" les classes et les propriétés de telle sorte qu'elles :
    - contiennent la base de faits
    - satisfassent les contraintes
  - Chacune de ces façons possibles est appelée **modèle** de l'ontologie
  - Les modèles ne sont pas matérialisés, ils représentent des données implicites qu'on peut deriver

# Sémantique d'une ontologie RDFS

- Que veut dire "satisfaire les contraintes" pour RDFS?
  - Nécessite une sémantique formelle
  - Mais **intuitivement** la sémantique attendue des contraintes RDFS est celle suggérée par leur noms, par exemple :

```
:createur rdfs:range  :Agent .
```

Sémantique (intuitive) :
dans tout triplet `s :createur p`, `p` doit être de classe `:Agent`

# Exemple : sémantique intuitive

- P ={ :auteur,  :createur}  C={ :Objet,  :Document,  :Agent,  :Personne}

K

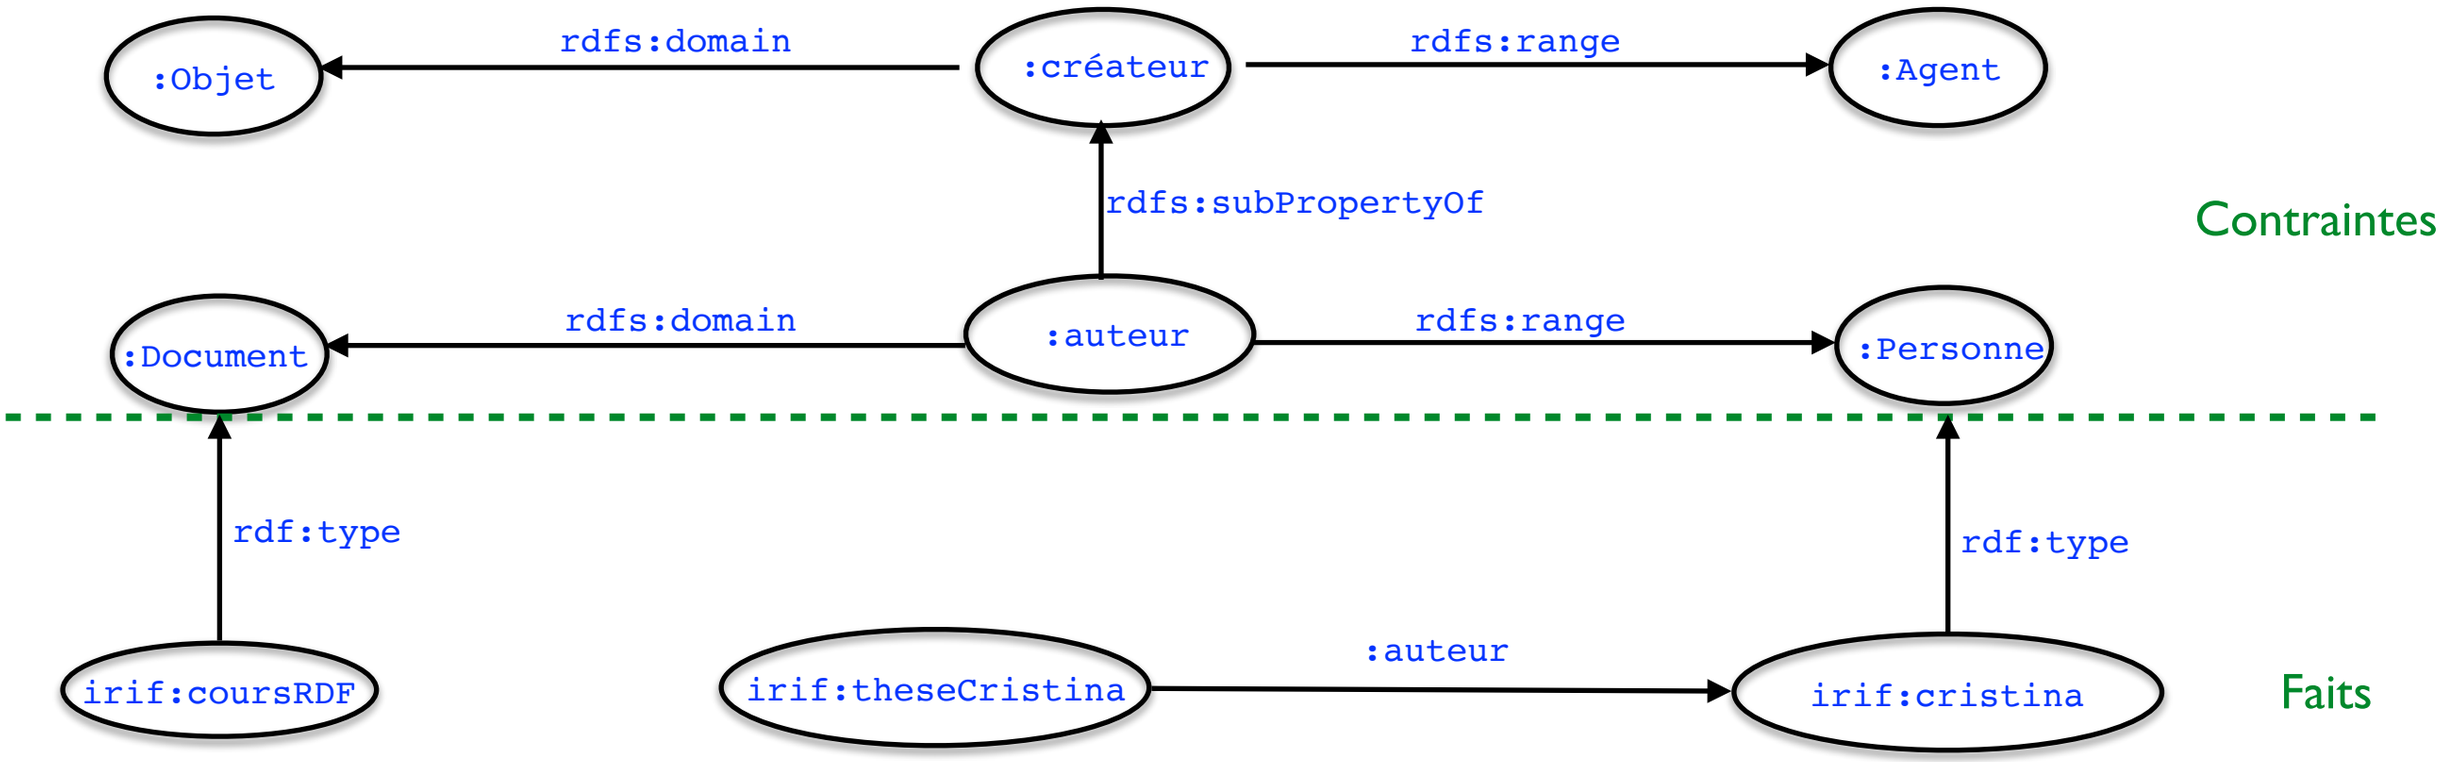

# Exemple : sémantique intuitive

- P ={ :auteur,  :createur}  C={ :Objet,  :Document,  :Agent,  :Personne}

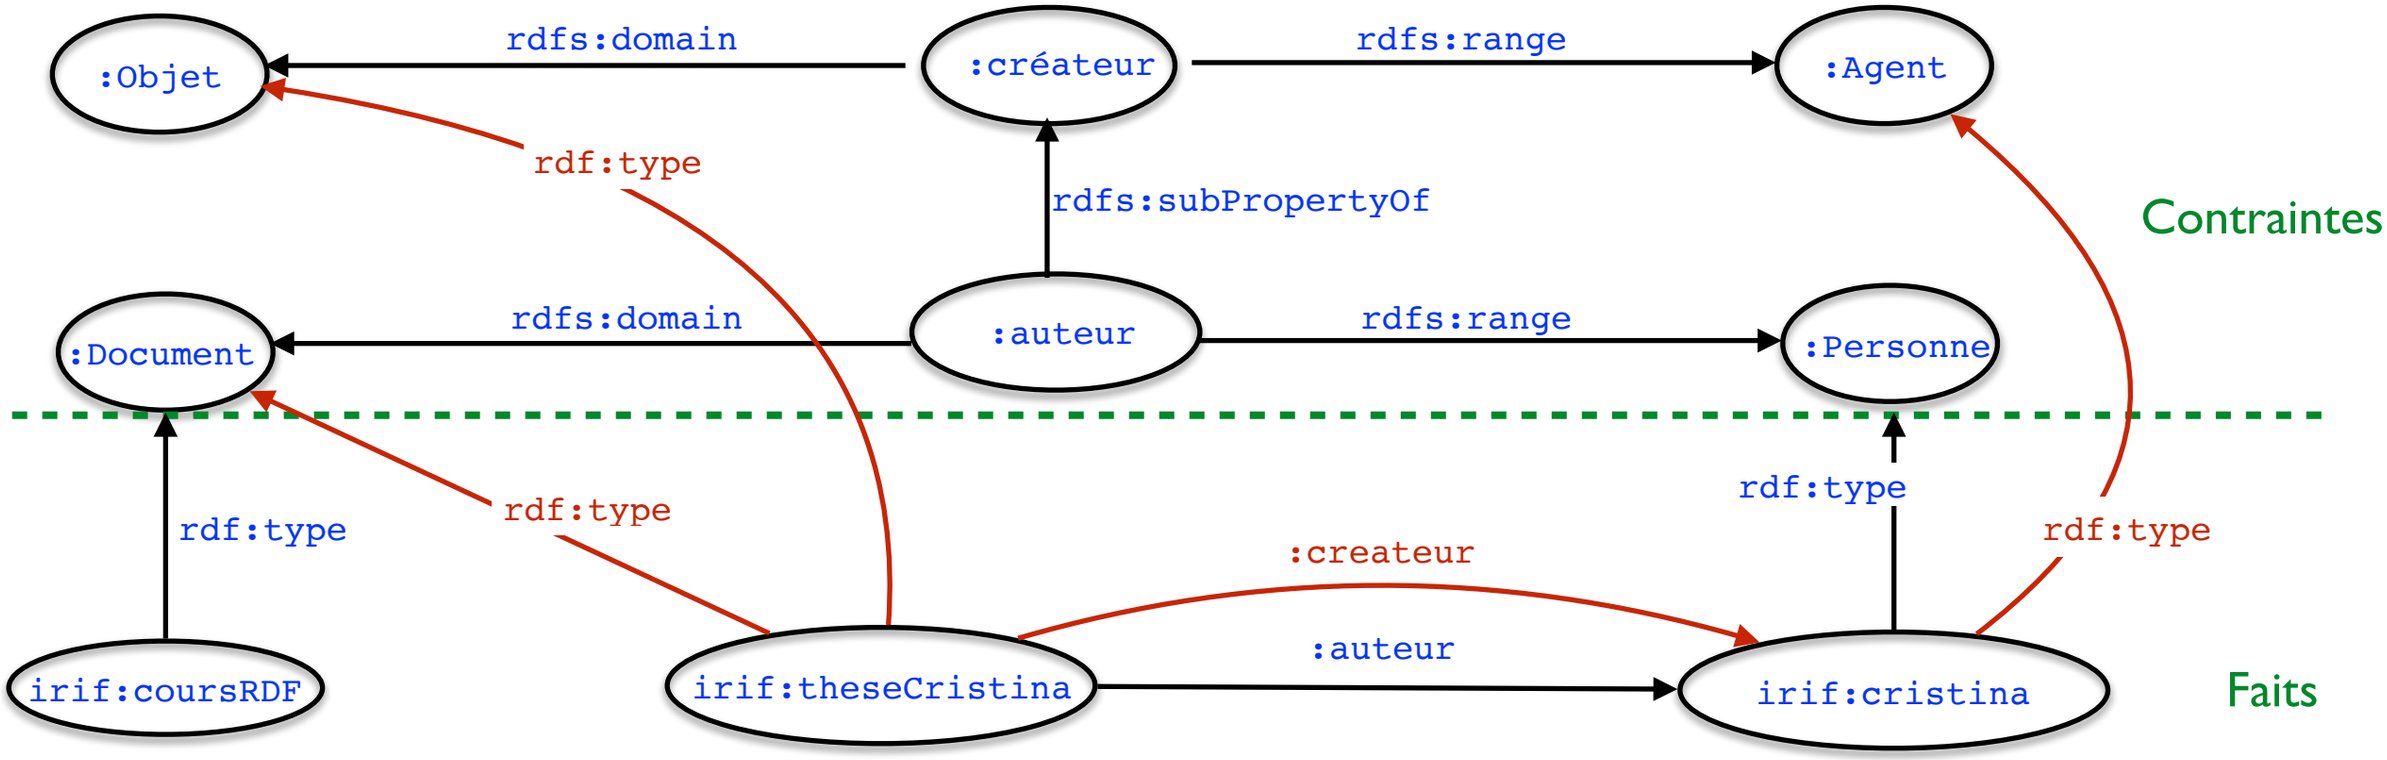


tout  modèle de K devra contenir au moins les nouveaux faits en rouge,

en plus des fait initiaux, autrement les contraintes ne sont pas satisfaites

# Plusieurs modèles d'une même ontologie

- Une ontologie admet en général plusieurs modèles. Exemple :

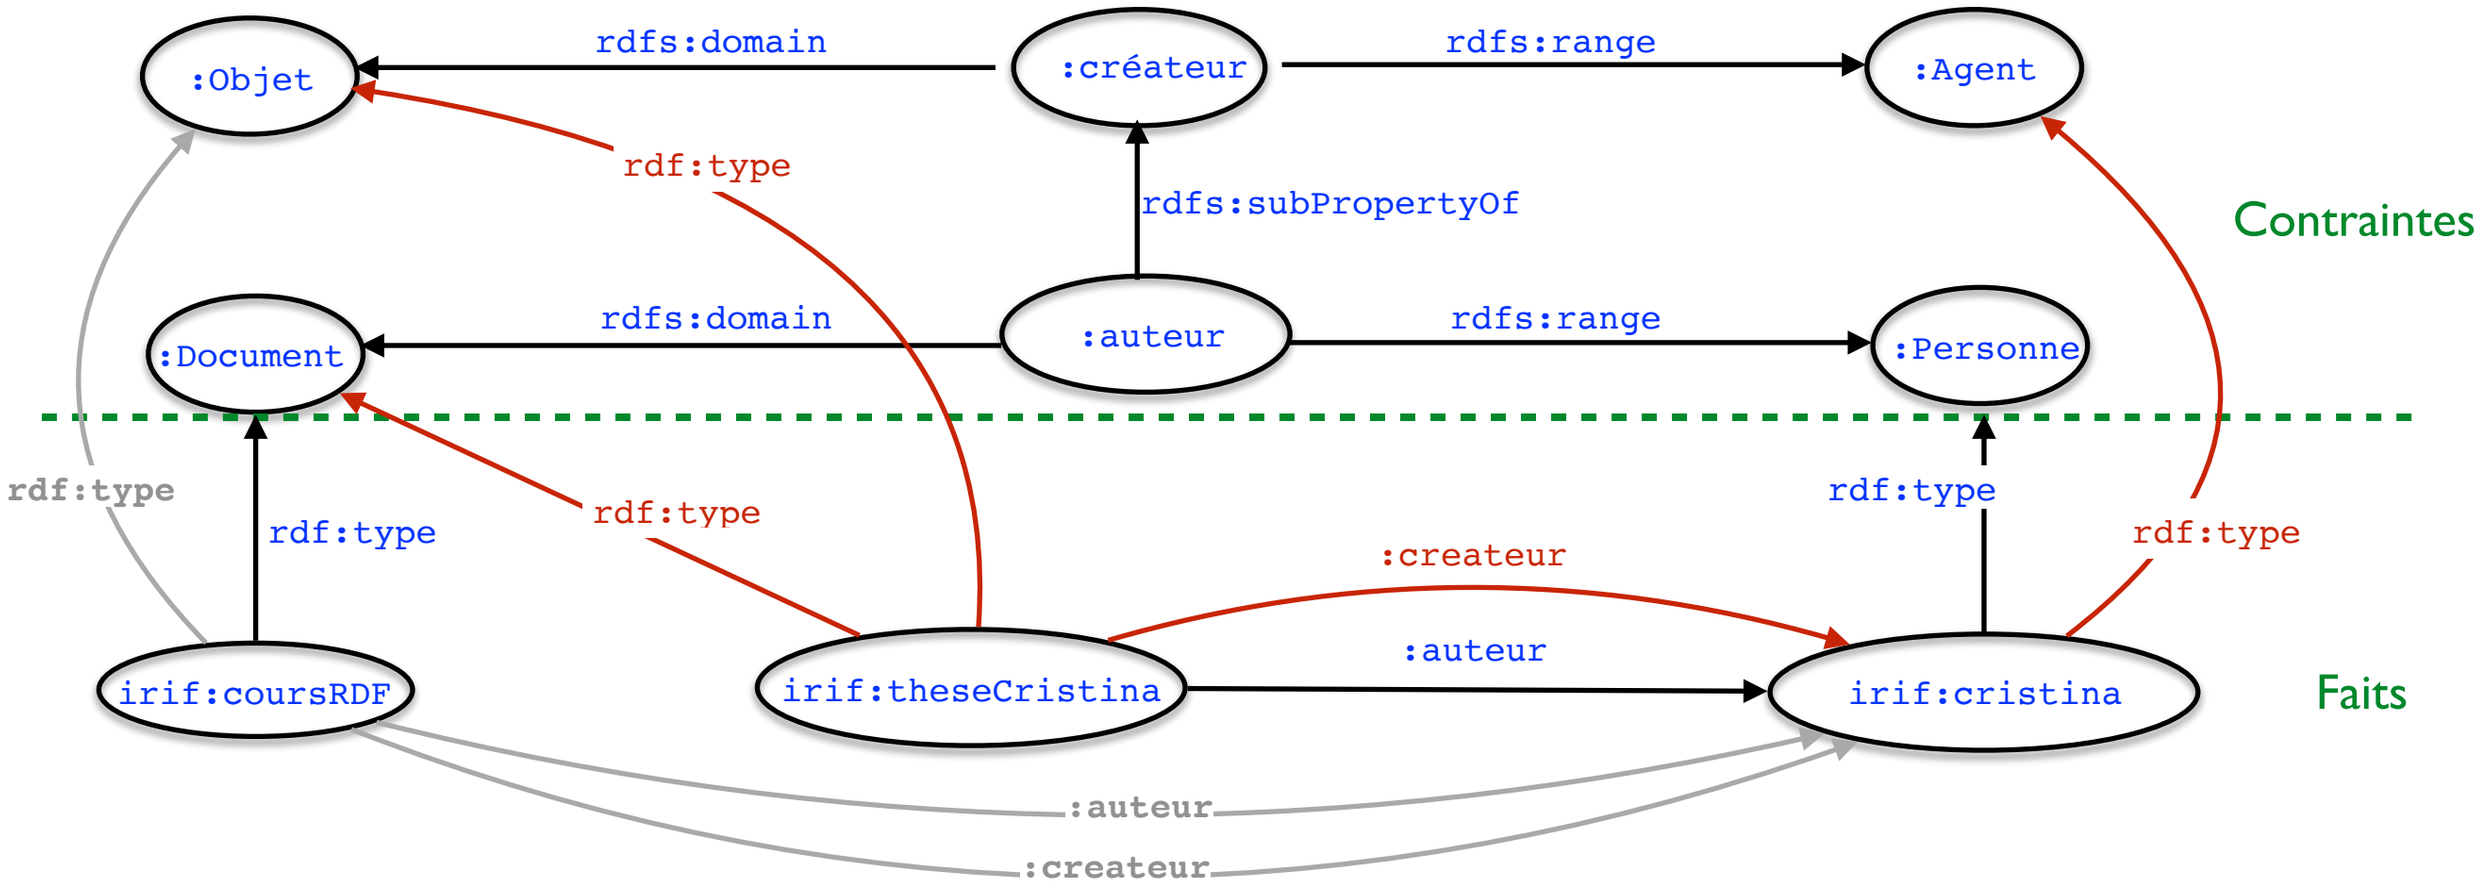


tout  modèle de K devra contenir au moins les nouveaux faits en rouge, en plus des fait initiaux, mais peut contenir ou pas les faits en gris par exemple

# Conséquences d'une ontologie

- Une ontologie admet en general plusieurs modèles
- Mais on s'intéresse à **ce qui est vrai dans tout modèle** (appelé **conséquences** de l'ontologie, ou **inférences** )
- Cela représente intuitivement ce qu'on peut deriver avec certitude de ce qui est connu (i.e de la "connaissance")
- Exemple : les fait initiaux ainsi que les faits en rouges sont des consequences

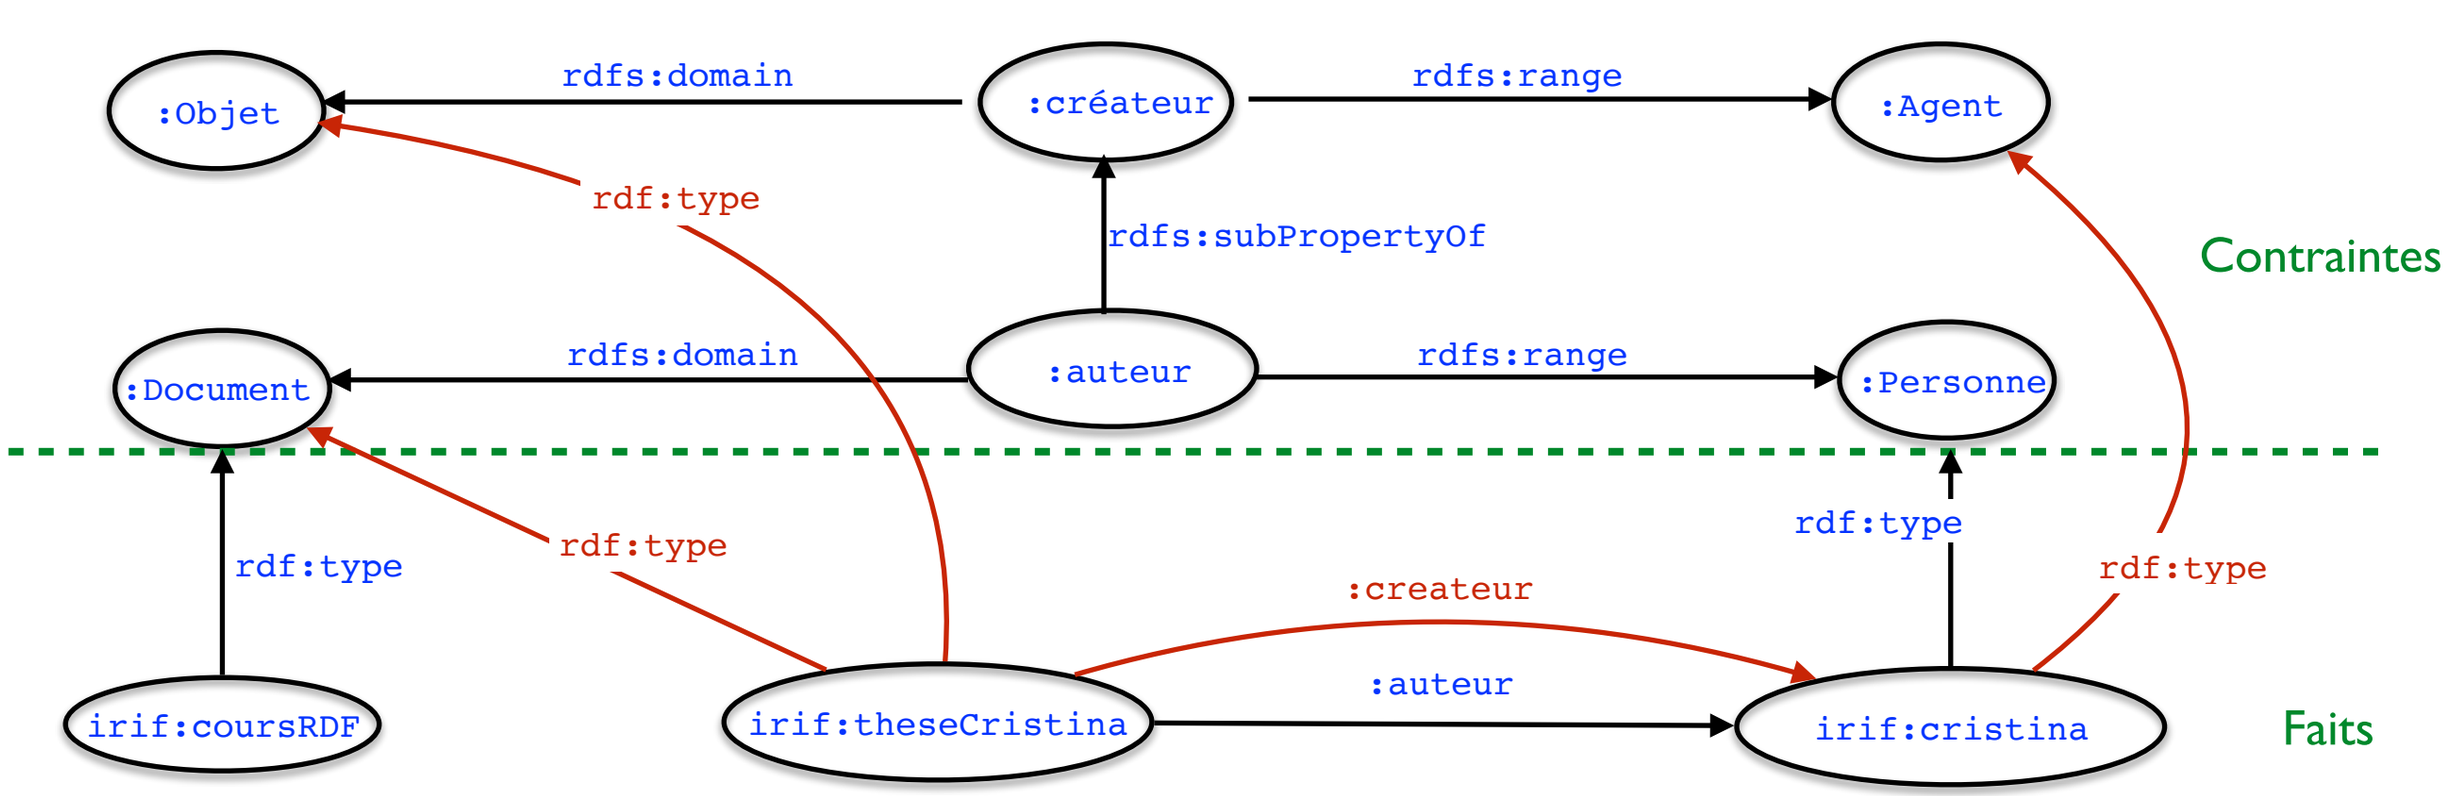

# Ontologie RDFS prédéfinie

- On souhaite avoir des systèmes capables de raisonner (deriver des conséquences) en utilisant un ensemble fixé de contraintes
- C'est pour cette raison que RDFS exprime les contraintes comme données
  - C-a-d en RDFS les contraintes sur un vocabulaire <C,P> sont exprimées comme des faits, en étendant <C,P> par de nouvelles classes et propriétés d'un vocabulaire prédéfini (`rdf:` et `rdfs:`)
    - `rdfs:domain, rdfs:subPropertyOf, rdfs:Class, rdf:Property` etc.

- La sémantique de ces nouvelles classes et propriétés est donnée par l'**ontologie RDFS prédéfinie**

# Ontologie RDFS prédéfinie - suite

- **Ontologie RDFS prédéfinie :**
  - Un ensemble de triplets de base et de contraintes fixées nécessaires à specifier la sémantique des classes et propriétés du vocabulaire `rdf:` / `rdfs`:
  - Si K est une ontologie exprimée en RDFS, faits **et** contraintes de K sont considérés comme faits de base de l'ontologie RDFS prédéfinie
  - **Ceci permet de raisonner avec un ensemble de contraintes fixé**
- Comporte :
  - triplets de base (axiomatiques)
  - contraintes logiques
- La liste exhaustive serait longues
  - description formelle (recommandation W3C) : https://www.w3.org/TR/rdf11-mt/
  - (cf. aussi "Foundations of Sem. Web Technologies" - Hitzler, Krotzsch, Rudolf)
- On en donne un extrait en guise d'exemple

# Ontologie RDFS prédéfinie - triplets axiomatiques

- Quelques triplets axiomatiques

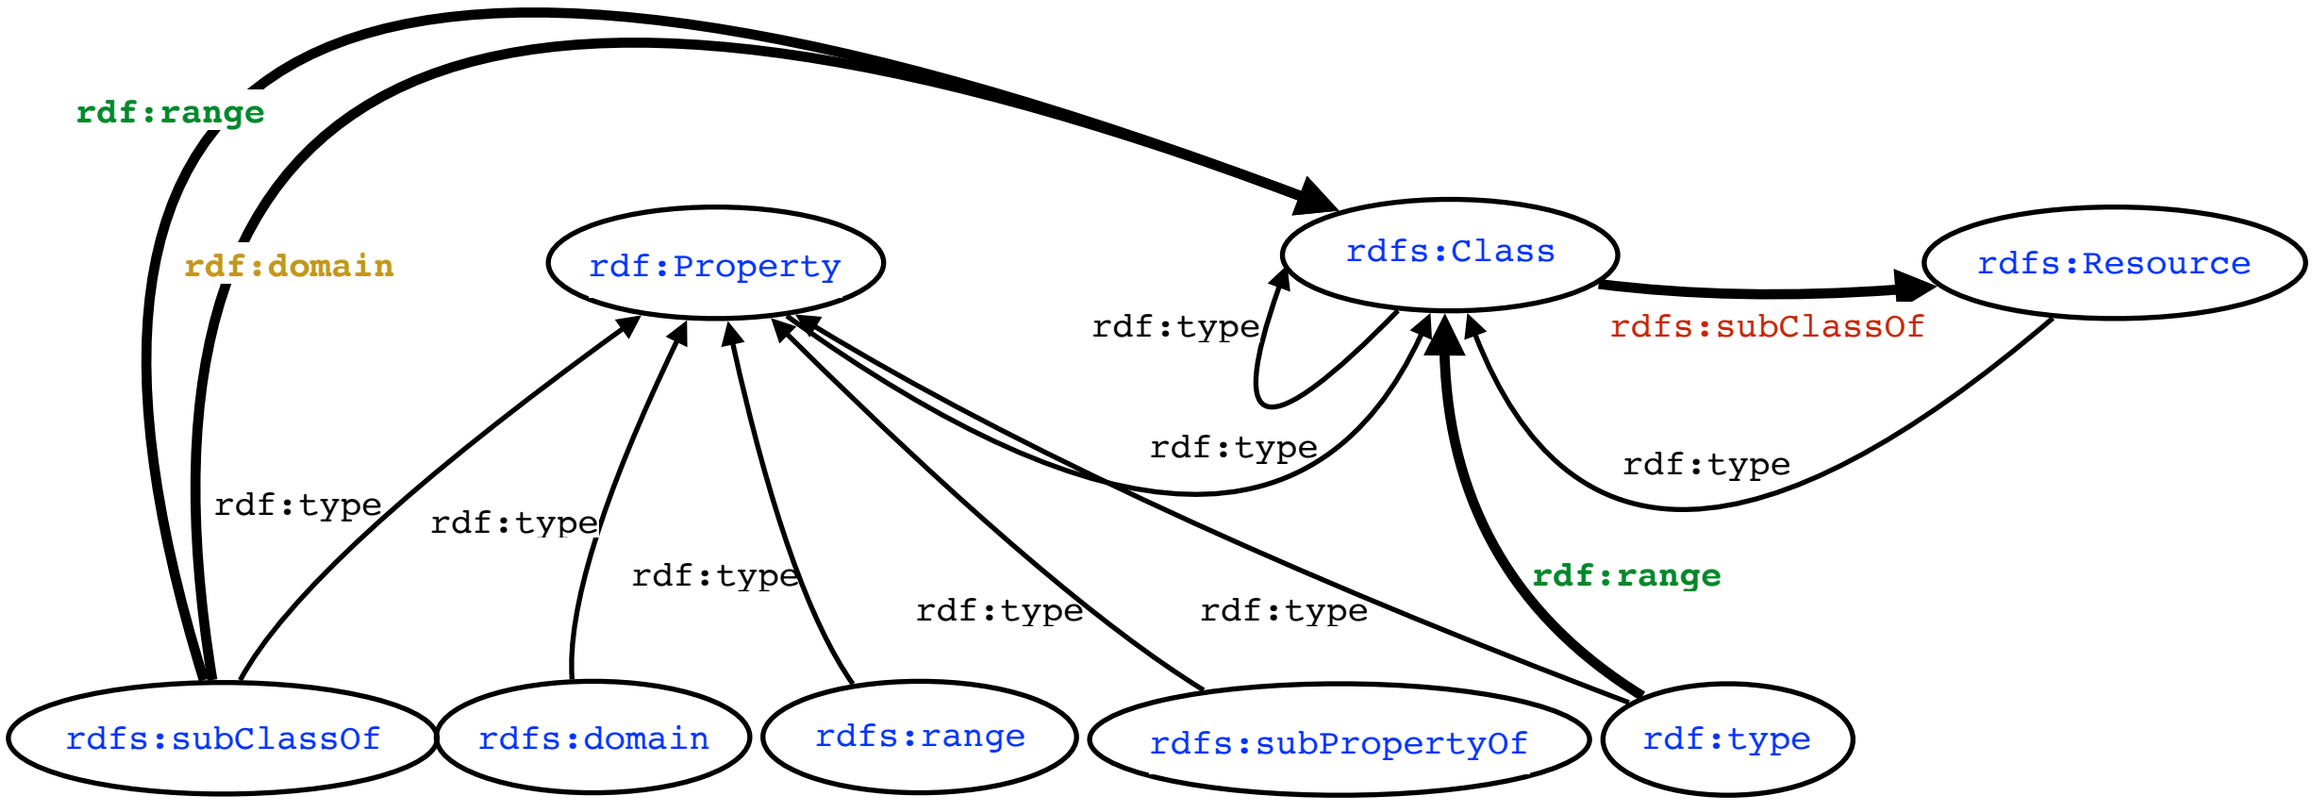


- e.g.
  - `rdfs:Class` contient toutes les classes
  - toute ressource est dans la classe `rdf:Resource`
  - L'objet de tout triplet `rdf:type` est une classe
  - etc.

# Ontologie RDFS prédéfinie - contraintes

- Quelques contraintes :

  - `(A rdfs:subClassOf B ∧ B rdfs:subClassOf C) ⇒ A rdfs:subClassOf C`
  - `(r rdf:type A et A rdfs:subClassOf B) ⇒ r rdf:type B`
  - `S rdf:type rdfs:Class ⇒ S rdfs:subClassOf rdfs:Resource`
  - `s p o ⇒ p rdf:type rdf:Property`
  - `(s p o ∧ p rdfs:range C )⇒ o rdf:type C`

  ***Etc. etc.***

- Ensemble avec les triplets axiomatiques servent à donner la sémantique attendue aux classes et propriétés du vocabulaire `rdf:/rdfs:`

# Modèle RDFS

- Soit K une ontologie  RDFS de schema <C,P>
- Soit A l'ensembles de faits de K, et T l'ensemble des contraintes de K (triplets)

un **modèle RDFS** de K est un graphe RDF dont les propriétés sont soit dans P soit des propriétés prédéfinies `rdf/rdfs,` qui :

- contient les triplets A et T et les triplets axiomatiques,
- satisfait les contraintes prédéfinies RDFS
  (cf slide "Ontologie RDFS prédéfinie - contraintes")

- Dans un modèle RDFS de K on s'intéresse tout particulièrement aux triplets de la forme suivante :
  - **Faits** :`<s p o>  avec p ∈ P`
    `<s rdf:type S> avec  S ∈ C`
  - **Contraintes** :`<s p o>` avec `s,o ∈ CUP` et `p ∈{rdfs:subClassOf, rdfs:subPropertyOf, rdfs:domain, rdfs:range}`

# Exemple

- K

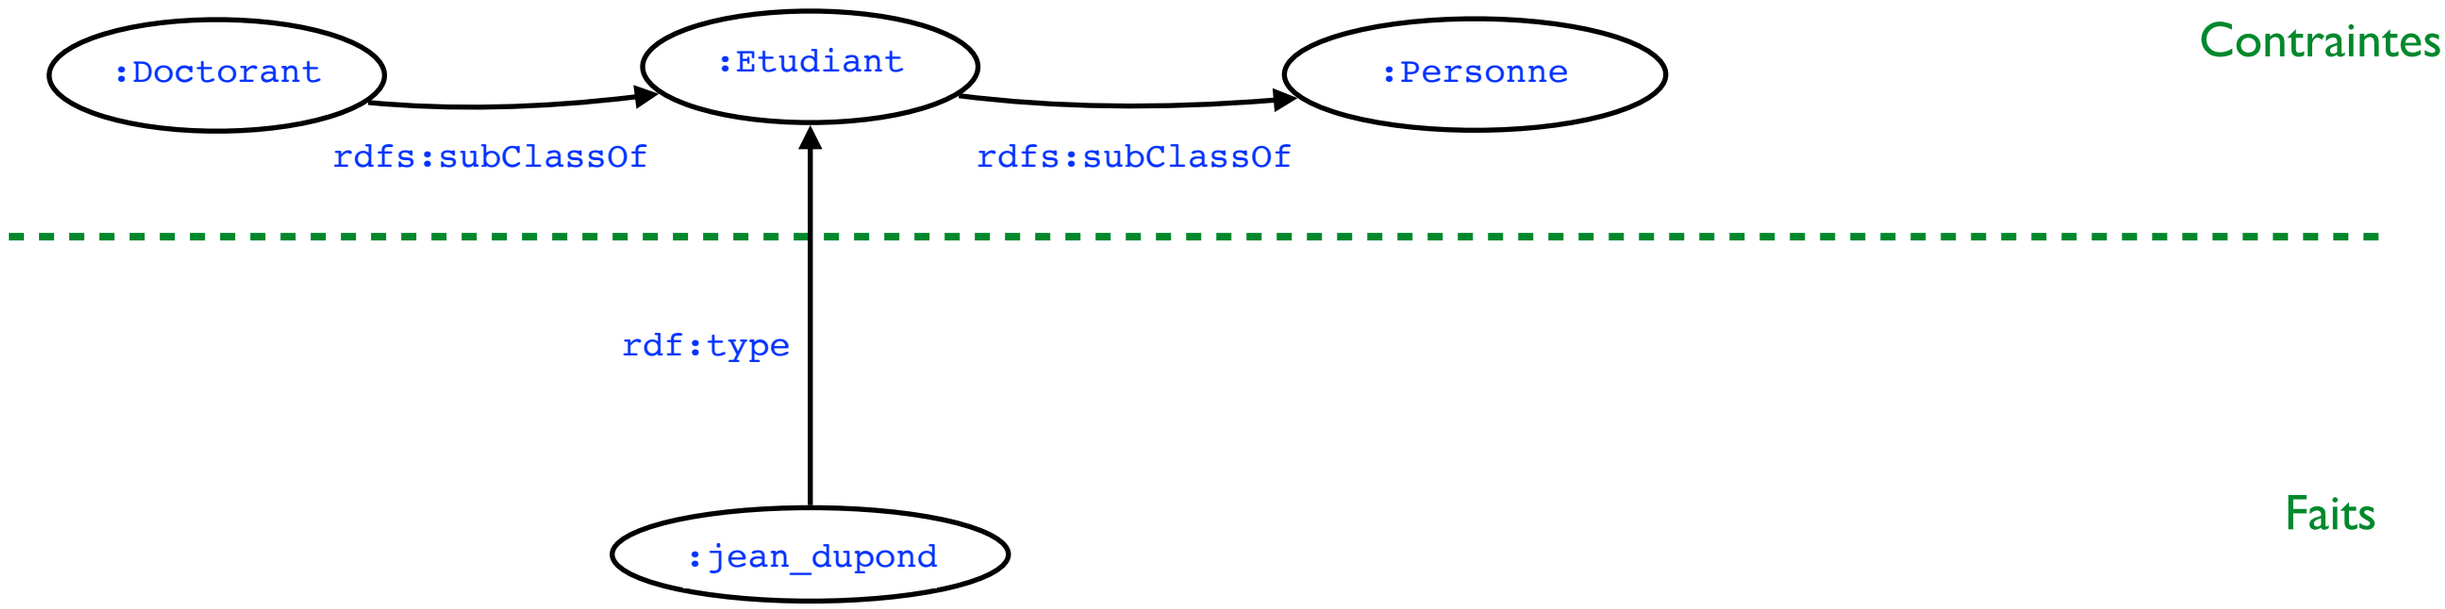
:Doctorant
:Etudiant
:Personne
rdfs:subClassOf
rdfs:subClassOf
Contraintes
rdf:type
:jean_dupond
Faits

# Exemple

- Faits et contraintes d'un modèle RDFS de K

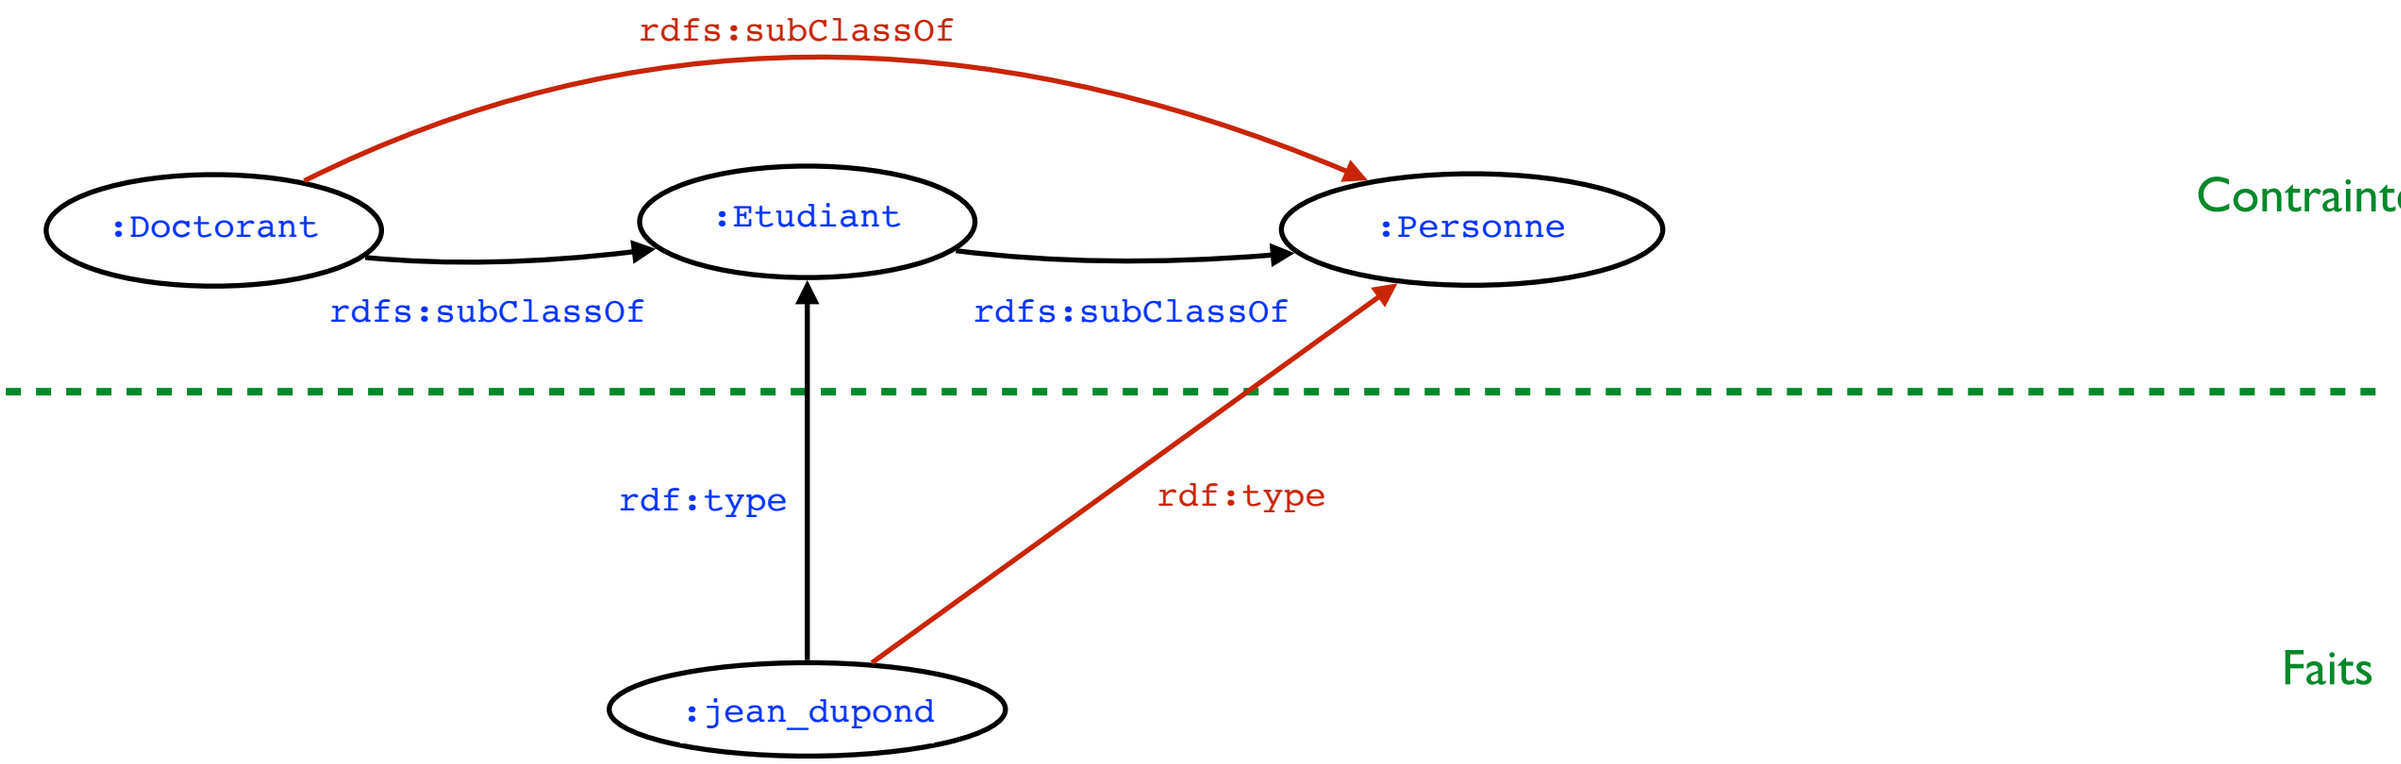


**NB** : Ce modèle contient d'autre triplets, par exemple
`:Etudiant rdf:type rdfs:Class`
(par le triplet axiomatique et la contrainte de range, cf. slide suivant),

mais cela n'est ni un fait ni une contrainte du vocabulaire de K

# Exemple - suite

- Triplet axiomatique :
  - `rdfs:subClassOf  rdf:range  rdfs:Class`
- Triplet dans K :
  - `:Doctorant  rdfs:subClassOf :Etudiant`
- La contrainte RDFs :
  - `(s p o ∧ p rdfs:range C )⇒ o rdf:type C`

Permet de deriver :

`:Etudiant rdf:type rdfs:Class`

# Sémantique opérationnelle de RDFS

- Les contraintes RDFS sont toutes de la forme

$$(X \wedge Y) \Rightarrow Z$$

`Example  (r rdf:type A et A rdfs:subClassOf B) ⇒ r rdf:type B`

- (appelées TDGS)
- Elle peuvent être vues comme **règles de derivation** (ou d'inférence) , et on les écrira comme

```
X    Y
------
  Z
```

exemple

```
<r rdf:type A>
<A rdfs:sublclassOf B>
----------------------
<r rdf:type B>
```

- Si un modèle contient les triplets X et Y il doit également contenir le triplet Z (autrement la contrainte n'est pas satisfaite)
- Donc l'application d'une règle de derivation génère un nouveau triplet qui est une consequence de l'ontologie (i.e. présent dans tous les modèles RDFS)

# Sémantique opérationnelle de RDFS

- Donnée une ontologie K avec faits A et contraintes T
- On part des triplets de base (qui doivent être presents dans tous les modèles RDFS)
  - triplets axiomatiques, A et T
- On peut utiliser les règles de derivations correspondantes aux contraintes RDFS comme **“générateurs” de nouveaux triplets**
- Ces nouveaux triplets doivent être obligatoirement presents dans tous les modèles RDFS de K,
  - C-a-d on ne derive **que des conséquences de K**
    - On dit alors que l’ensemble des règles de derivation est **correct** pour la derivation des consequences
    - On peut facilement voir qu’il est également **complet** ( permet de deriver toutes les conséquences de K)
    - On en déduit que l’application successive des règles d’inference RDFS donne un algorithme de saturation pour calculer toutes les conséquences de l’ontologie

# Algorithme de saturation

- Soit $\Gamma$ l'ensemble des contraintes RDFS *

Saturation ($\Gamma$)

**Input**: K=<A,T> ( faits A et contraintes T)
**Output**: toutes les conséquences de K

```
(1) F←A U T U triplets axiomatiques
(3) repeat
(4)     foreach rule  Condition / Conclusion  in Γ
(5)         if there exists a substitution σ such that
(6)         σ(Condition) ∈ F and σ(Conclusion) ∉ F
(7)             add σ(Conclusion) to F
(8)
(10) until nothing added to F
```

(*$\Gamma$ ici est l'ensemble des contraintes RDFS, mais l'algo est parametré par un ensemble arbitraire de contraintes $\Gamma$)

# Algorithme de saturation

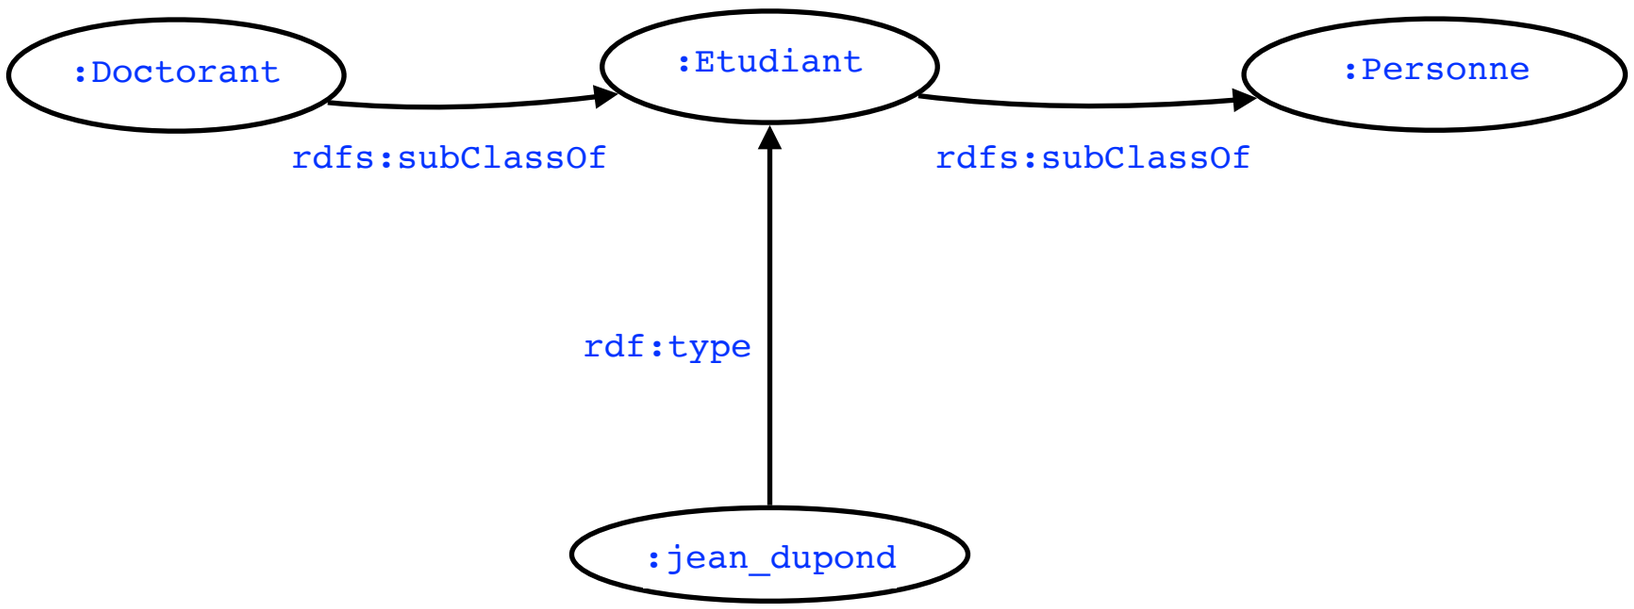


```
<r rdf:type A>
<A rdfs:sublclassOf B>
_________________
<r rdf:type B>
```

$\sigma(r)$ = :jean_dupond
$\sigma(A)$ = *:Etudiant*
$\sigma(B)$ = *:Personne*

# Algorithme de saturation

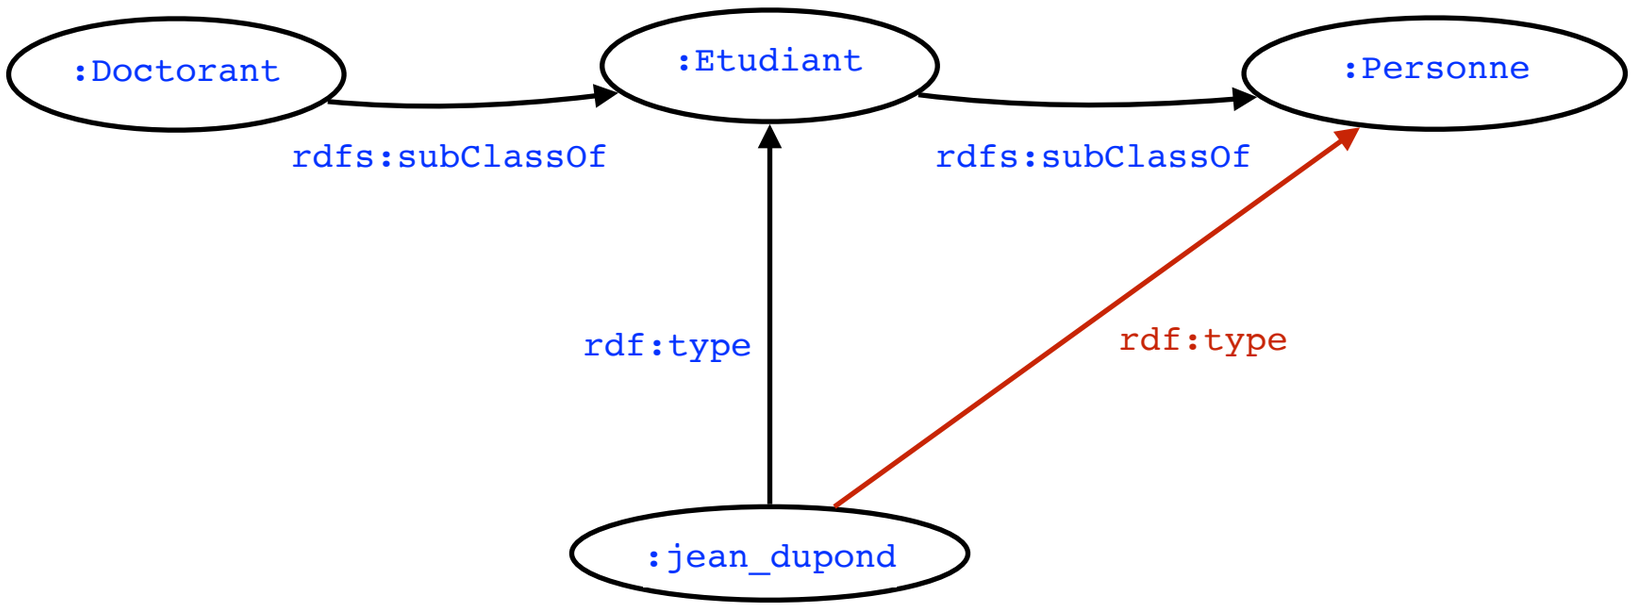


```
<r rdf:type A>
<A rdfs:sublclassOf B>
_________________
<r rdf:type B>
```

$\sigma(r)$ = :jean_dupond
$\sigma(A)$ = *:Etudiant*
$\sigma(B)$ = *:Personne*

# Algorithme de saturation

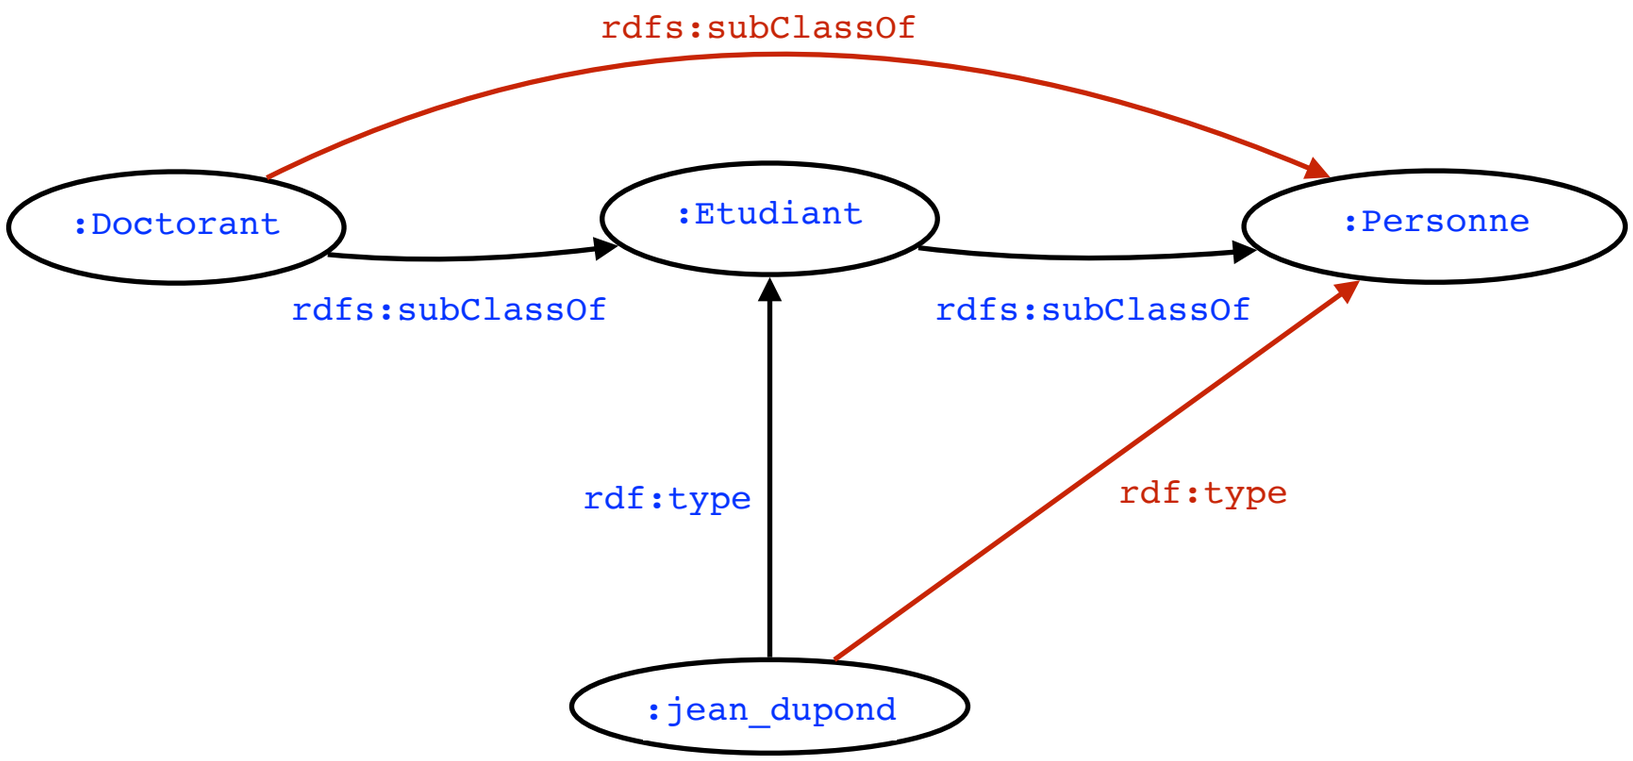


```
<A rdfs:sublclassOf B>
<B rdfs:sublclassOf B>
_____________________
<A rdfs:sublclassOf C>
```

*σ(A) = :Doctorant*
*σ(B) = :Etudiant*
*σ(C) = :Personne*

Etc…

# Saturation partielle

- Souvent nous ne sommes pas intéressés à deriver toutes les consequences
  - E.g `:createur rdf:type rdf:Property` moins interessant que `irif:theseCristina :createur irif:cristina`
- On peut alors appliquer l'algorithme pour un ensemble restraints de règles de derivation $\Gamma$
- Rappel : nous sommes souvent intéressés à deriver uniquement tous les faits et les contraintes (cf. slide Modèle RDFS)
- On peut identifier un sous-ensemble des règles de derivations RDFS qui est **correct et complet** pour la derivations de tous les **faits** et toutes les **contraintes** qui sont conséquences de K

# Sémantique opérationnelle de RDFS : les faits

- Les règles d'inférence suivantes sont correctes et completes pour la derivation de nouveaux **faits *** :

(rdfs9)

```
<r rdf:type D>
<D rdfs:sublclassOf B>
————————————————
<r rdf:type B>
```

(rdfs7)

```
<r P s>
<P rdfs:subPropertyOf Q >
————————————————
<r Q s>
```

$\Gamma_A$

(rdfs2)

```
<r P s>
<P rdfs:domain D >
————————————————
<r rdfs:type D>
```

(rdfs3)

```
<r P s>
<P rdfs:range D >
————————————————
<s rdfs:type D>
```

- Cela veut dire : pour une ontologie K=(A,T) de schema <C,P>
  Un fait (c-a-d `<s p o>` avec `p` ∈ P ou `<s rdf:type S>` avec `S` ∈ C) est conséquence de K (c-a-d obligatoirement présent dans tous les modèles RDFS de K) ssi ce fait peut être obtenu par application successive de ces derivations à partir de A∪T

* en l'absence de blank nodes

# Sémantique opérationnelle de RDFS : les contraintes

- Les règles d'inférence suivantes sont correctes et completes pour la derivation de nouvelles **contraintes**:

(rdfs11)

```
<D rdfs:subClassOf B>
<B rdfs:subClassOf E>
_____________________
<D rdfs:subClassOf E>
```

(rdfs5)

```
<d rdfs:subPropertyOf b>
<b rdfs:subPropertyOf e>
_____________________
<d rdfs:subPropertyOf e>
```

$\Gamma_T$

- $\Gamma_T$ fournit la variante la plus faible de la sémantiques RDFs dans la quelle *domaine* et *co-domaine* d'une propriété sont uniquement ceux déclarés explicitement
- Des règles extensionnelles sont nécessaire si on veut imposer une sémantiques RDFS plus forte, dans la quelle domaine et co-domaine d'une propriété sont clos par super-ensemble

# Sémantique opérationnelle de RDFS : les contraintes

- Les règles d'inférence suivantes sont correctes et completes pour la derivation de nouvelles **contraintes** sous sémantiques extensionnelle:

$\Gamma_T^{ext}$

(rdfs11)

```
<D rdfs:subClassOf B>
<B rdfs:subClassOf E>
————————————————————
<D rdfs:subClassOf E>
```

(rdfs5)

```
<d rdfs:subPropertyOf b>
<b rdfs:subPropertyOf e>
————————————————————
<d rdfs:subPropertyOf e>
```

(ext1)

```
<p rdfs:domain D>
<D rdfs:subClassOf B>
————————————————————
<p rdfs:domain B>
```

(ext2)

```
<p rdfs:range D>
<D rdfs:subClassOf B>
————————————————————
<p rdfs:range B>
```

(ext3)

```
<p rdfs:domain D>
<b rdfs:subPropertyOf p>
————————————————————
<b rdfs:domain D>
```

(ext4)

```
<p rdfs:range D>
<b rdfs:subPropertyOf p>
————————————————————
<b rdfs:range D>
```

# Sémantique opérationnelle de RDFS : les contraintes

- Les règles d'inférence $I_T$ ($I_T$ ext) ou sont correctes et completes pour la derivation de nouvelles **contraintes**

  Cela veut dire : pour une ontologie K=(A,T) de schema <C,P>, une contrainte

  (c-a-d `<s p o>` avec `s,o` ∈ `CUP` et `p` ∈ {`rdfs:subClassOf, rdfs:subPropertyOf, rdfs:domain, rdfs:range`})

  est consequence de K ssi

  - ce triplet peut être obtenu par application successive des derivations $I_T$ ($I_T$ ext) à partir de A∪T
  - ou bien s'il est une contrainte reflexive :

    `D rdfs:subClassOf D` pour tout `D` ∈ C
    `p rdfs:subPropertyOf p` pour tout `p` ∈ P

# Algorithme de saturation pour les faits et les contraintes

- On en derive que l'algorithme de saturation restraint aux règles d'inference $\Gamma_A$ et $\Gamma_T$ (ou $\Gamma_T^{ext}$) et ignorant les triplets axiomatiques, calcule **tous les faits et contraintes** impliquées par (i.e conséquences de) une ontologie RDFS

# Algorithme de saturation RDFS pour les faits et contraintes

Saturation ($\Gamma_T$, $\Gamma_A$)

**Input**: K=<A,T> ( faits A et contraintes T)

**Output**: Les faits et contraintes conséquences de K

```
(1) F←A U T

(3) repeat

(4)     foreach rule  Condition / Conclusion  in Γ_A U Γ_T

(5)         if there exists a substitution σ such that
(6)         σ(Condition) ∈ F and σ(Conclusion) ∉ F
(7)             add σ(Conclusion) to F
(8)
(10) until nothing added to F
```

Pour utiliser la sémantique extensionnelle utiliser Saturation ($\Gamma_T$ ext, $\Gamma_A$)

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur,  :createur}  C={ :Objet,  :Document,  :Agent,  :Personne}

F

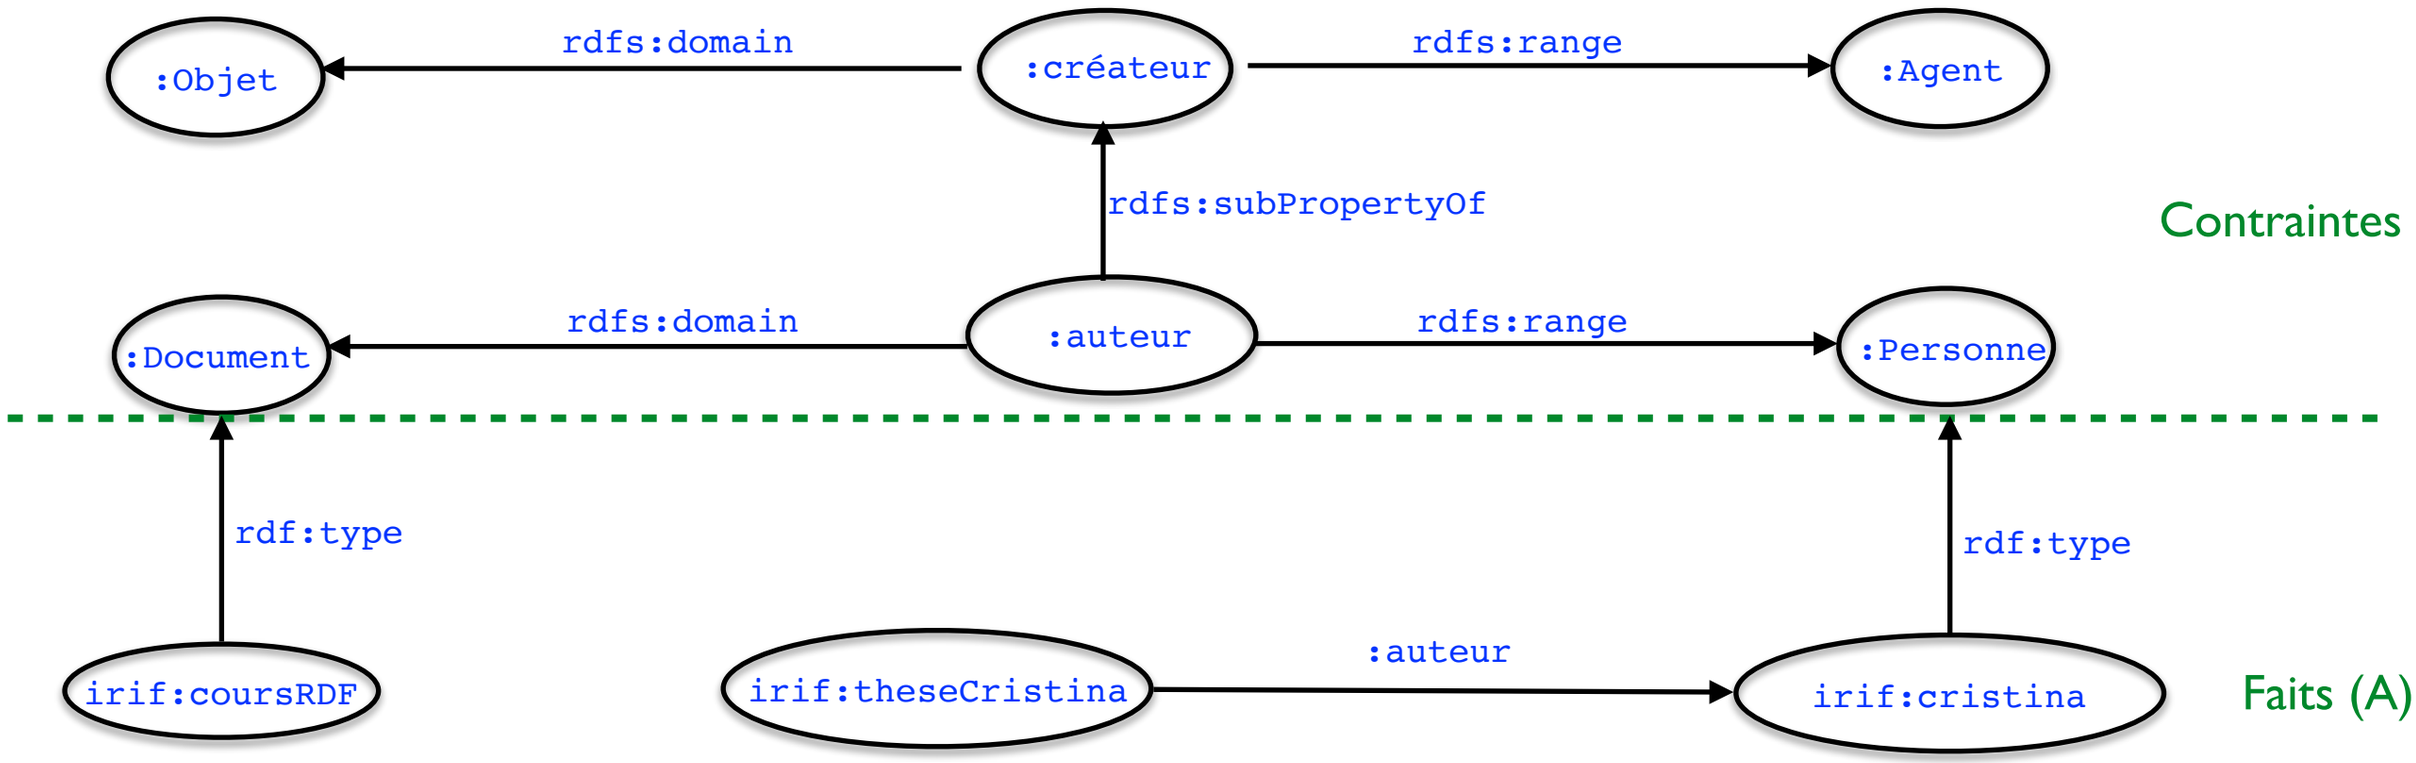


F:= A ∪ T

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur,  :createur}  C={ :Objet,  :Document,  :Agent,  :Personne}

F

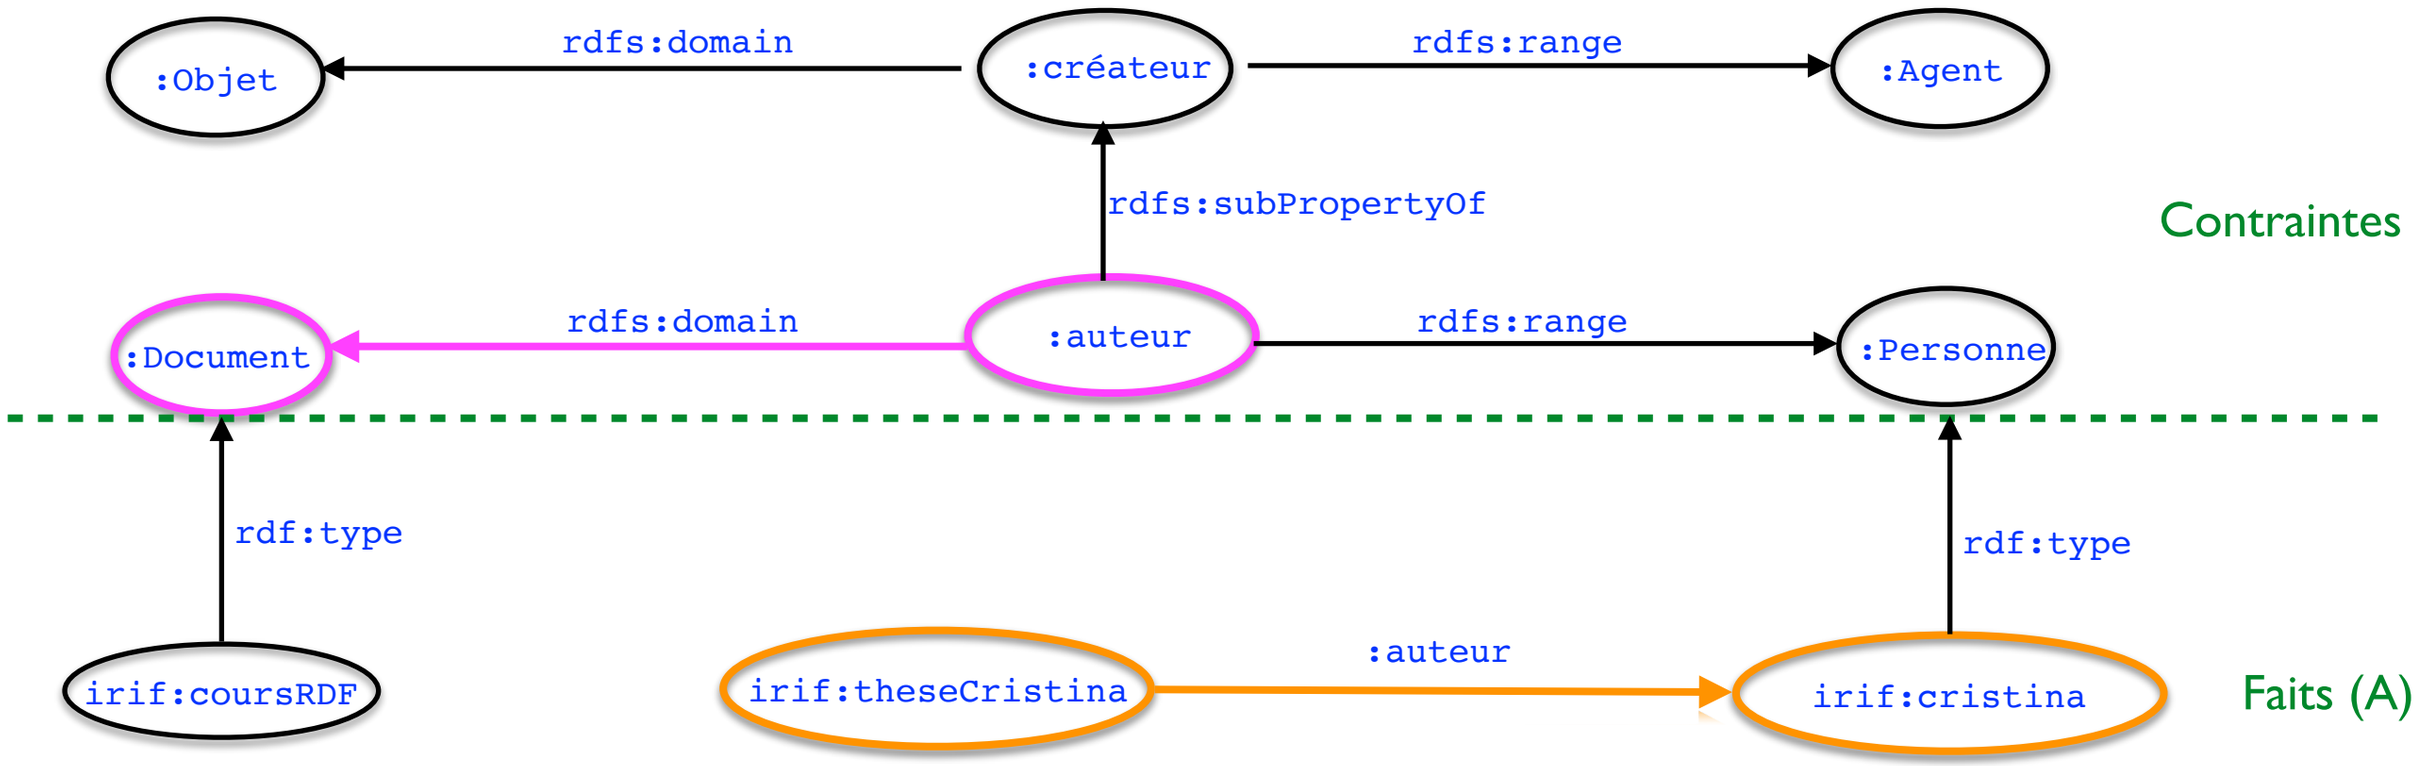


---

F:= A∪T

1. La regle (rdfs2)

```
<r P s>
<P rdfs:domain D >
_____________________
<r rdfs:type D>
```

a une substitution $\sigma$ qui inclut les premisses dans F :

$\sigma$ : *r -> irif:theseCristina*
*P ->  :auteur*
*s -> irif:cristina*
*D -> :Document*

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur, :createur}  C={ :Objet, :Document, :Agent, :Personne}

F

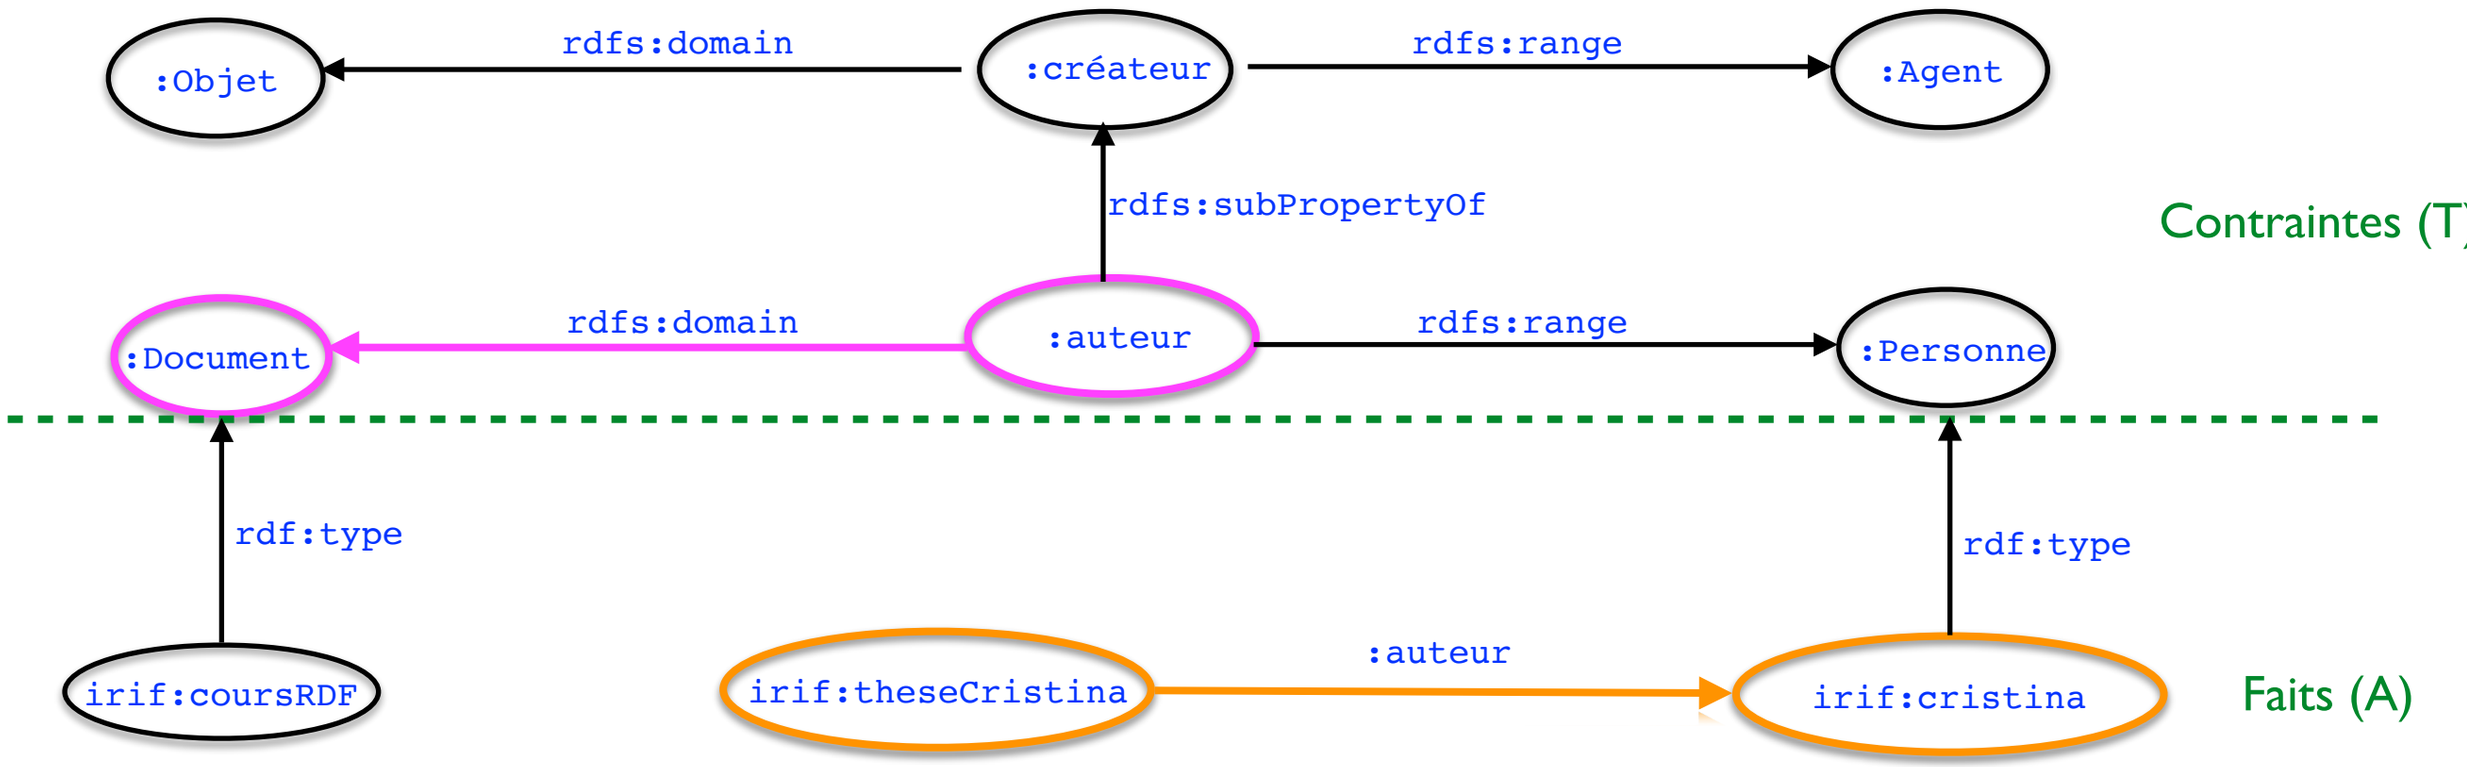


---

F:= A∪T

I.

<irif:theseCristina :auteur irif:Cristina>
<:auteur rdfs:domain :Document >
---
<irif:theseCristina rdfs:type :Document>

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur, :createur}  C={ :Objet, :Document, :Agent, :Personne}

F

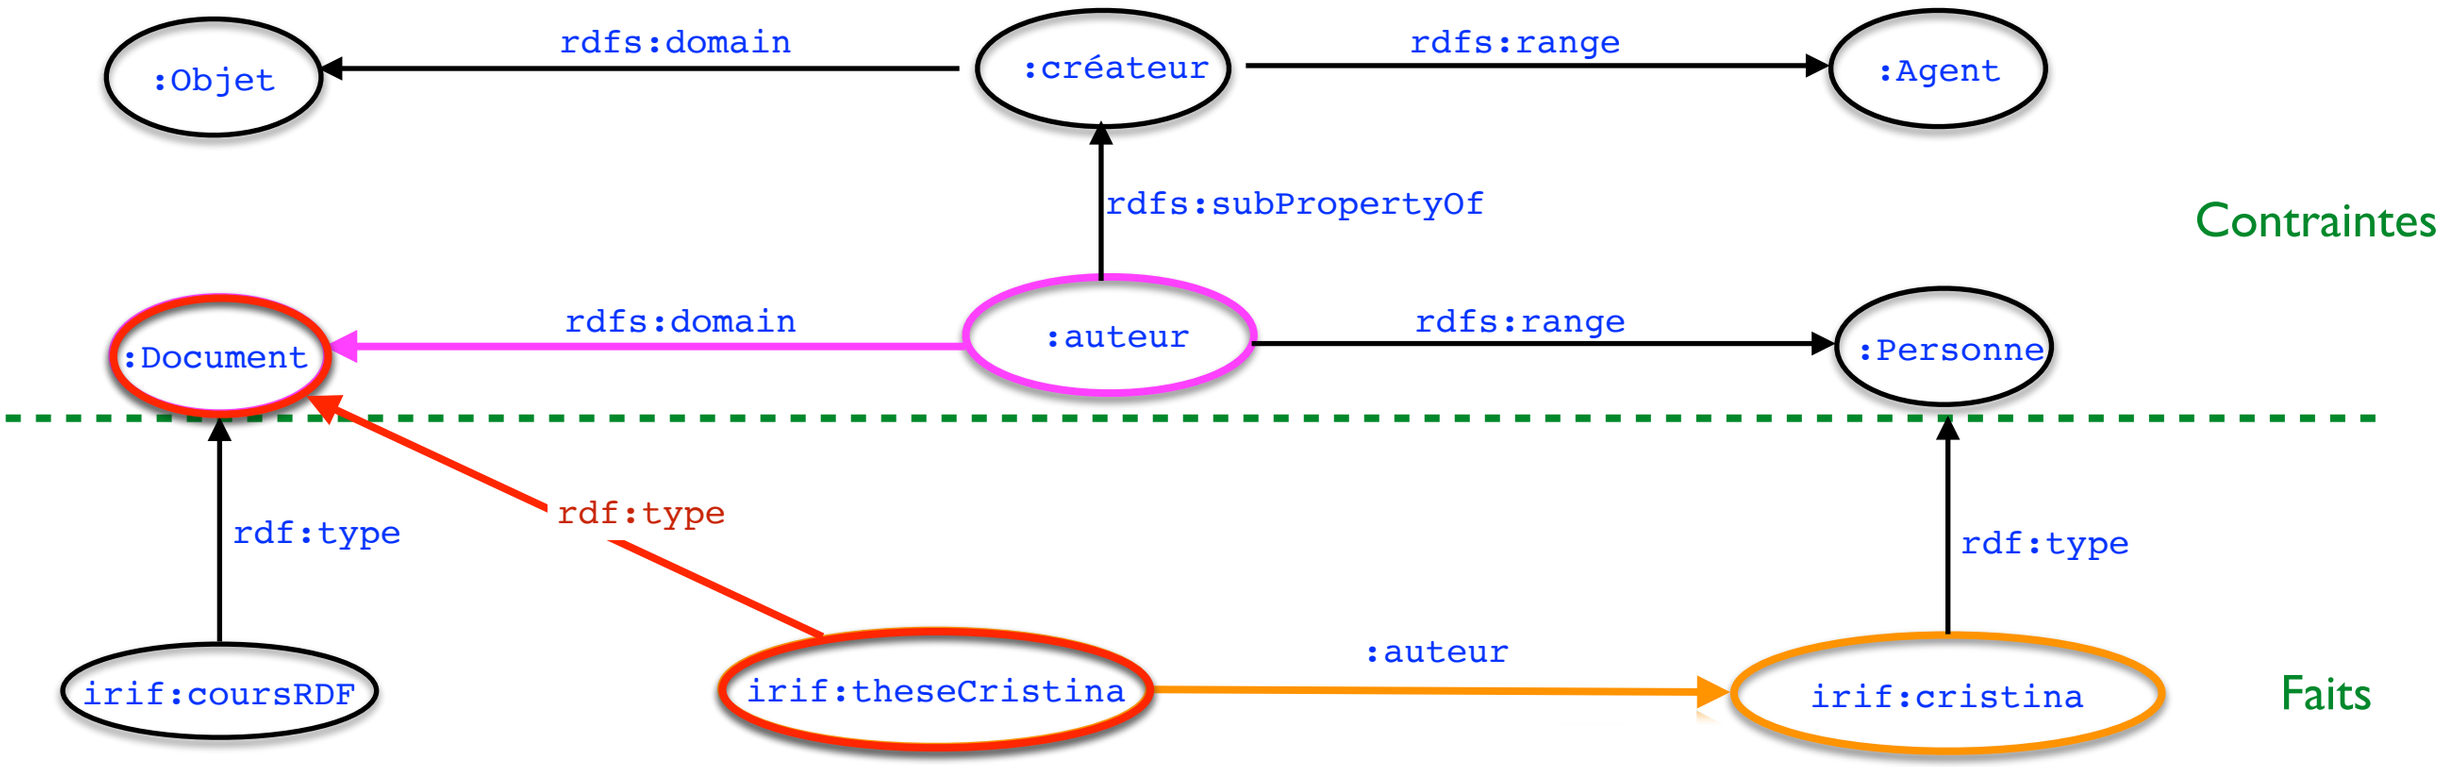


---

F:= AUTU { **irif:theseCristina rdfs:type :Document**}

1.

**<irif:theseCristina :auteur irif:Cristina>**
**<:auteur rdfs:domain :Document >**
---
**<irif:theseCristina rdfs:type :Document>**

On en déduit un nouveau fait dans F

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur, :createur}  C={ :Objet, :Document, :Agent, :Personne}

F

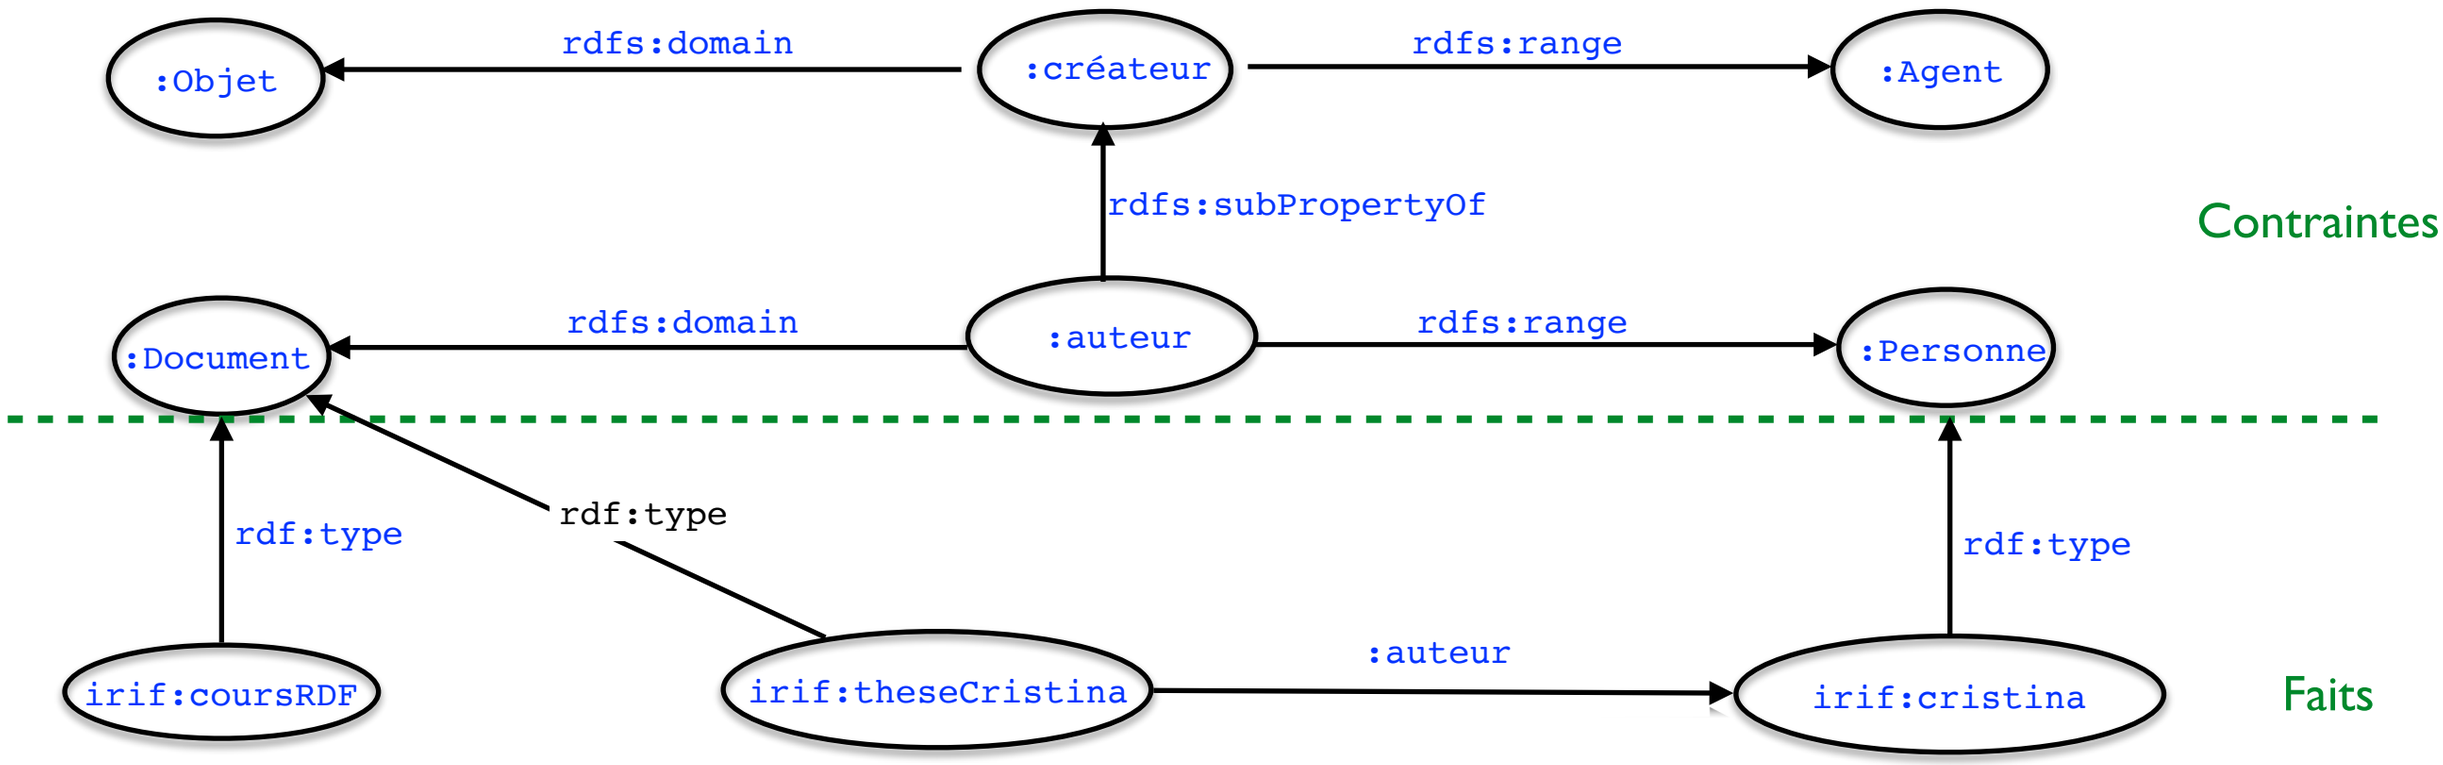


---

F:= A∪T ∪ { `irif:theseCristina rdfs:type :Document`}

2.

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur, :createur}  C={ :Objet, :Document, :Agent, :Personne}

F

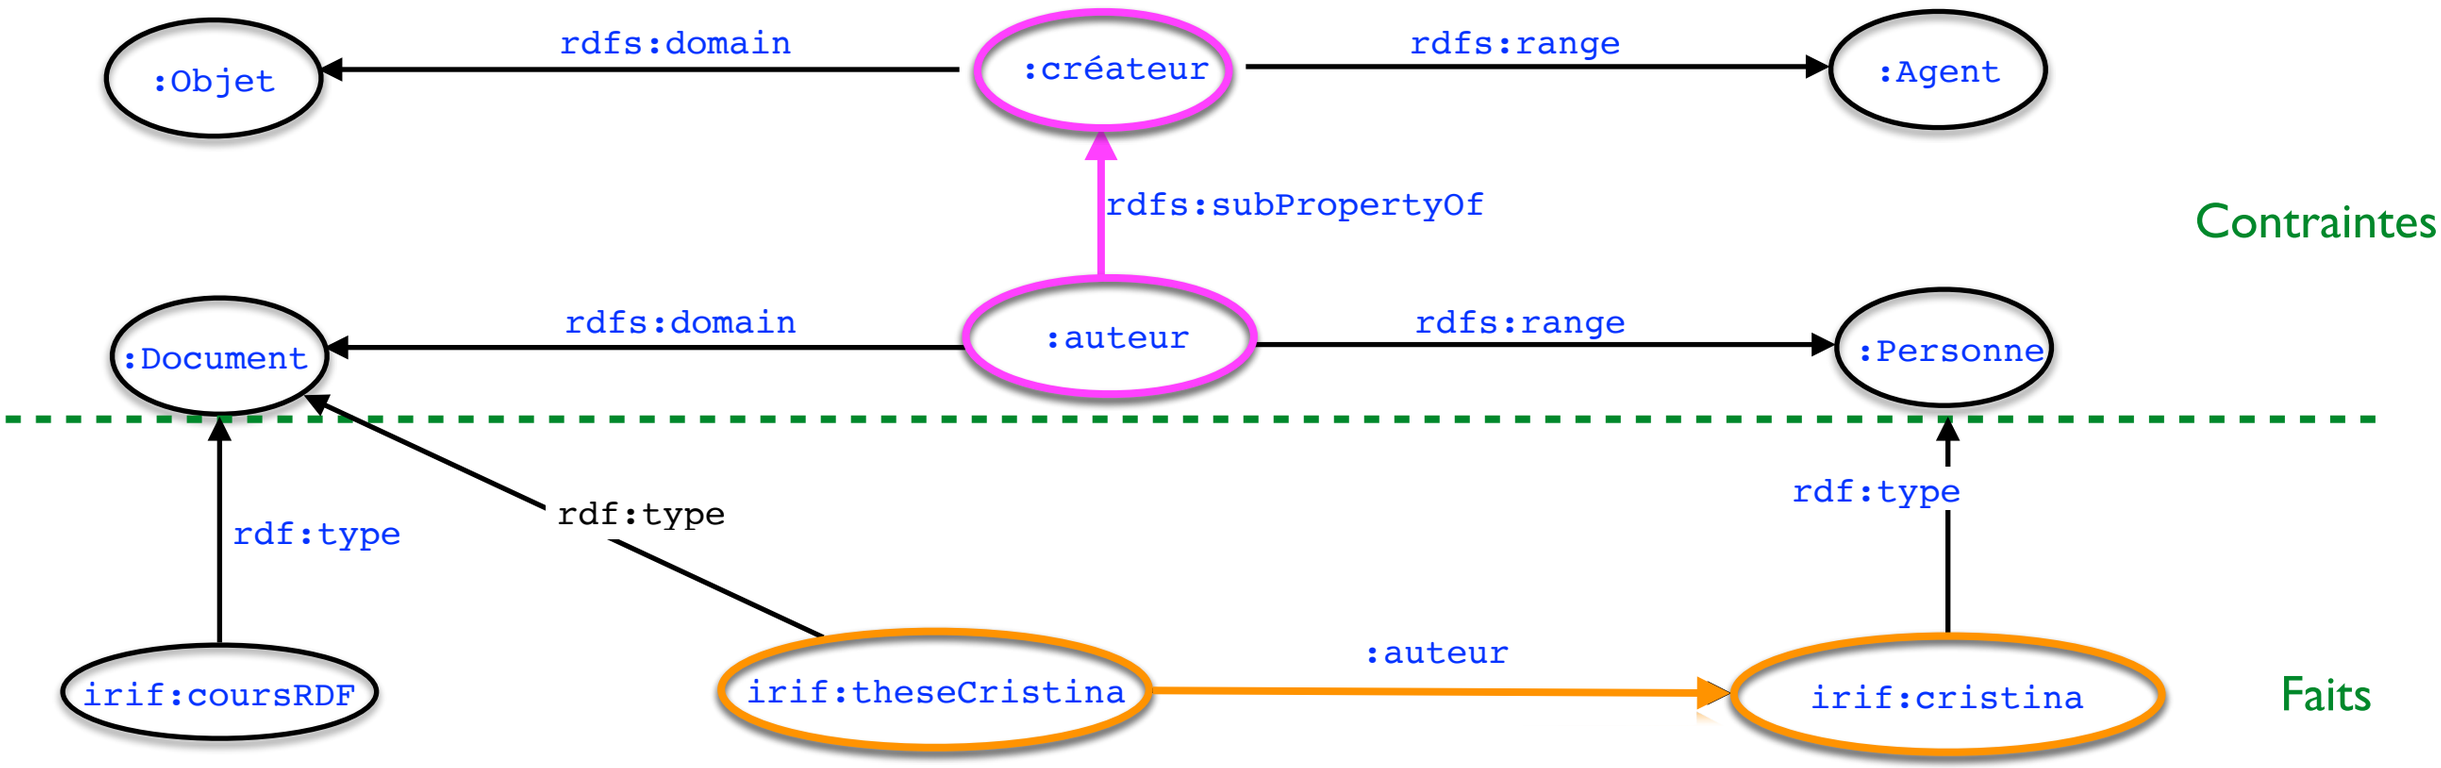


F:= AUT U { irif:theseCristina rdfs:type :Document}

2.

```
<irif:theseCristina :auteur irif:Cristina>
<:auteur rdfs:subPropertyOf :createur >
_____________________
<irif:theseCristina :createur irif:cristina>
```

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur, :createur}  C={ :Objet, :Document, :Agent, :Personne}

F

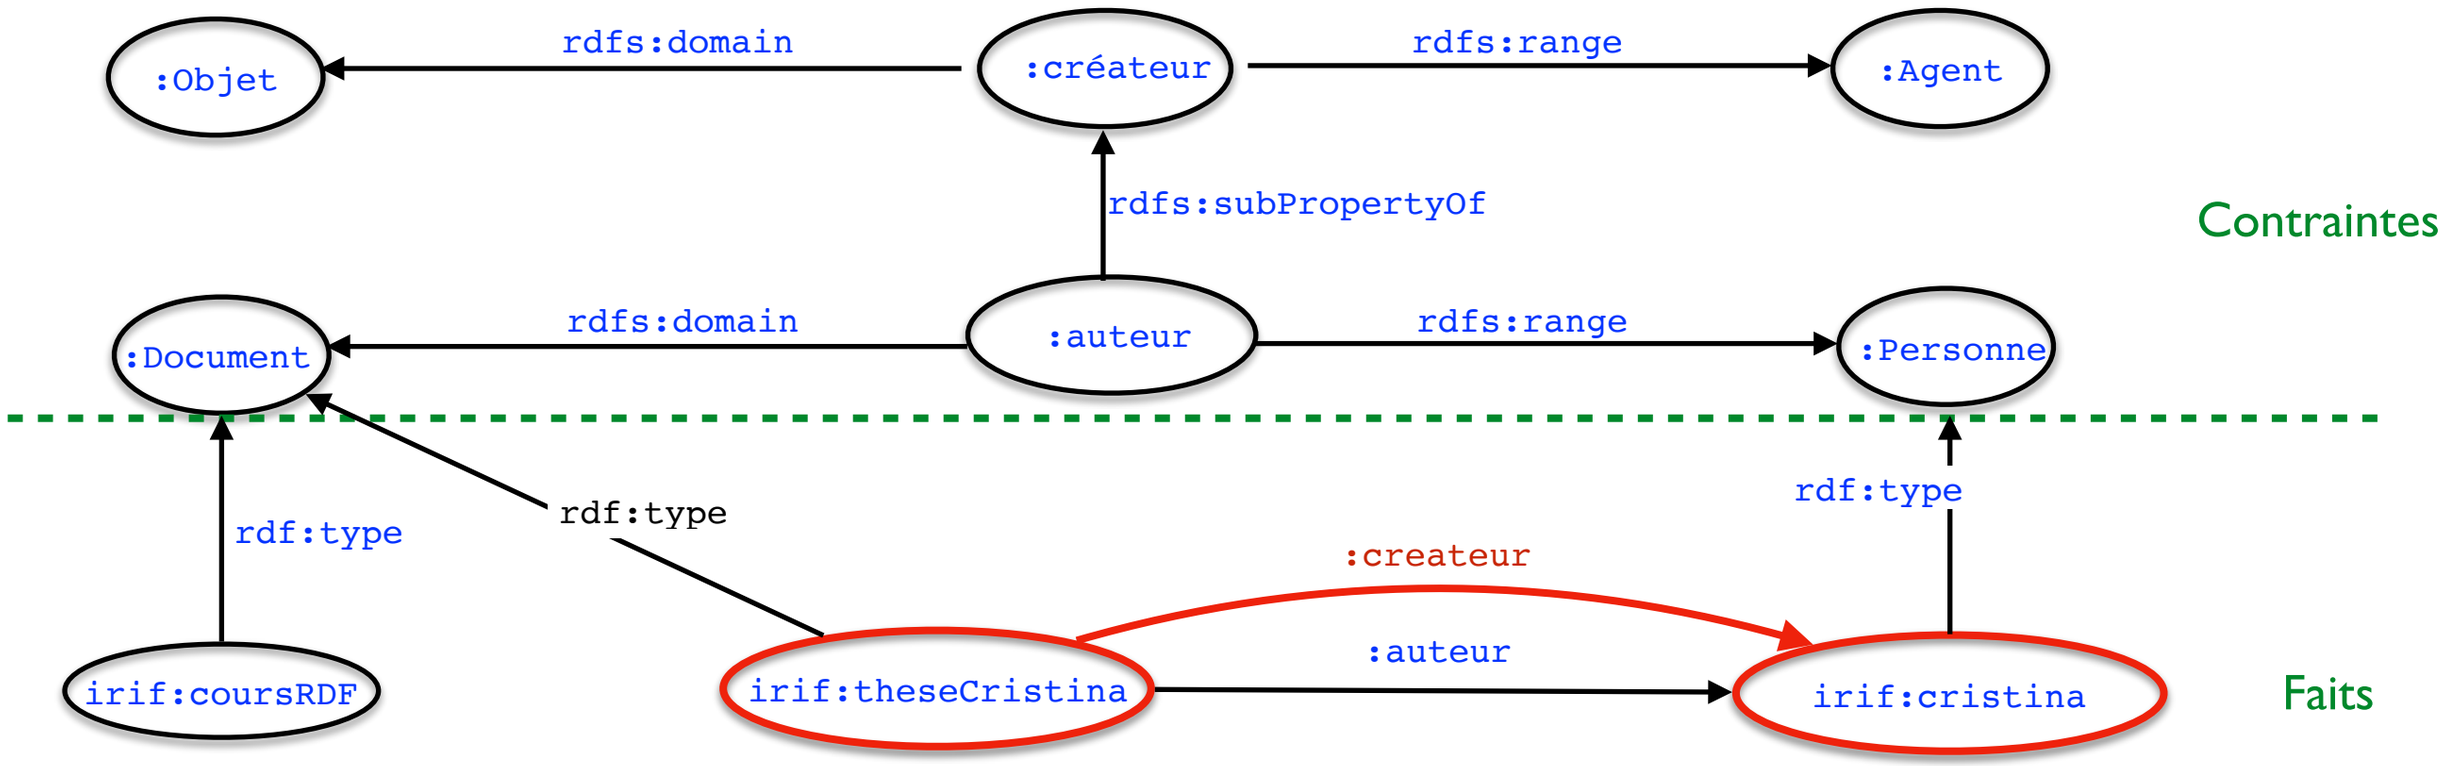


F:= AUT U { irif:theseCristina rdfs:type :Document, **irif:theseCristina :createur irif:cristina** }

2.

**<irif:theseCristina :auteur irif:Cristina>**
**<:auteur rdfs:subPropertyOf :createur >**

---

**<irif:theseCristina :createur irif:cristina>**

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur,  :createur}  C={ :Objet,  :Document,  :Agent,  :Personne}

F

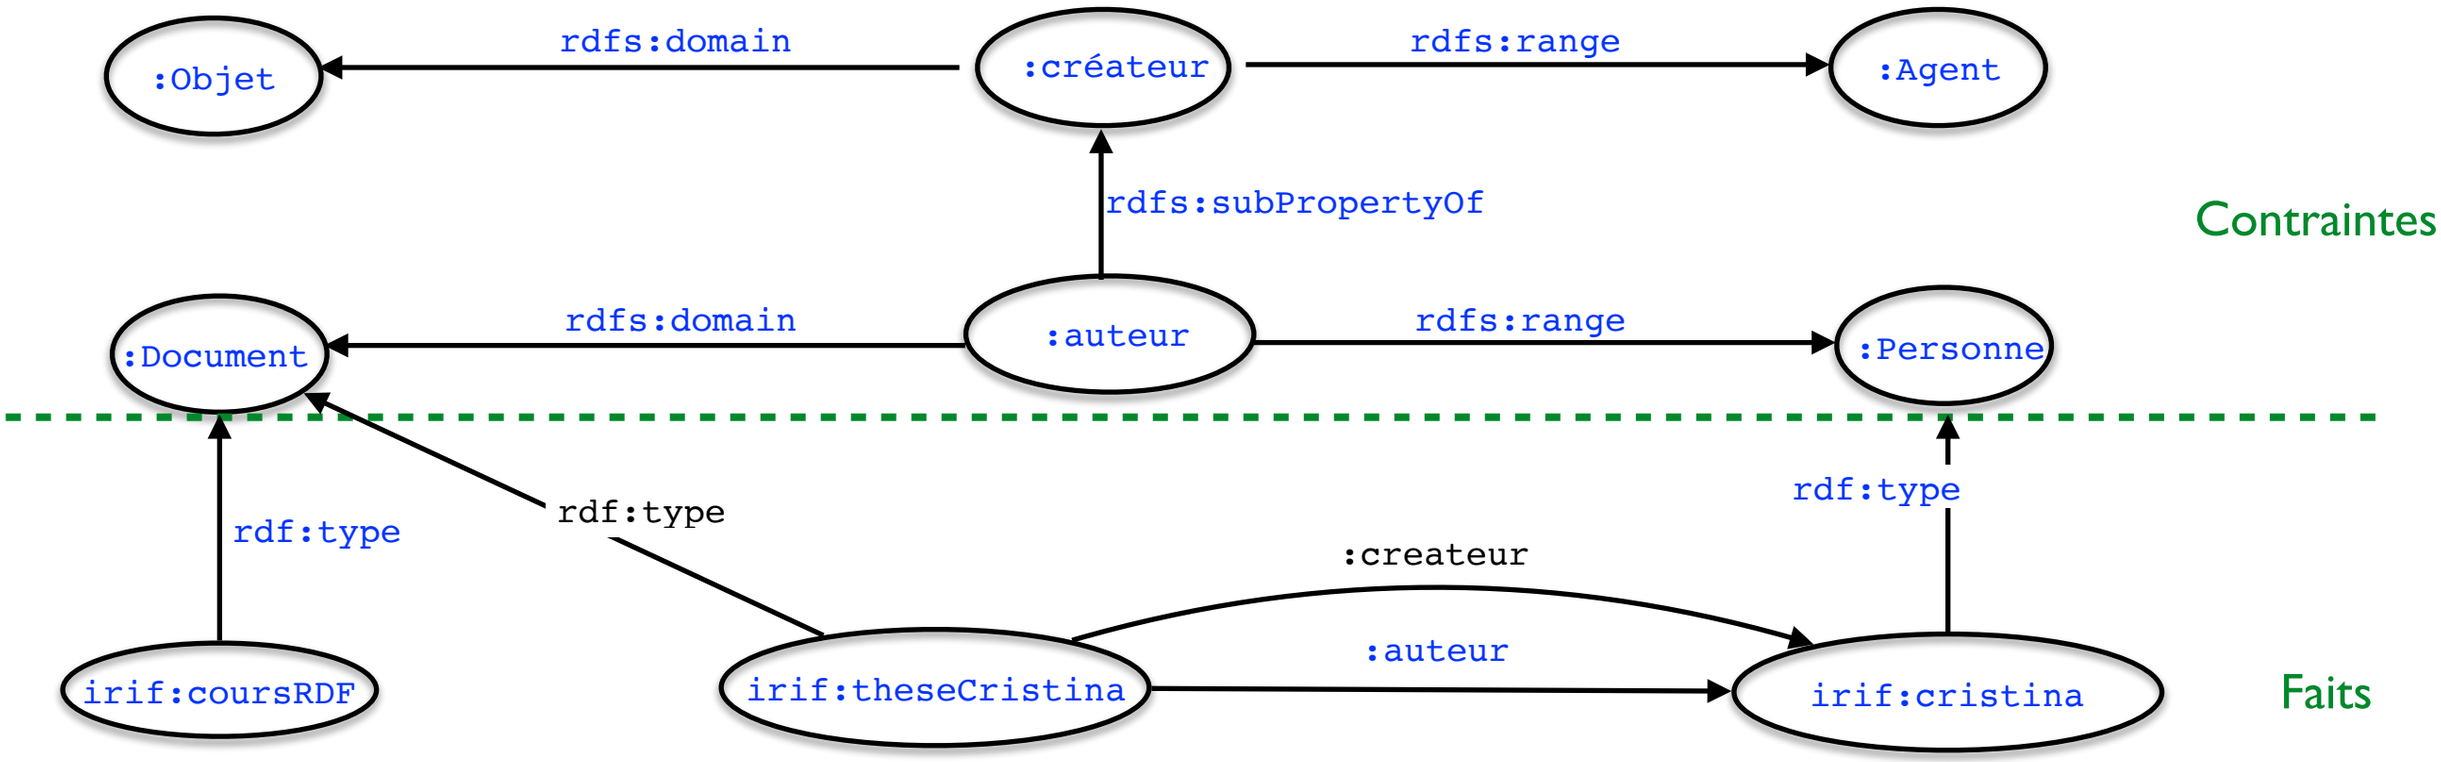


---

F:= AUT U { irif:theseCristina rdfs:type :Document, irif:theseCristina :createur irif:cristina }

3.

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur, :createur}  C={ :Objet, :Document, :Agent, :Personne}

F

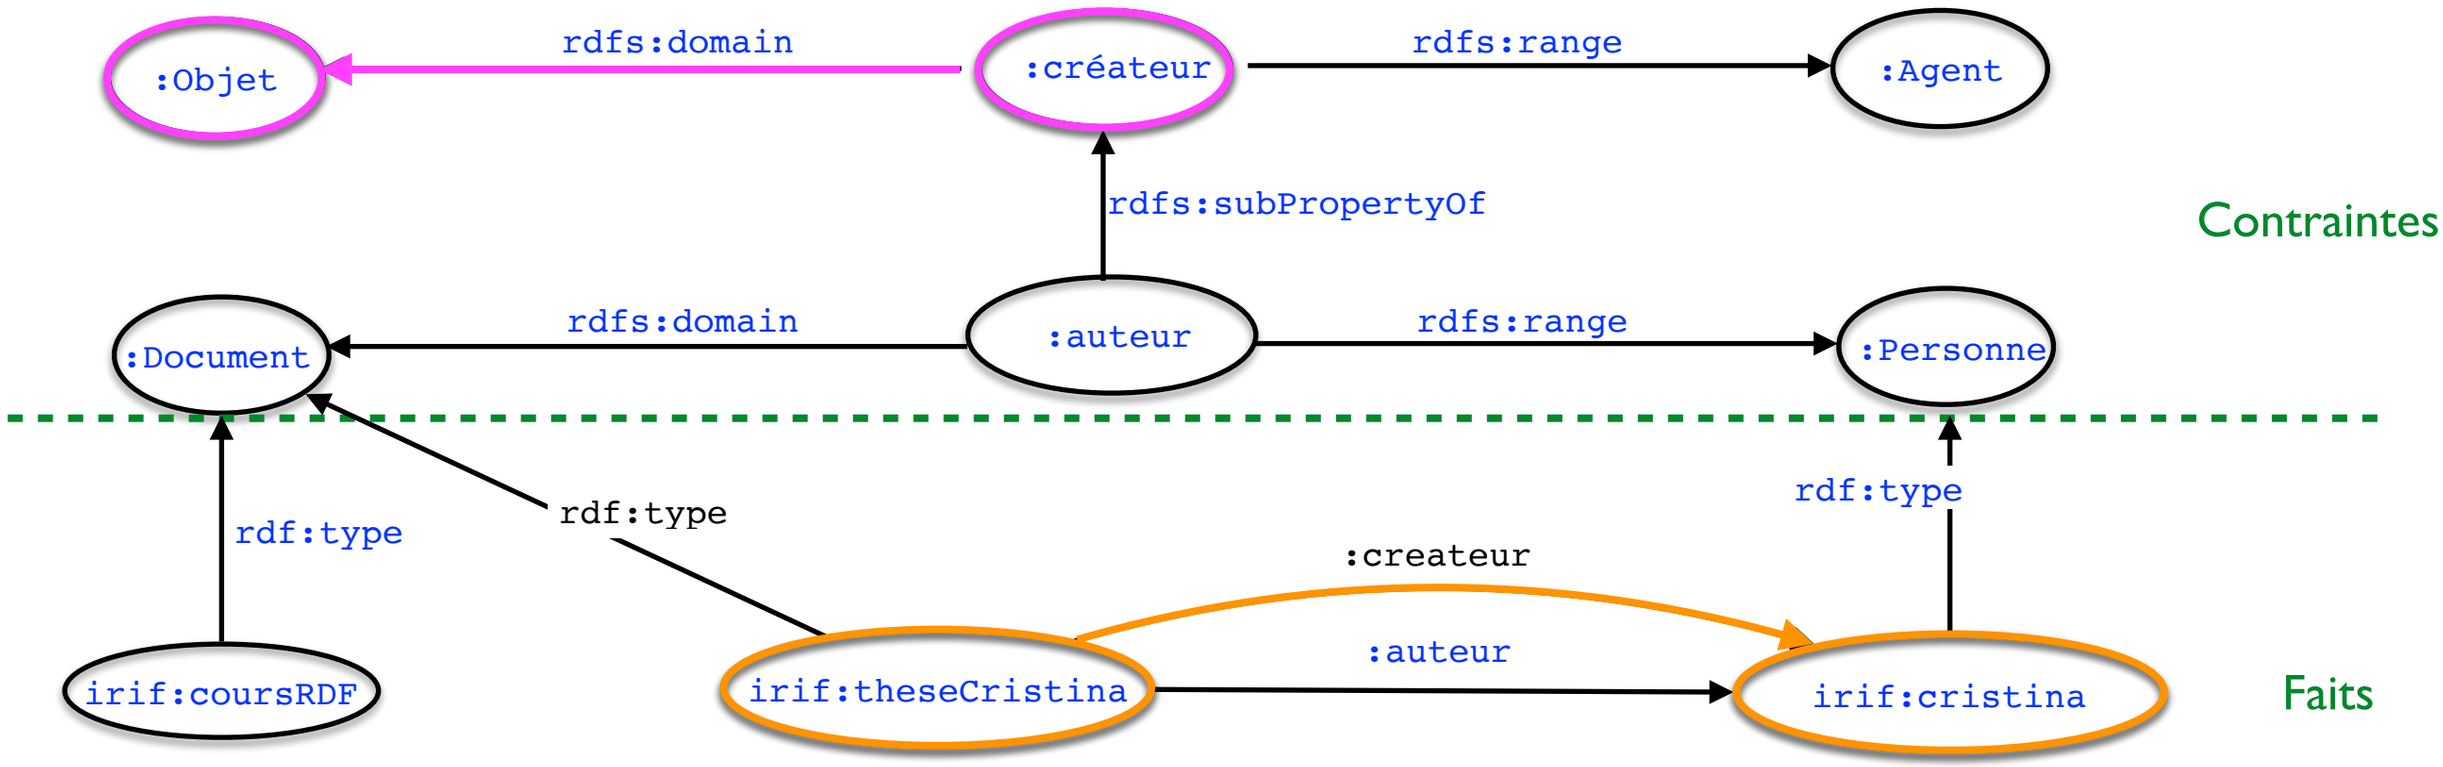


F:= A∪T ∪ { `irif:theseCristina rdfs:type :Document, irif:theseCristina :createur irif:cristina` }

3.

```
<irif:theseCristina :createur irif:cristina>
<:createur rdfs:domain :Object >
_____________________
<irif:theseCristina :rdf:type :Object>
```

**Remarque** : on peut utiliser les inférences comme base pour de nouvelles inférences

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur, :createur}  C={ :Objet, :Document, :Agent, :Personne}

F

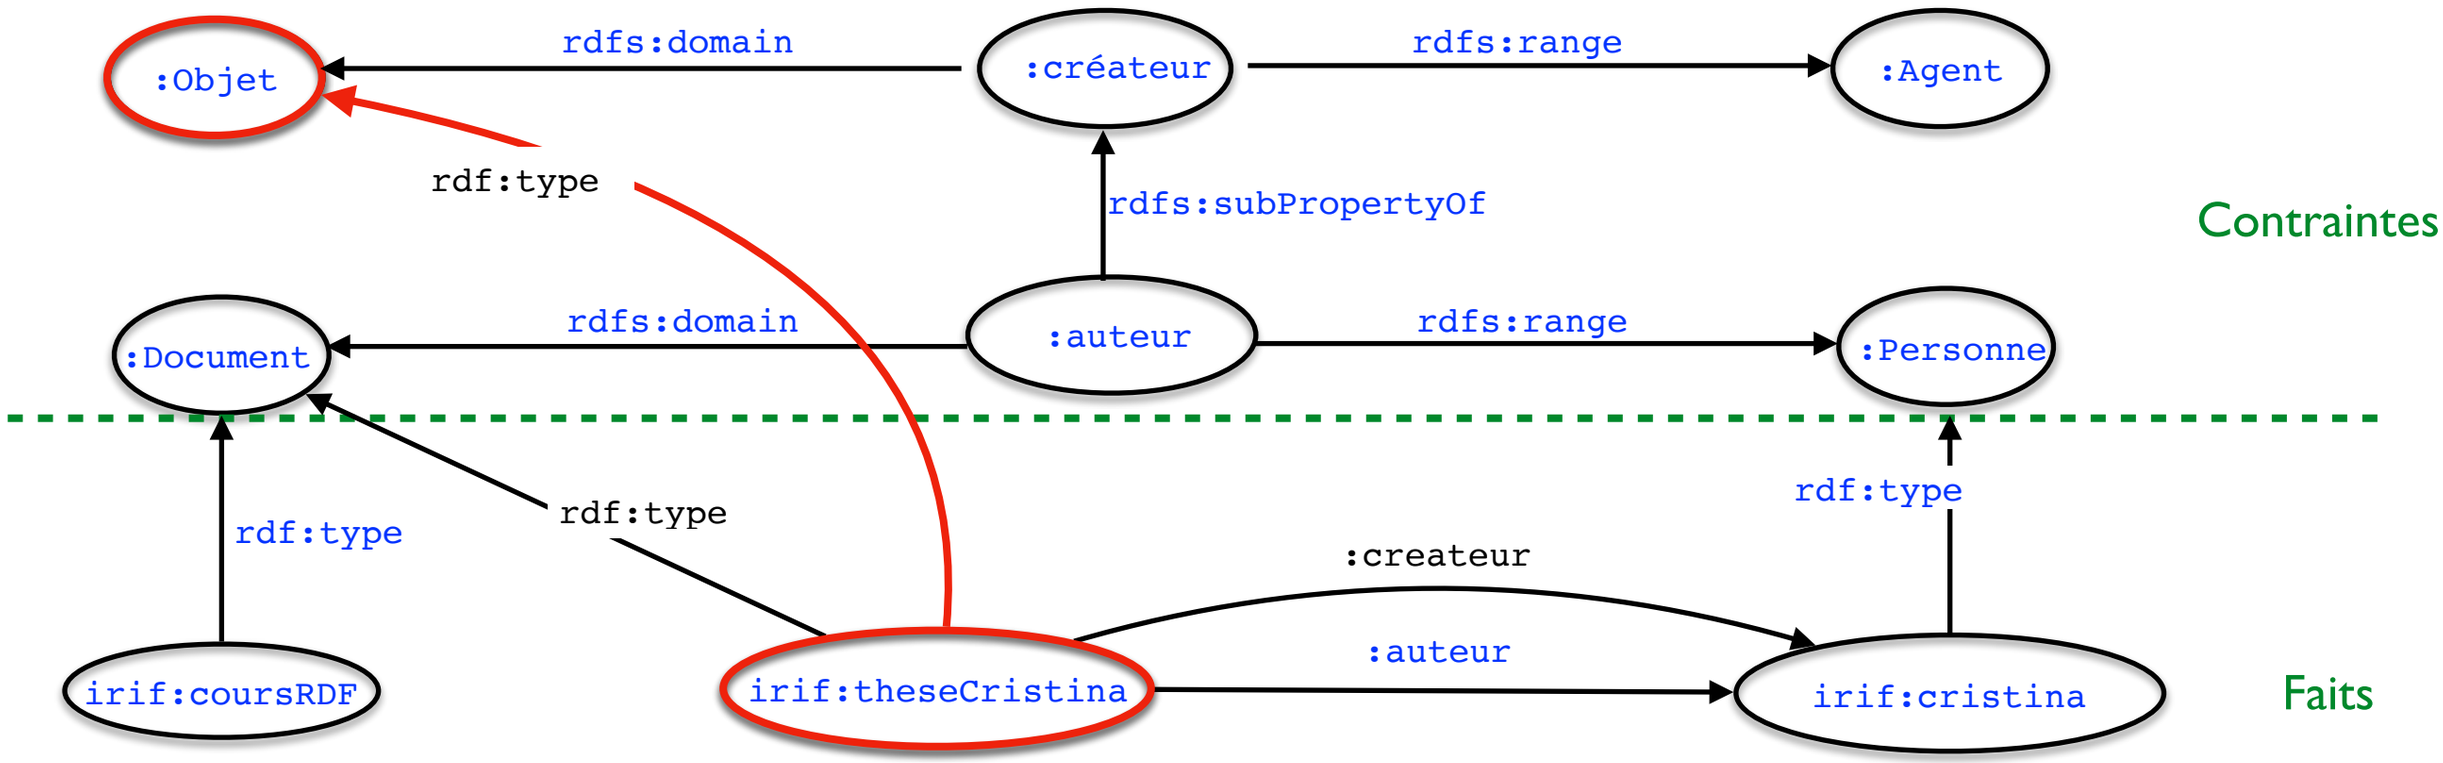


F:= AuT U { irif:theseCristina rdfs:type :Document, irif:theseCristina :createur irif:cristina, **irif:theseCristina :rdf:type :Object** }

3.

**<irif:theseCristina :createur irif:cristina>**
**<:createur rdfs:domain :Object >**

---

**<irif:theseCristina :rdf:type :Object>**

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur, :createur}  C={ :Objet, :Document, :Agent, :Personne}

F

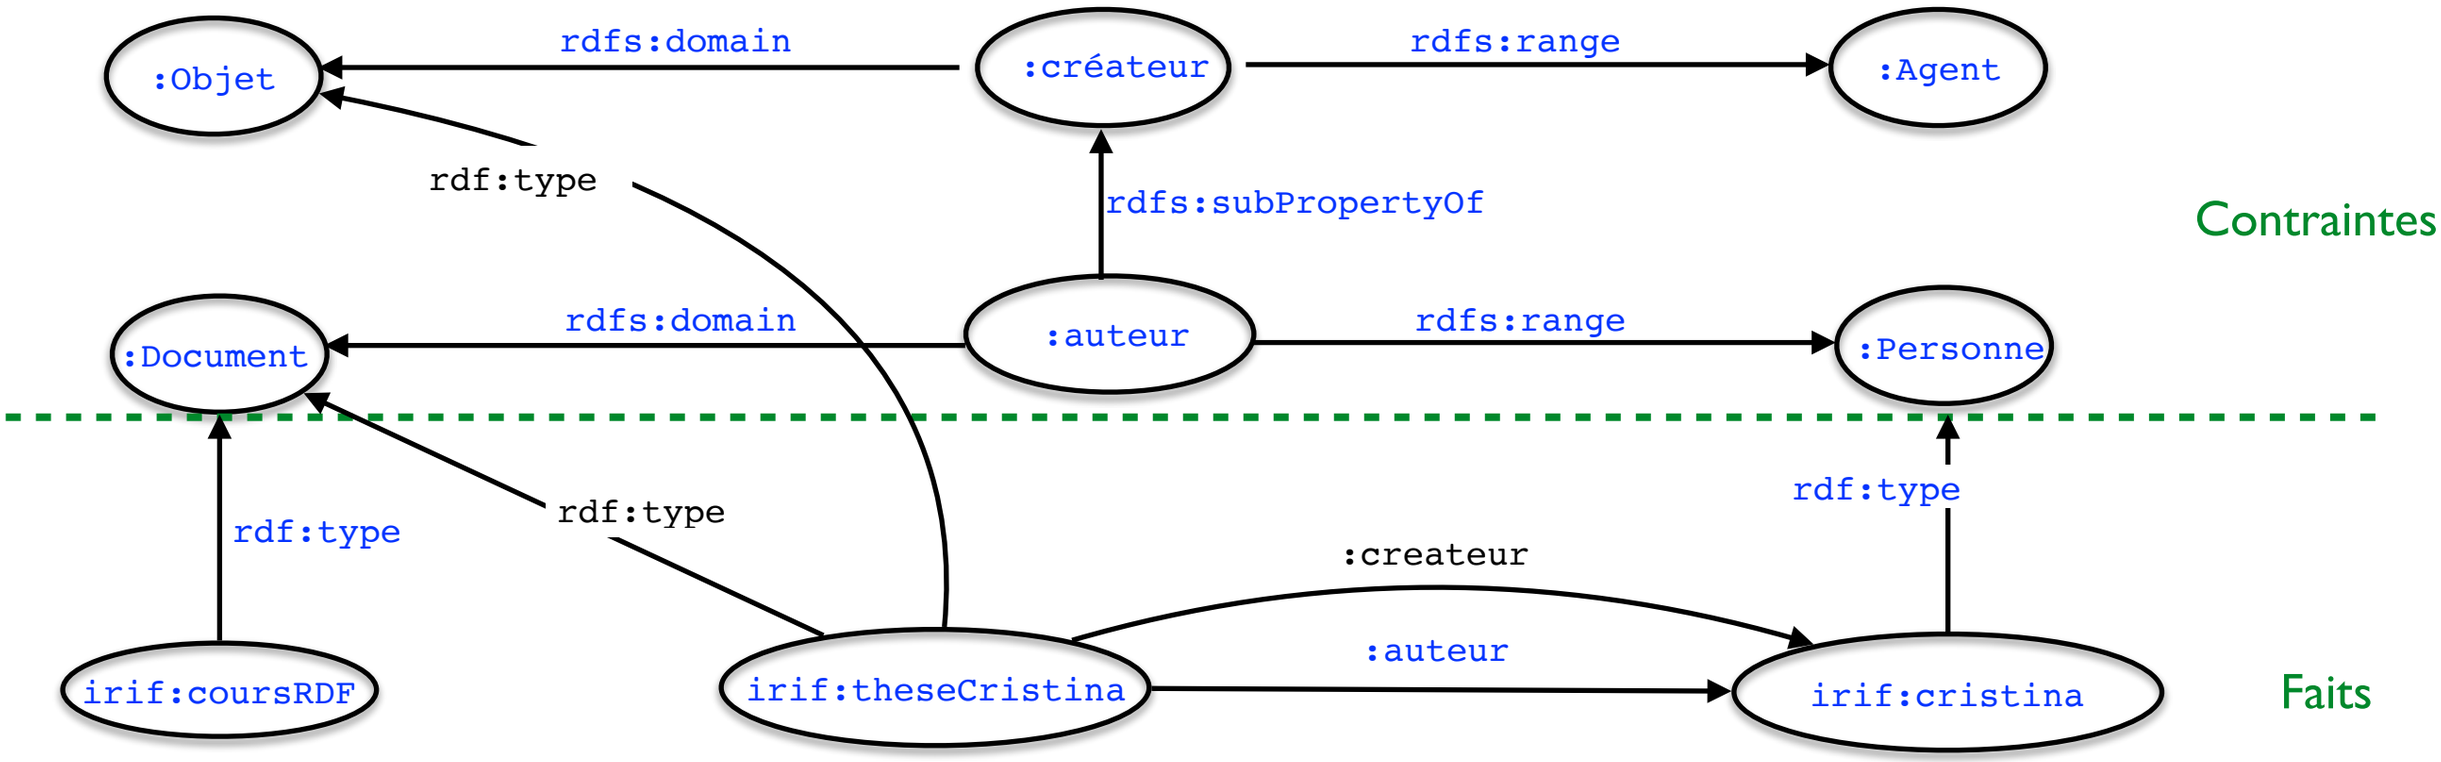


F:= AUT U { irif:theseCristina rdfs:type :Document, irif:theseCristina :createur irif:cristina, irif:theseCristina :rdf:type :Object }

4.

# Exemple : algorithme de saturation

- P ={ :auteur, :createur} C={ :Objet, :Document, :Agent, :Personne}

F

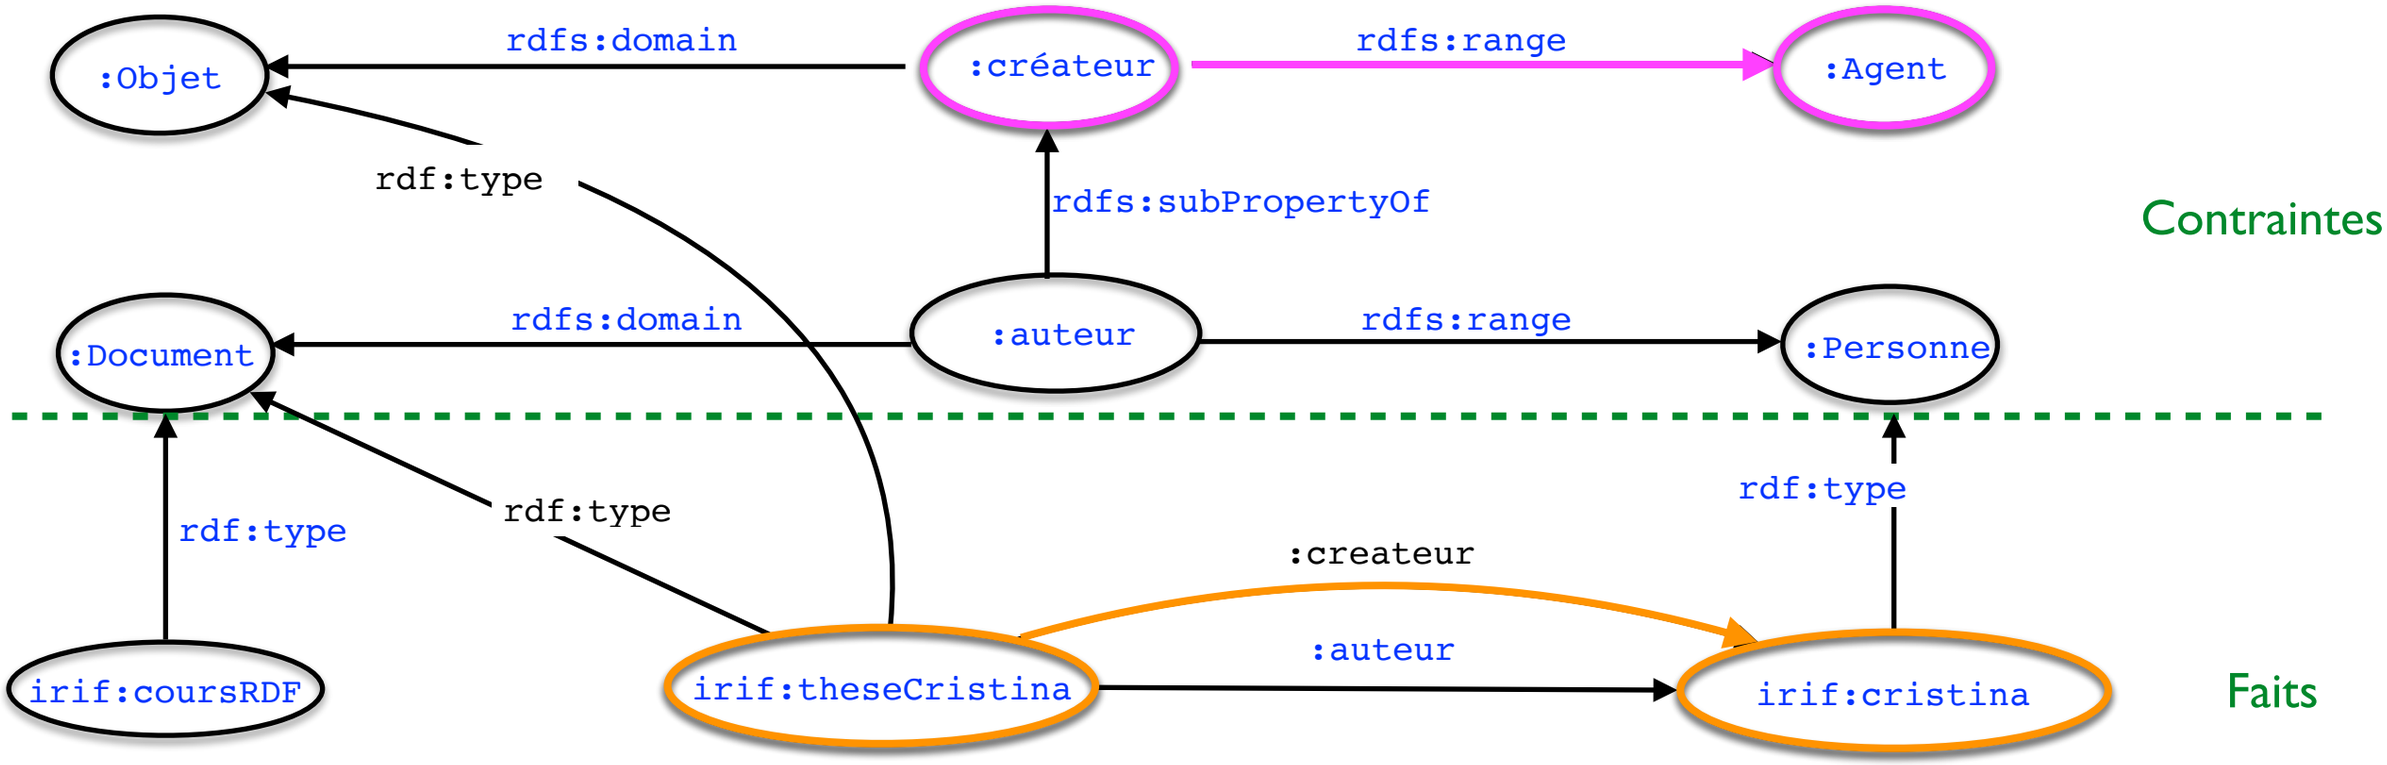


F:= AUT U { irif:theseCristina rdfs:type :Document, irif:theseCristina :createur irif:cristina, irif:theseCristina :rdf:type :Object }

4.

<irif:theseCristina :createur irif:cristina>
<:createur rdfs:range :Agent >

---

<irif:theseCristina rdf:type :Agent>

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur, :createur} C={ :Objet, :Document, :Agent, :Personne}

F

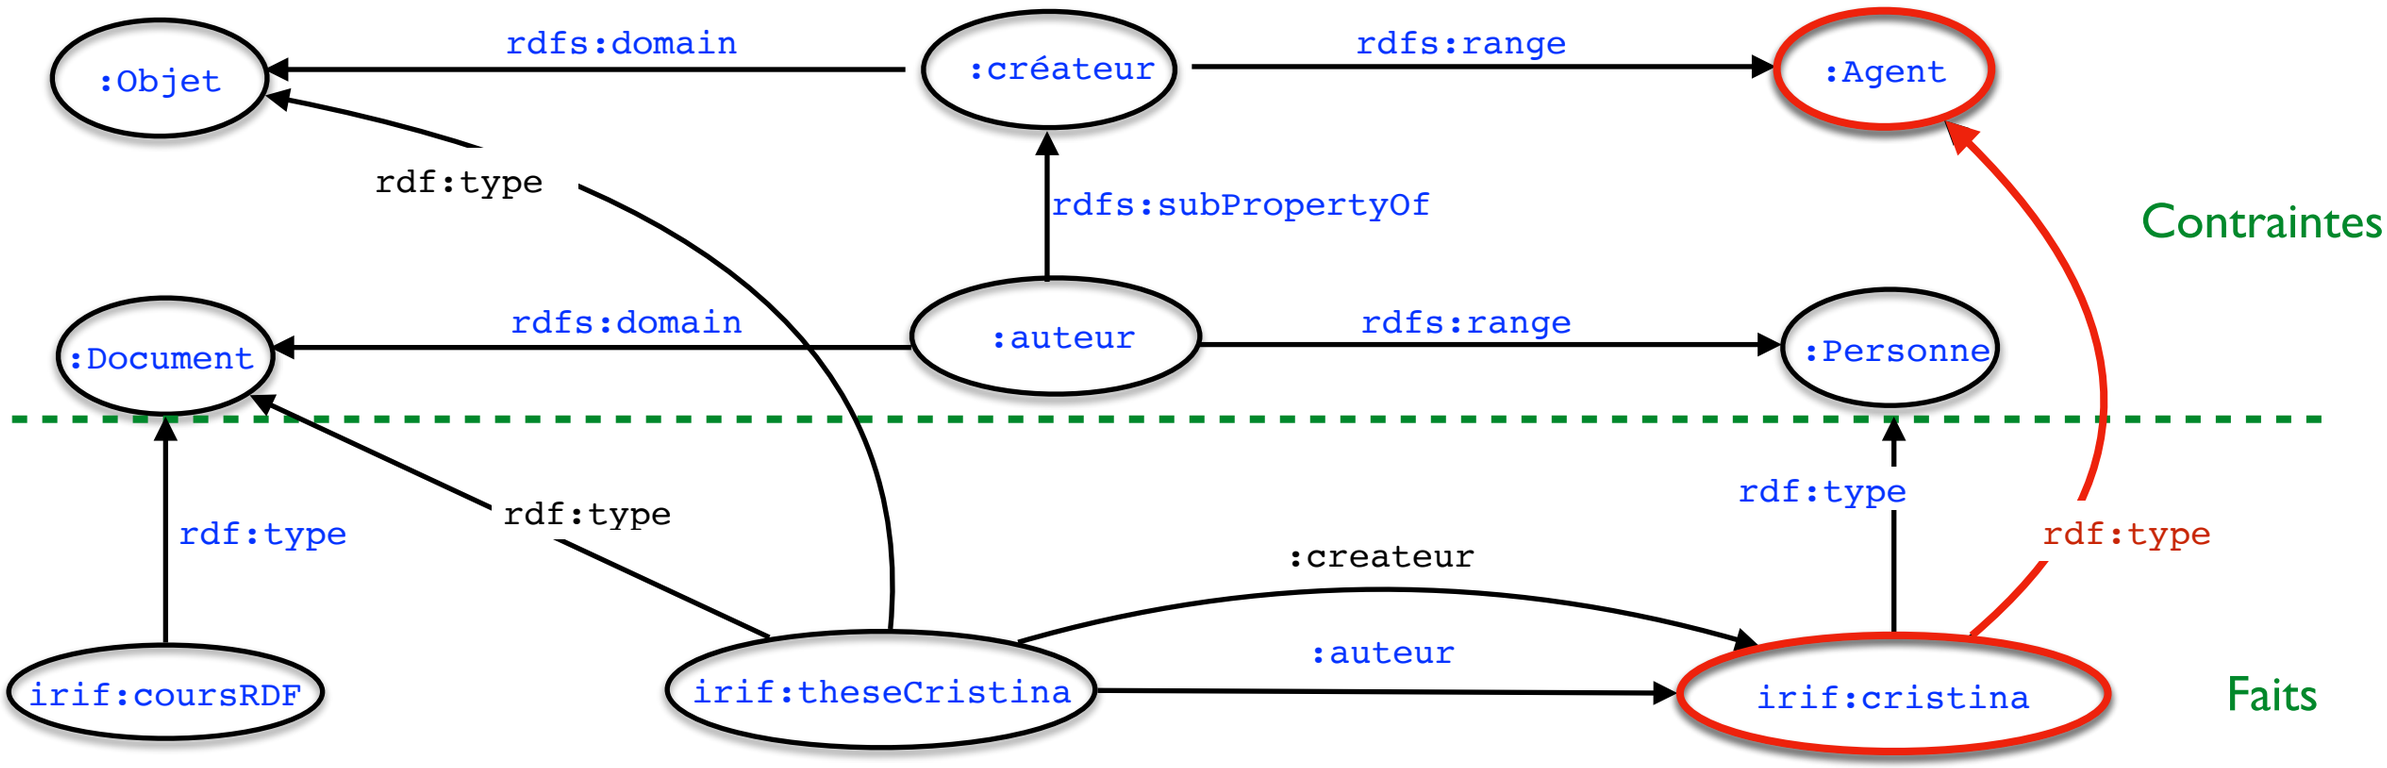


F:= AUT U { irif:theseCristina rdfs:type :Document, irif:theseCristina :createur irif:cristina, irif:theseCristina :rdf:type :Object, **irif:theseCristina rdf:type :Agent** }

4.

**<irif:theseCristina :createur irif:cristina>**
**<:createur rdfs:range :Agent >**

---

**<irif:theseCristina rdf:type :Agent>**

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur, :createur}  C={ :Objet, :Document, :Agent, :Personne}

F

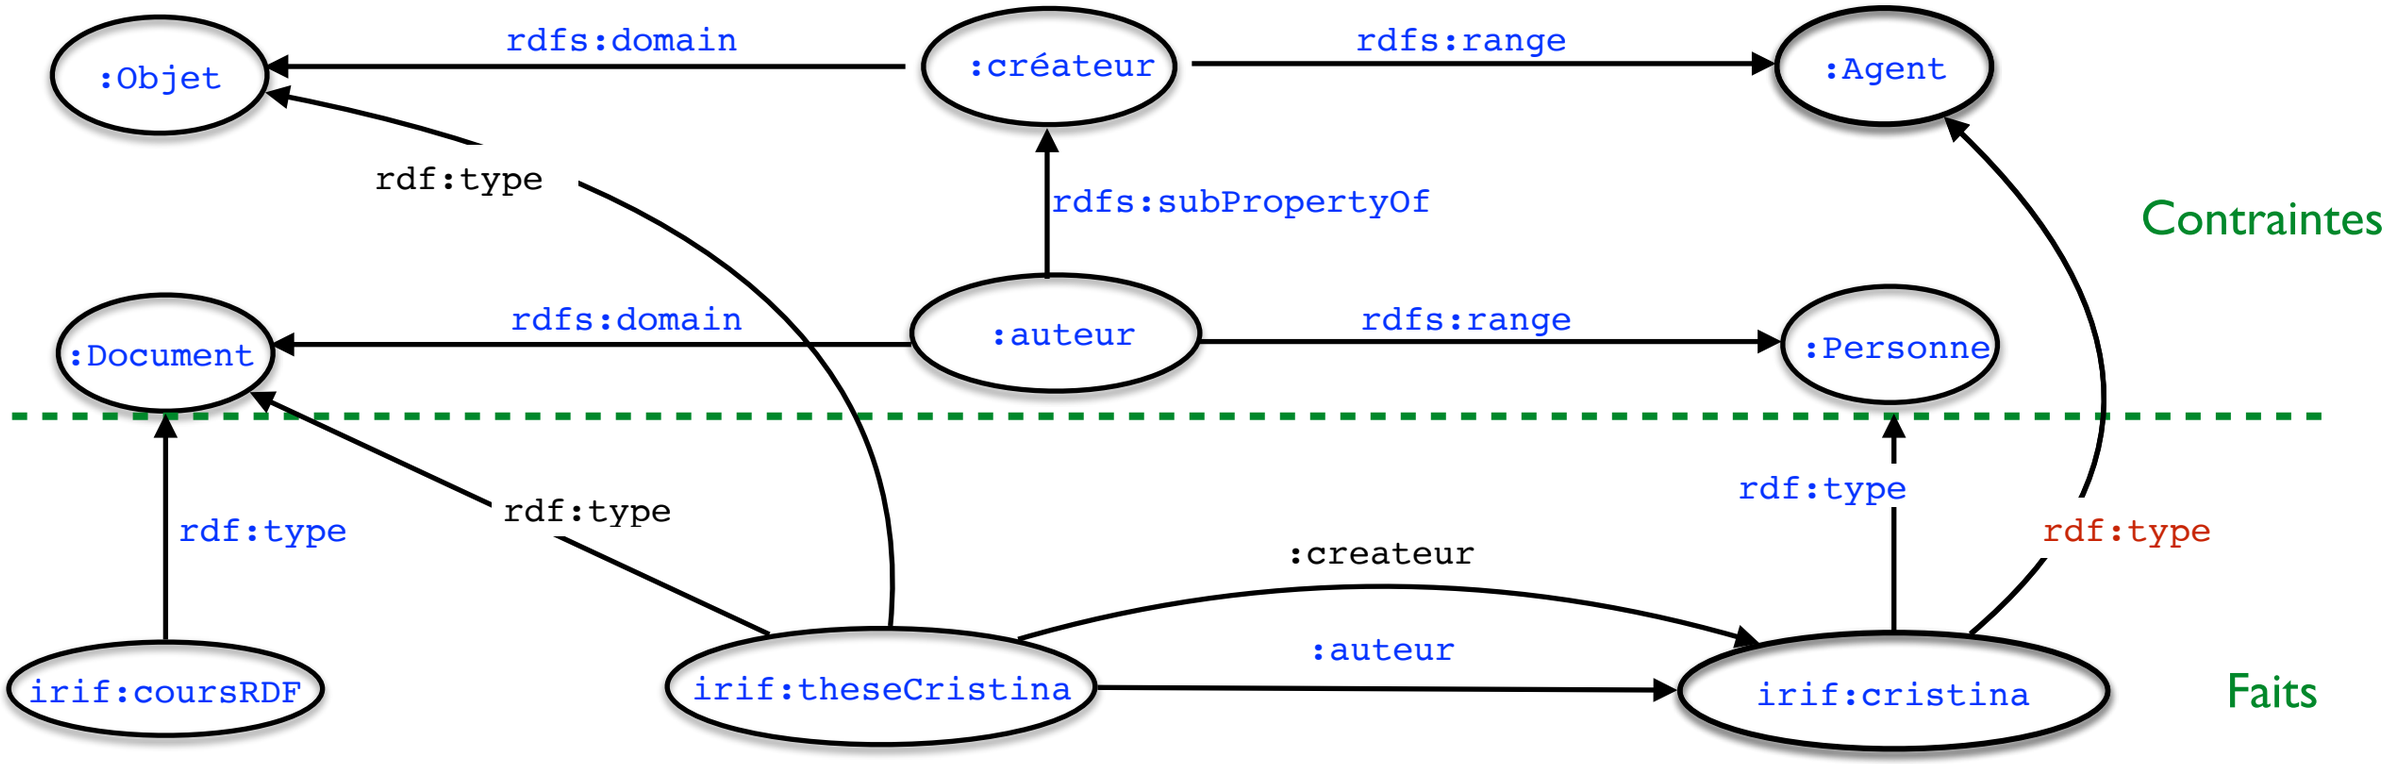


F:= AUT U { irif:theseCristina rdfs:type :Document, irif:theseCristina :createur irif:cristina, irif:theseCristina :rdf:type :Object, irif:theseCristina rdf:type :Agent }

5.

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur, :createur}  C={ :Objet, :Document, :Agent, :Personne}

F

**En plus si sémantique extensionnelle**

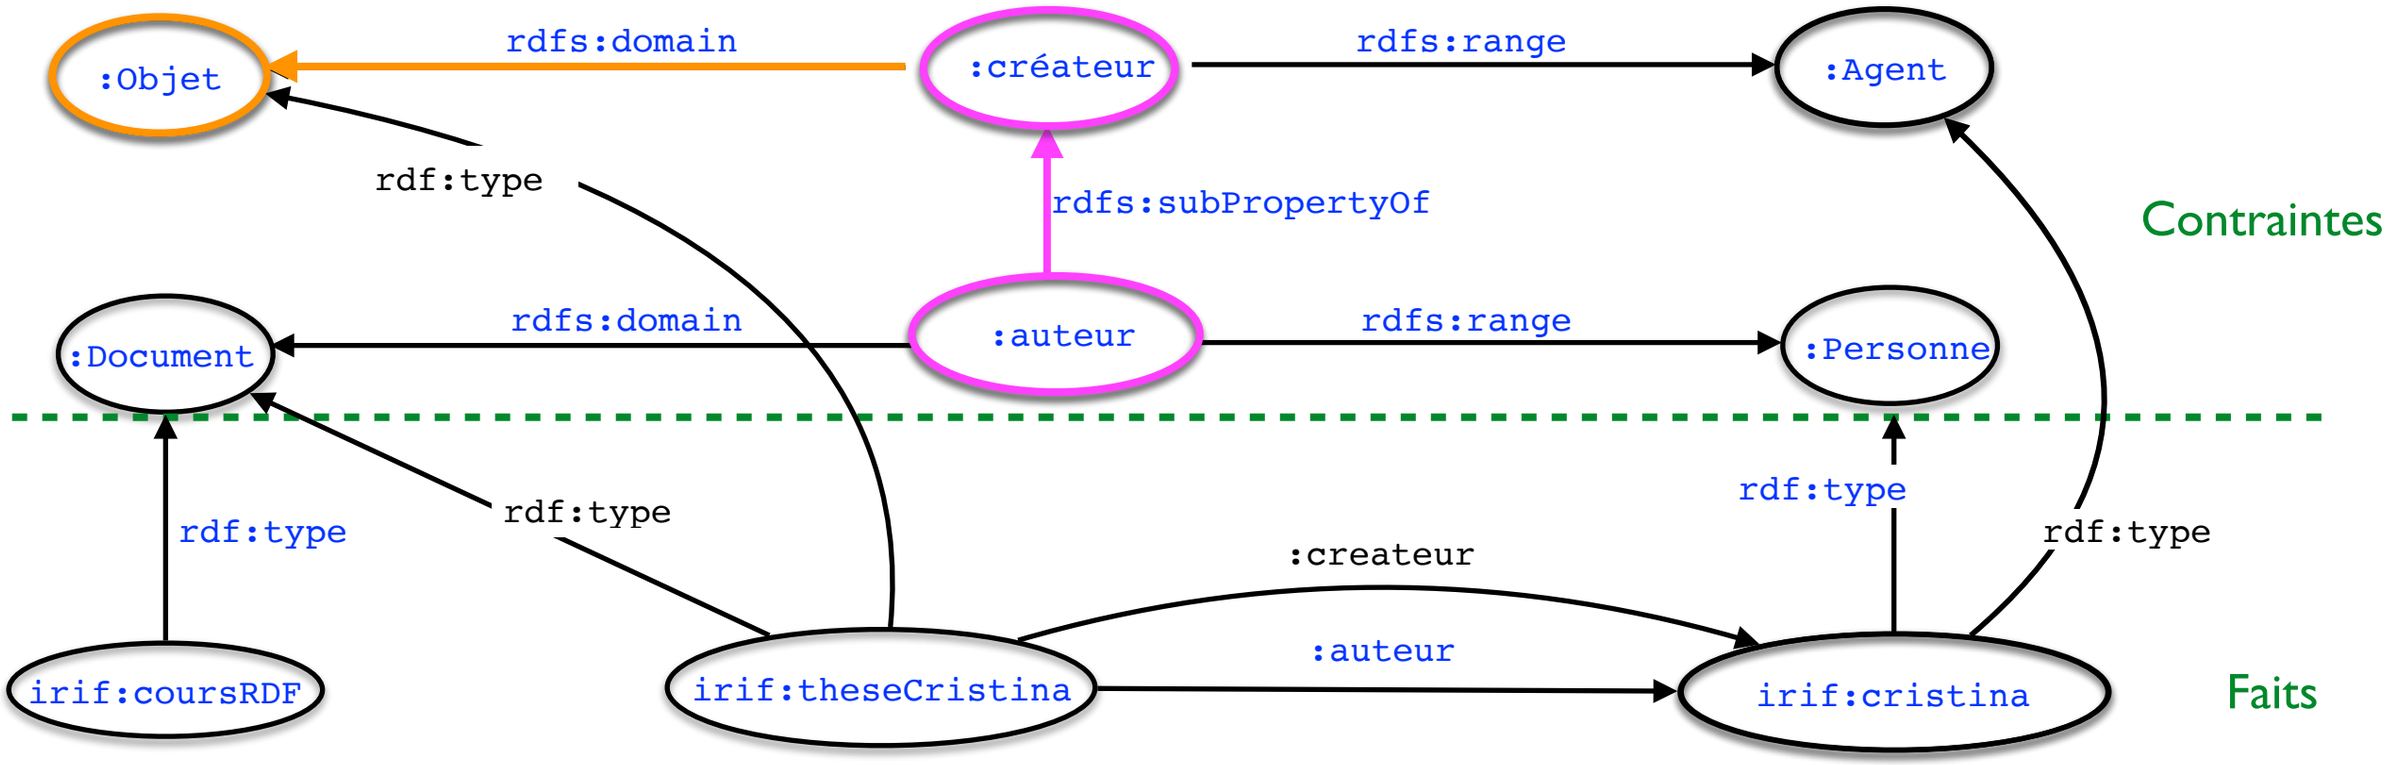


F:= A∪T ∪ { irif:theseCristina rdfs:type :Document, irif:theseCristina :createur irif:cristina, irif:theseCristina :rdf:type :Object, irif:theseCristina rdf:type :Agent }

5.

<:createur rdfs:domain :Object>
<:auteur rdfs:subPropertyOf :createur >
---
<:auteur rdfs:domain :Object>

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur, :createur}  C={ :Objet, :Document, :Agent, :Personne}

**En plus si sémantique extensionnelle**

F

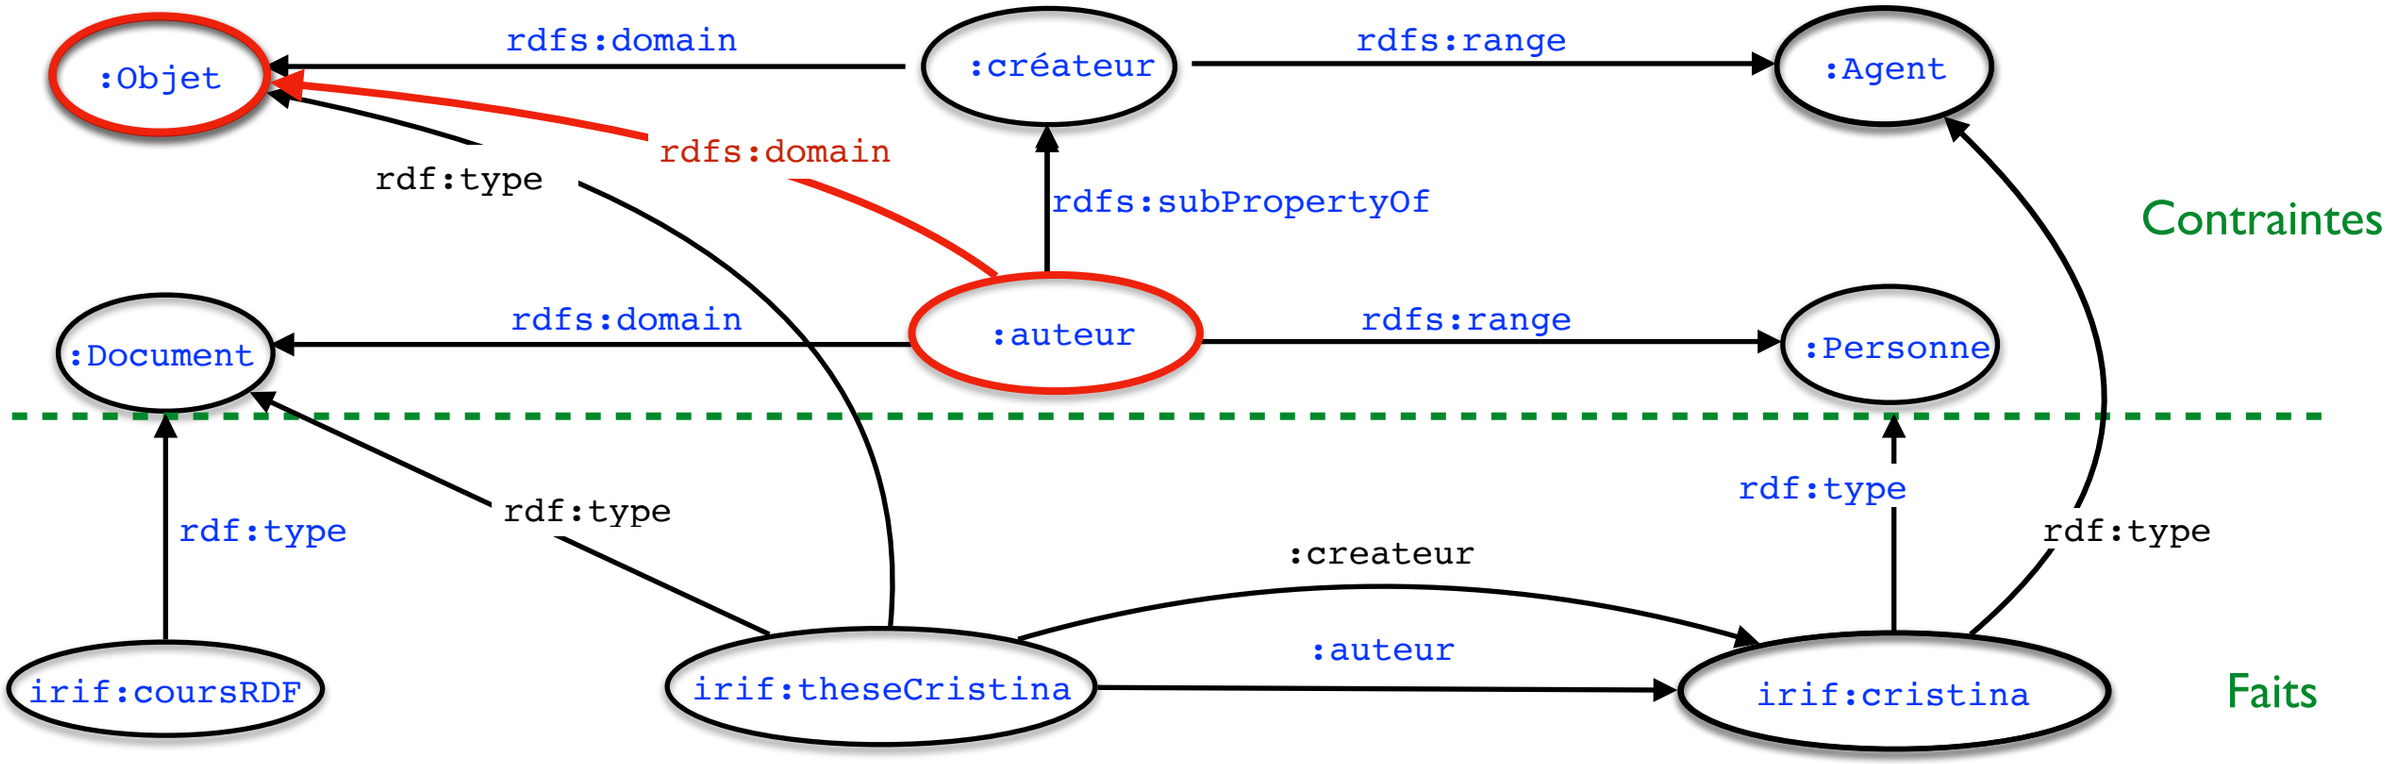


---

F:= AUT U { irif:theseCristina rdfs:type :Document, irif:theseCristina :createur irif:cristina, irif:theseCristina :rdf:type :Object, irif:theseCristina rdf:type :Agent, :auteur rdfs:domain :Object}

5.

<:createur rdfs:domain :Object>
<:auteur rdfs:subPropertyOf :createur >
---
<:auteur rdfs:domain :Object>

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur, :createur}  C={ :Objet, :Document, :Agent, :Personne}

**En plus si sémantique extensionnelle**

F

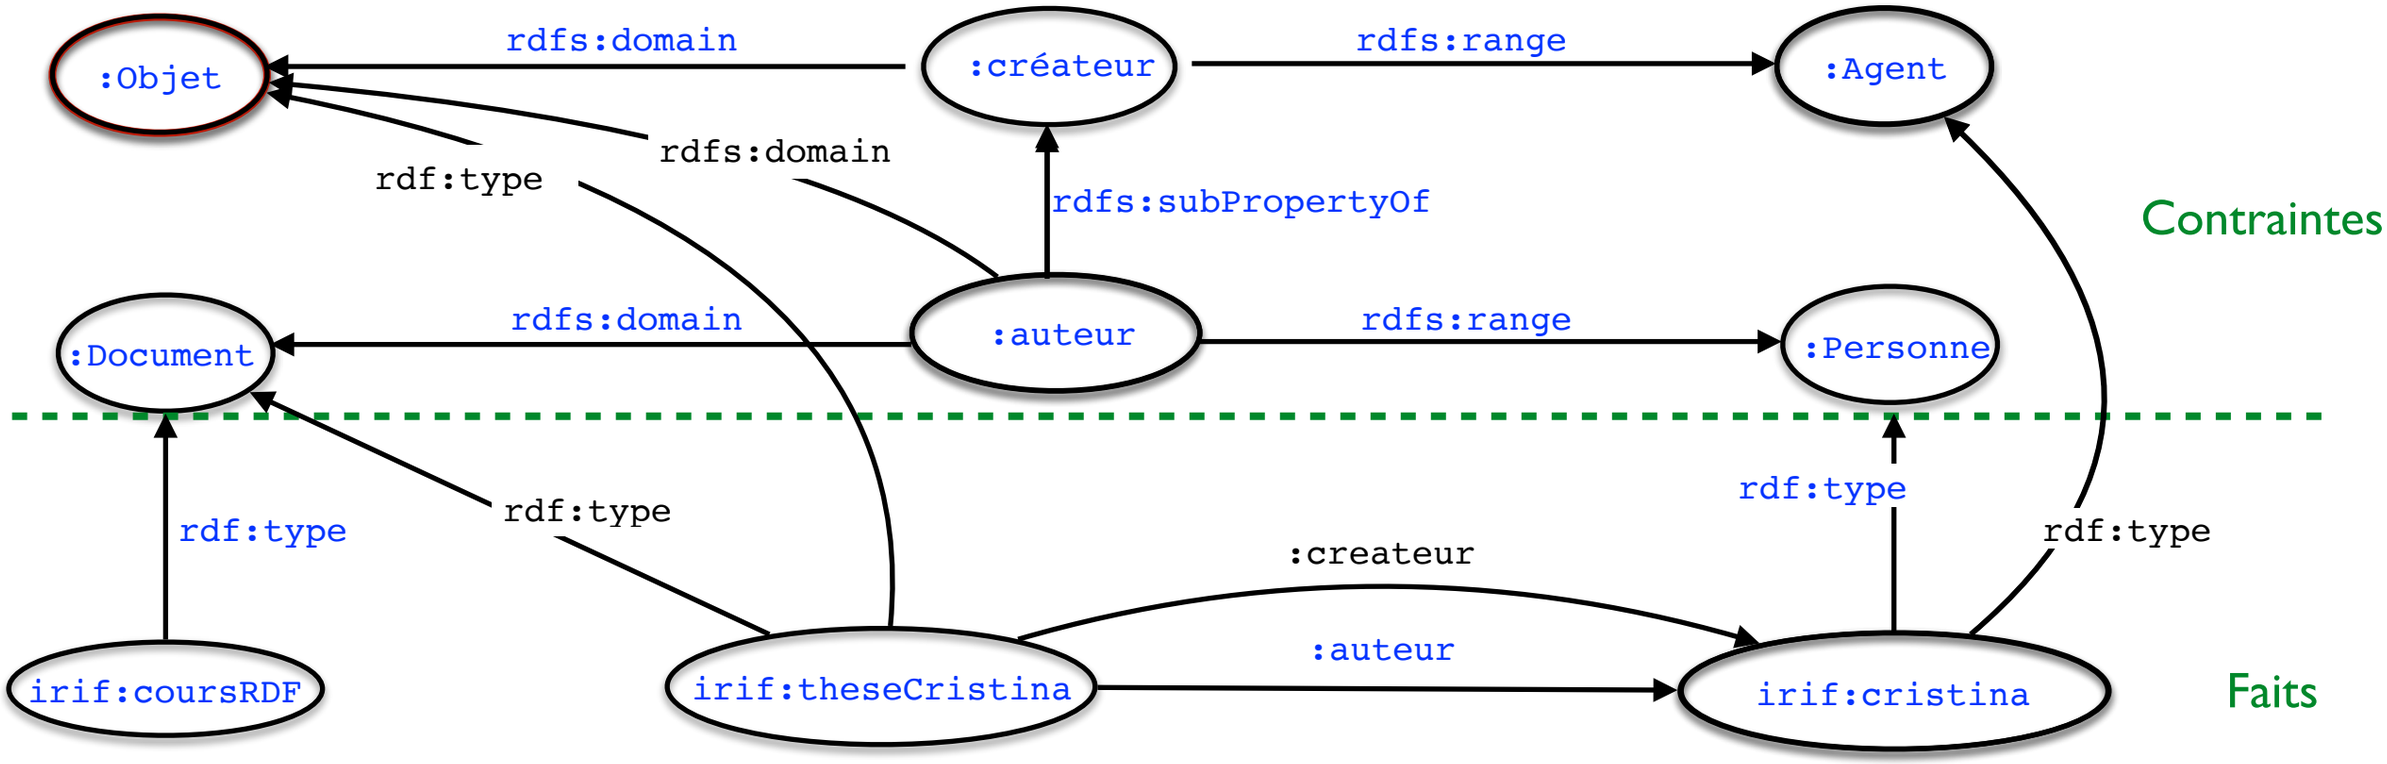


---

F:= AUT U { irif:theseCristina rdfs:type :Document, irif:theseCristina :createur irif:cristina, irif:theseCristina :rdf:type :Object, irif:theseCristina rdf:type :Agent, :auteur rdfs:domain :Object}

6.

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur, :createur}  C={ :Objet, :Document, :Agent, :Personne}

**En plus si sémantique extensionnelle**

F

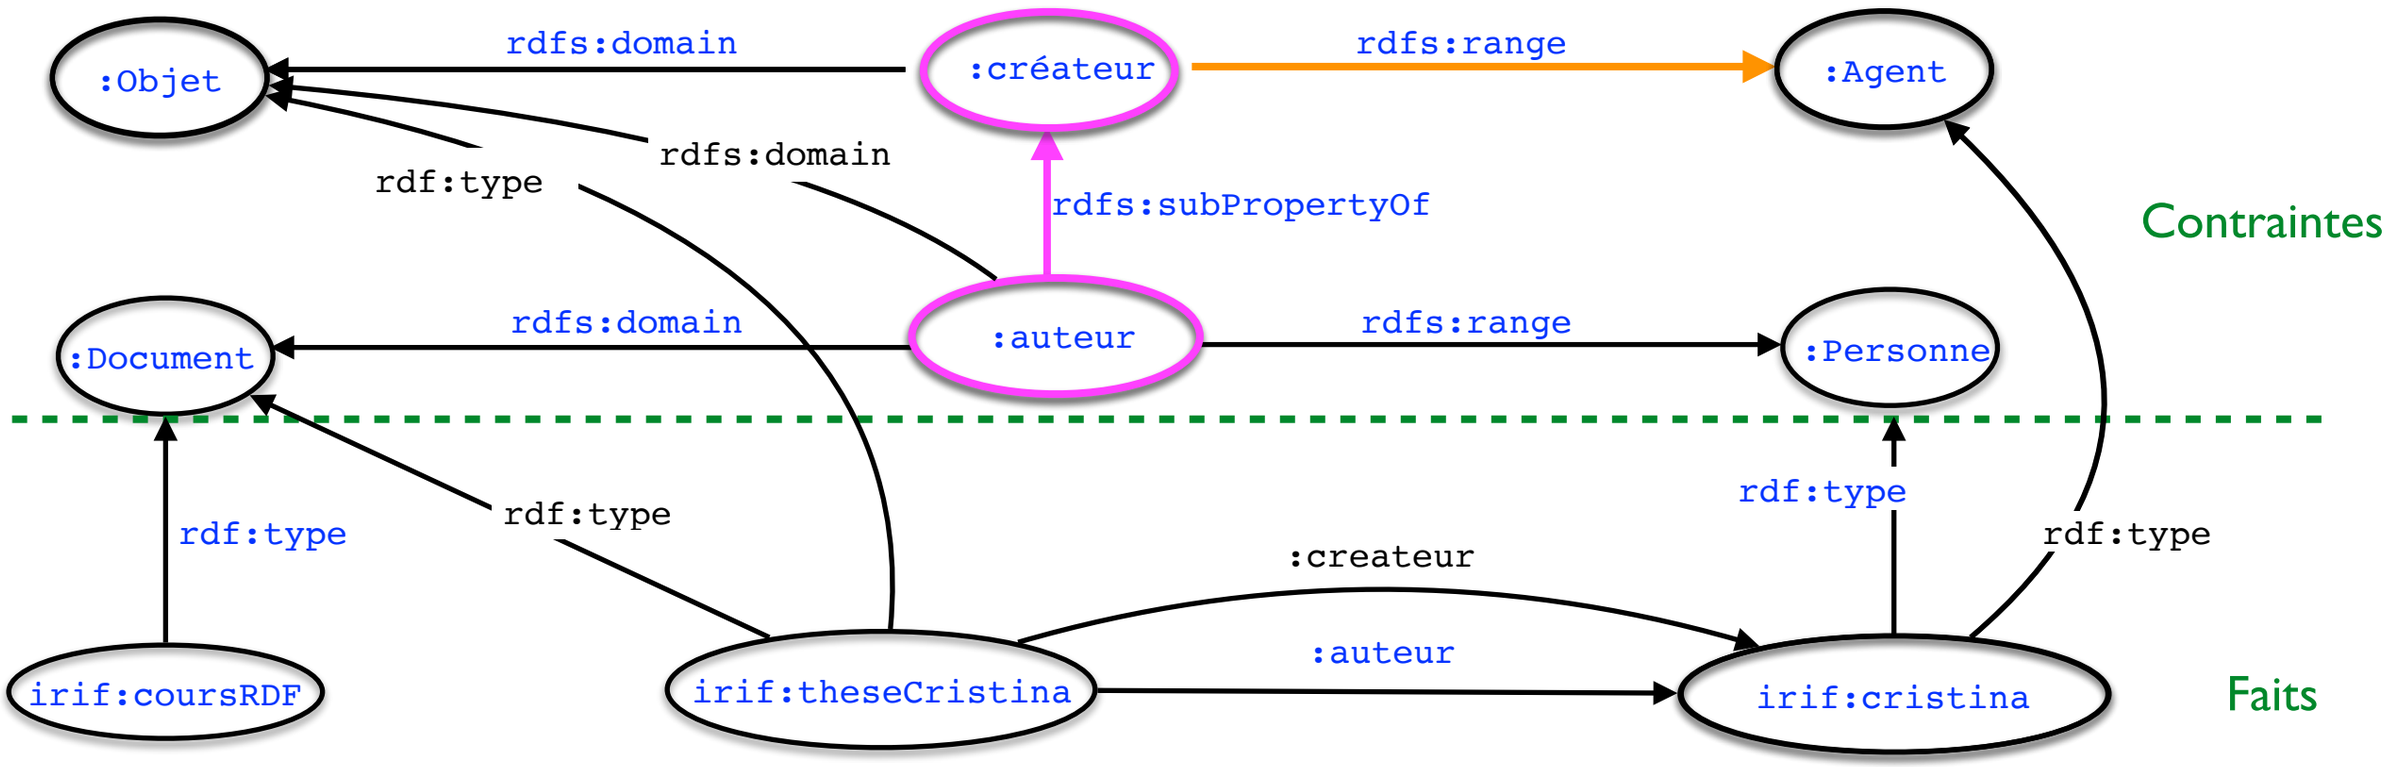


---

F:= A∪T ∪ { irif:theseCristina rdfs:type :Document, irif:theseCristina :createur irif:cristina, irif:theseCristina :rdf:type :Object, irif:theseCristina rdf:type :Agent, :auteur rdfs:domain :Object}

6.

<:createur rdfs:range :Agent>
<:auteur rdfs:subPropertyOf :createur >

---

<:auteur rdfs:range :Agent>

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur, :createur}  C={ :Objet, :Document, :Agent, :Personne}

**En plus si sémantique extensionnelle**

F

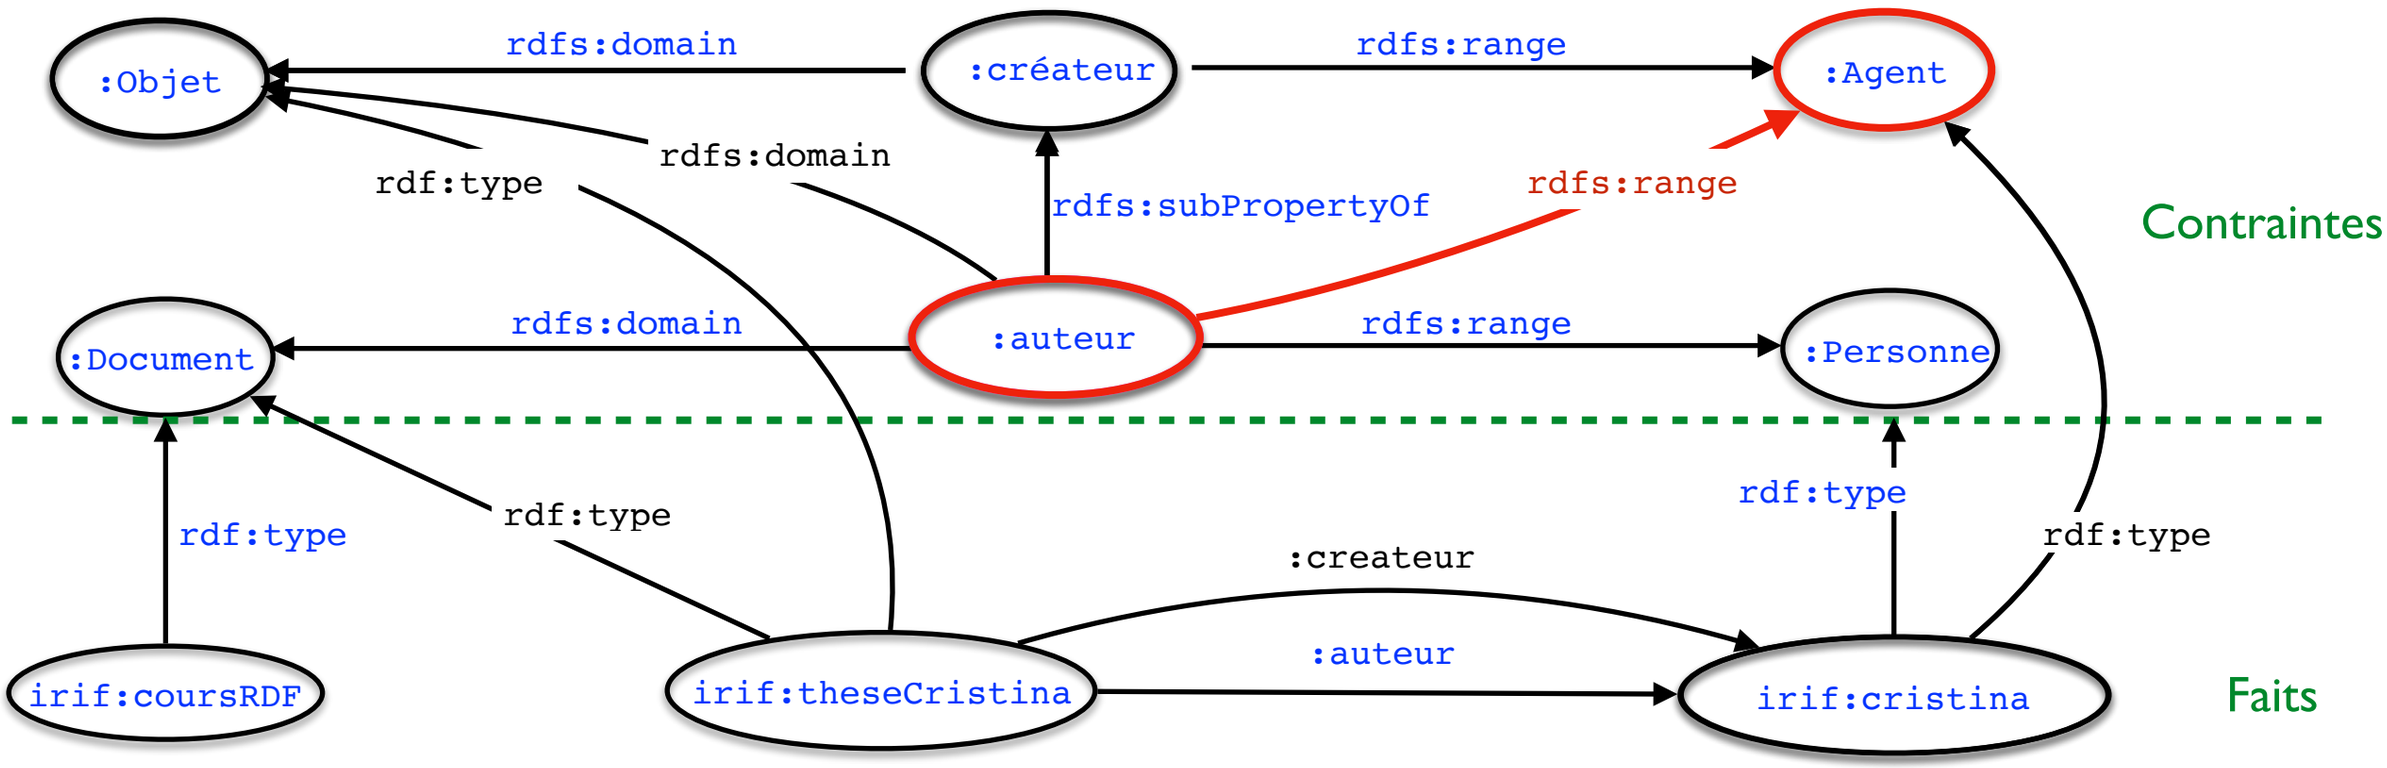


F:= AUT U { irif:theseCristina rdfs:type :Document, irif:theseCristina :createur irif:cristina, irif:theseCristina :rdf:type :Object, irif:theseCristina rdf:type :Agent, :auteur rdfs:domain :Object, :auteur rdfs:range :Agent}

5.

<:createur rdfs:range :Agent>
<:auteur rdfs:subPropertyOf :createur >

---

<:auteur rdfs:range :Agent>

# Exemple : algorithme de saturation pour les faits et les contraintes

- P ={ :auteur, :createur}  C={ :Objet, :Document, :Agent, :Personne}

F

**En plus si sémantique extensionnelle**

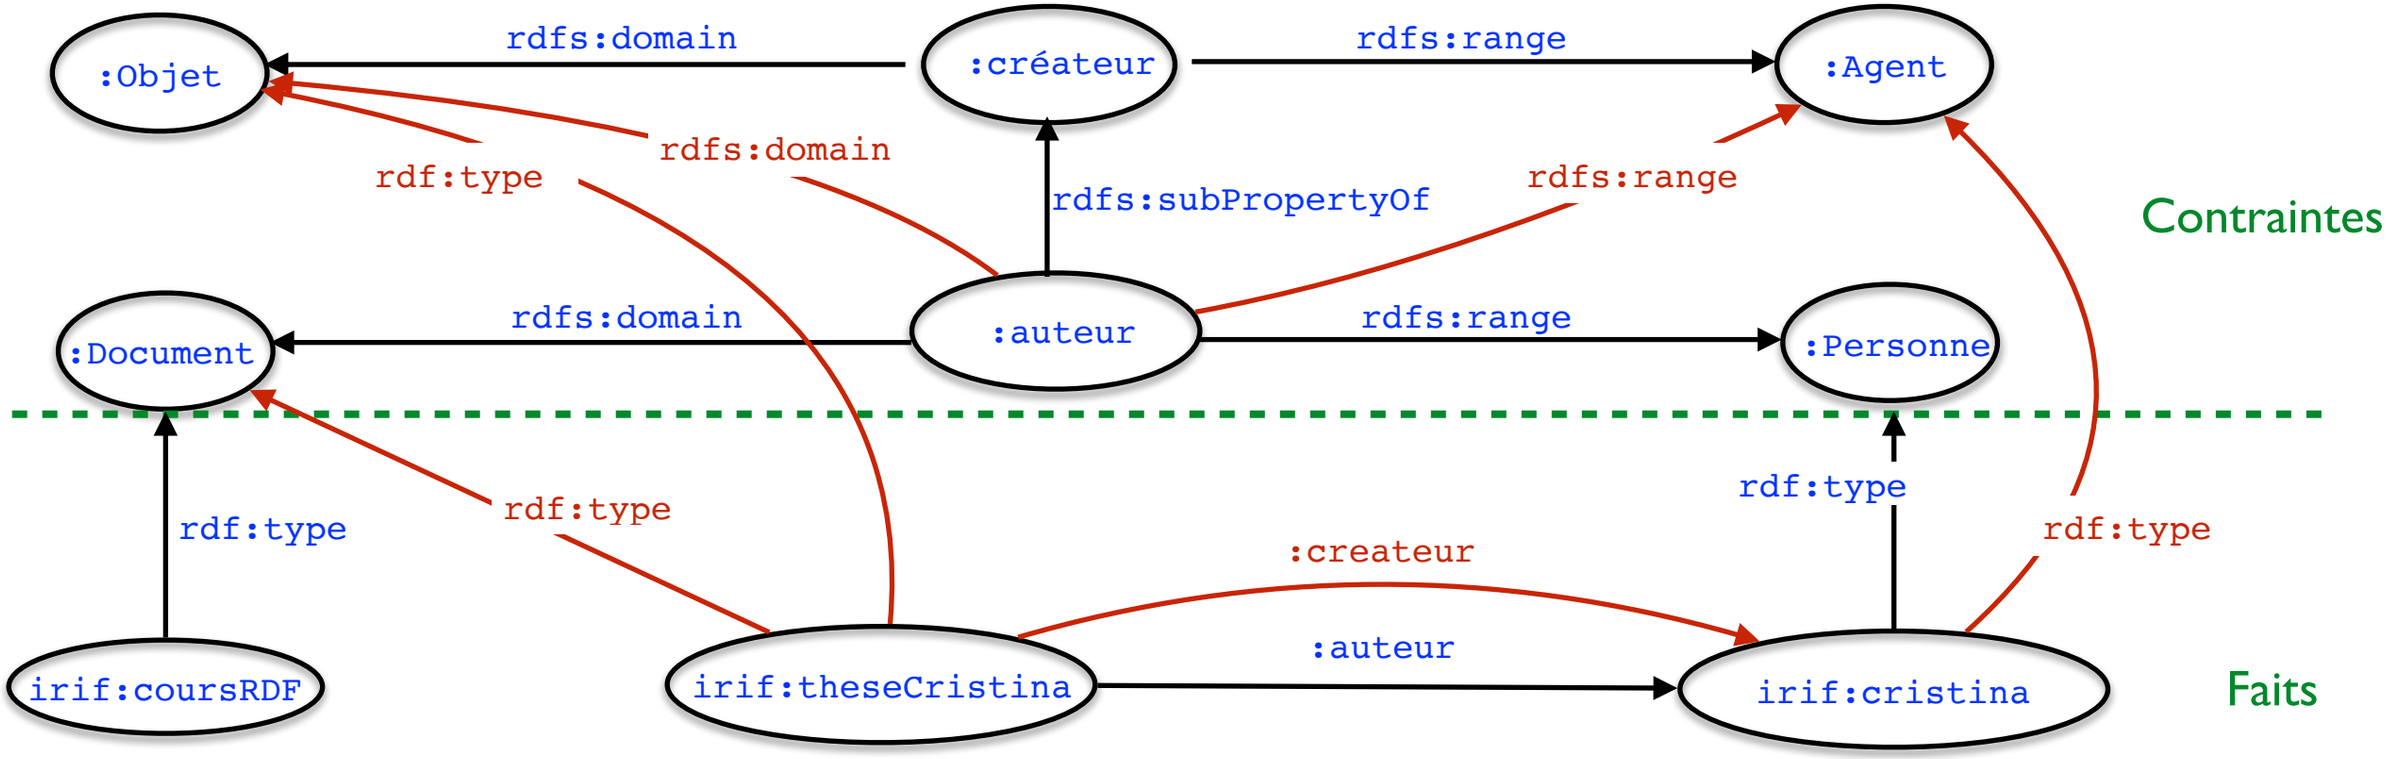


Plus aucune règles n'est applicable. **Saturation terminée. On a dérivé en F toutes les conséquences** (de type fait ou contrainte)

(remarque : à la fois des règle de $\Gamma_A$ et de $\Gamma_T$ étaient applicables, donc on a dérivé à la fois de nouveaux faits et de nouvelles contraintes (en rouge))

(on fait omission des triplets réflexifs)

# Un autre exemple : saturation des faits et des contraintes

- K

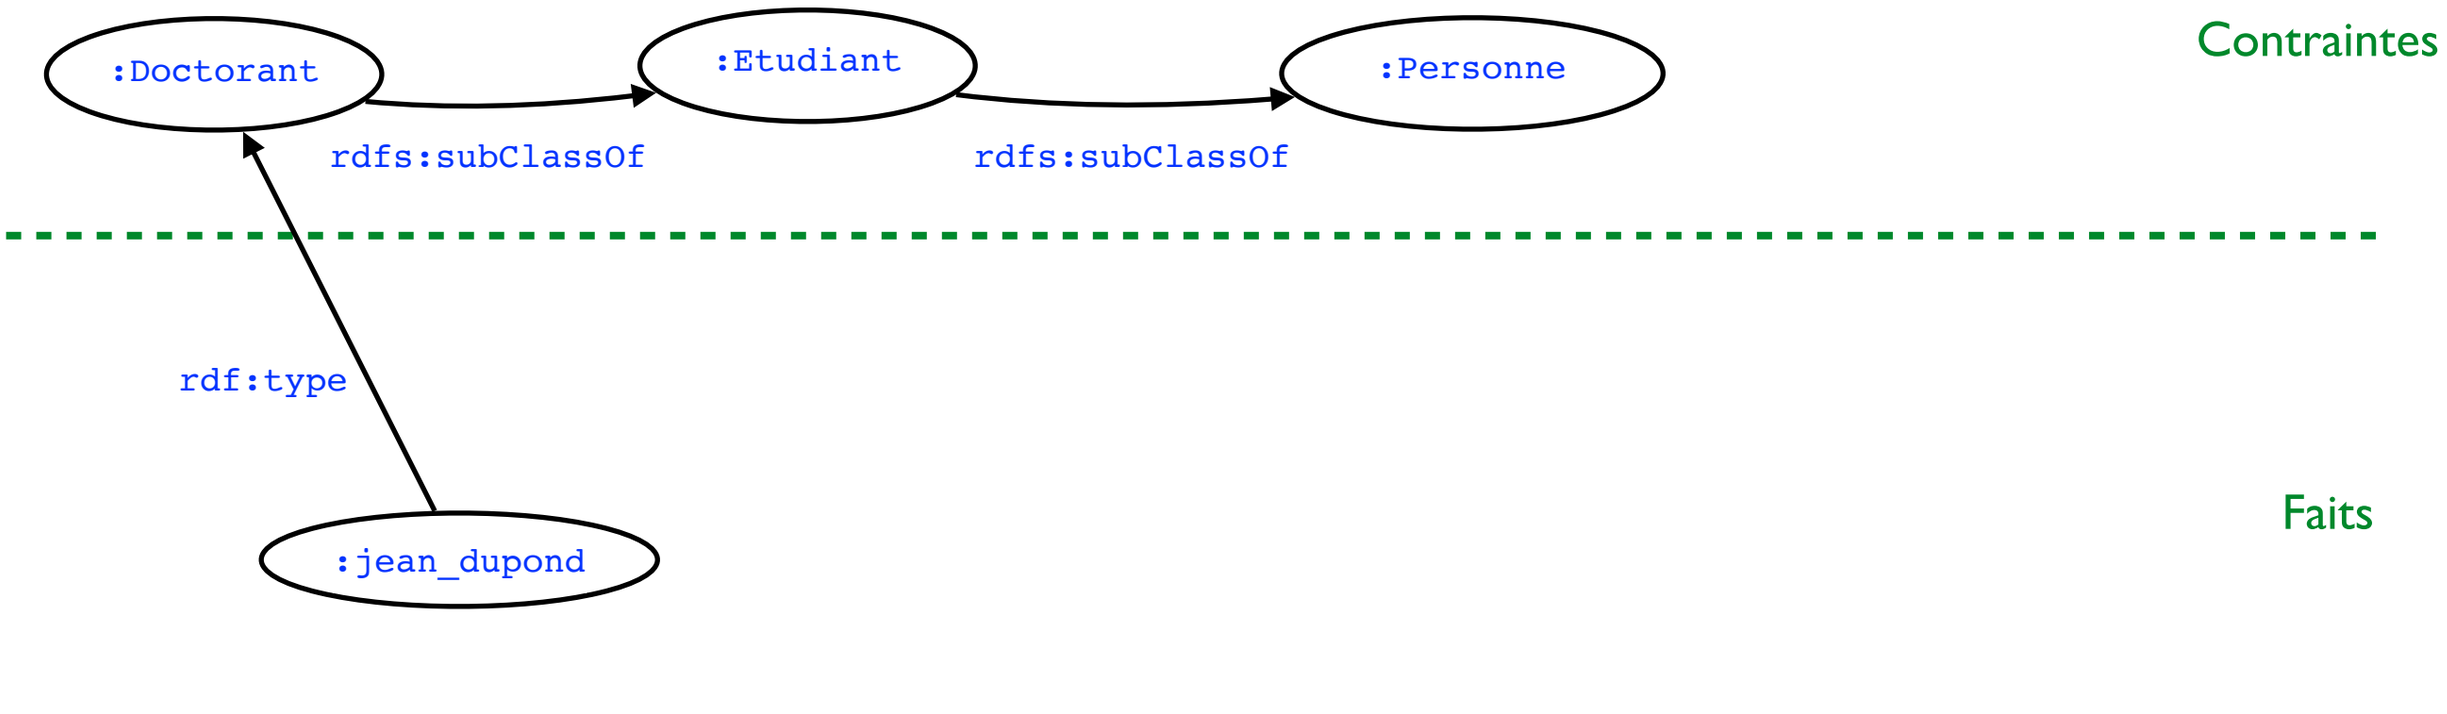

# Un autre exemple : saturation des faits et des contraintes

- K

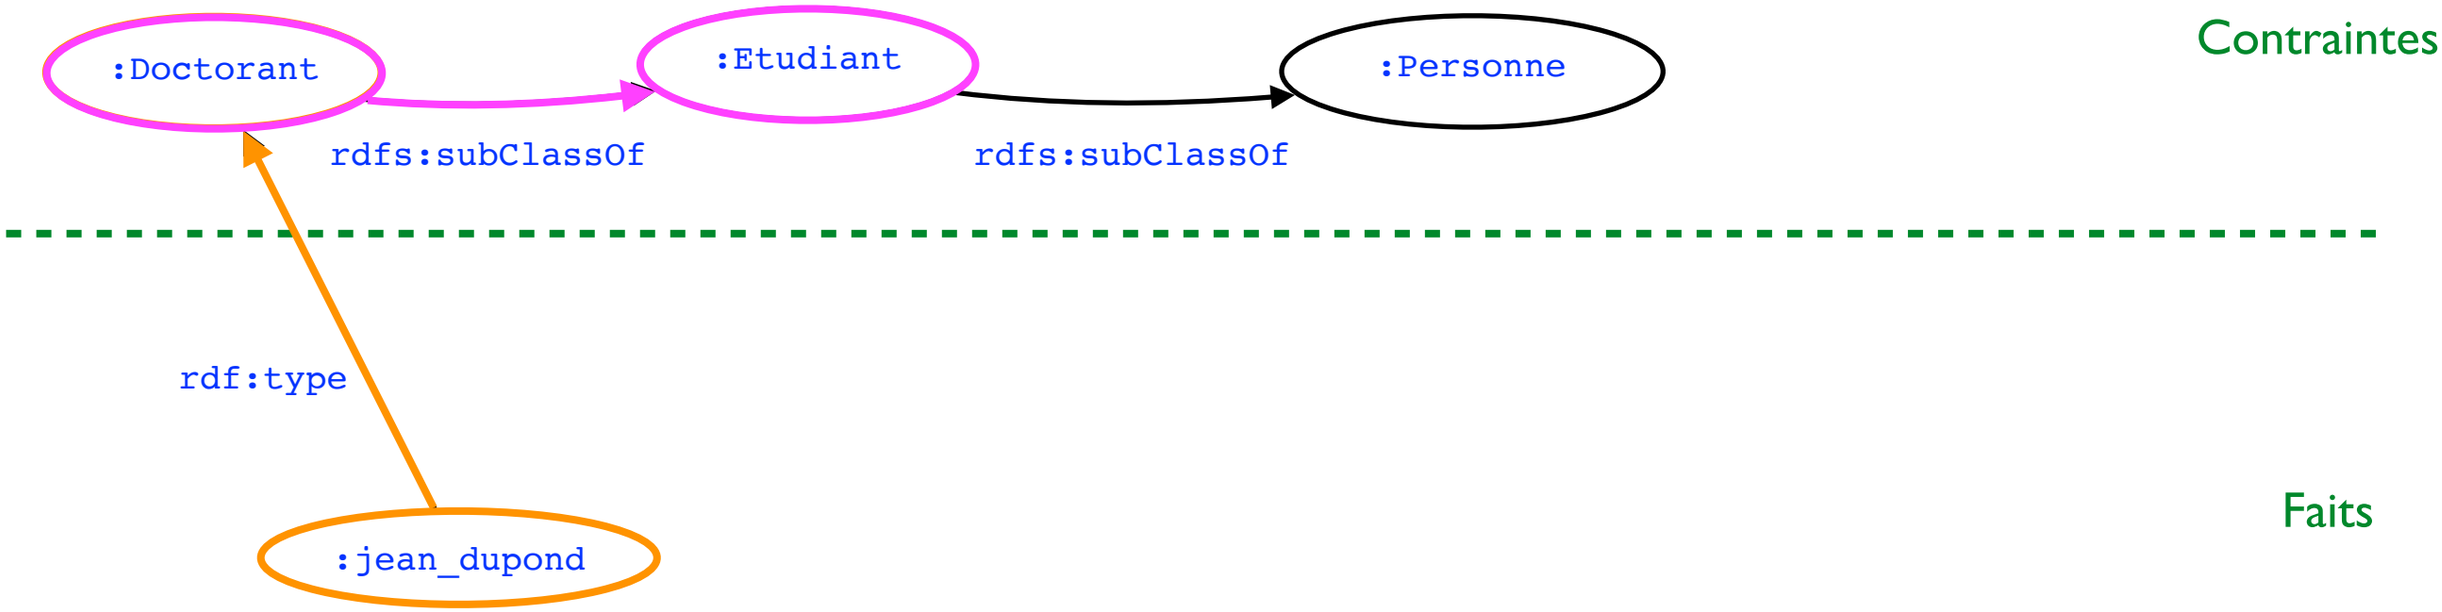


```
<:jean_dupond rdf:type :Doctorant>
<:Doctorant rdfs:subClassOf :Etudiant >
_____________________
<:jean_dupond rdf:type :Etudiant>
```

# Un autre exemple : saturation des faits et des contraintes

- F

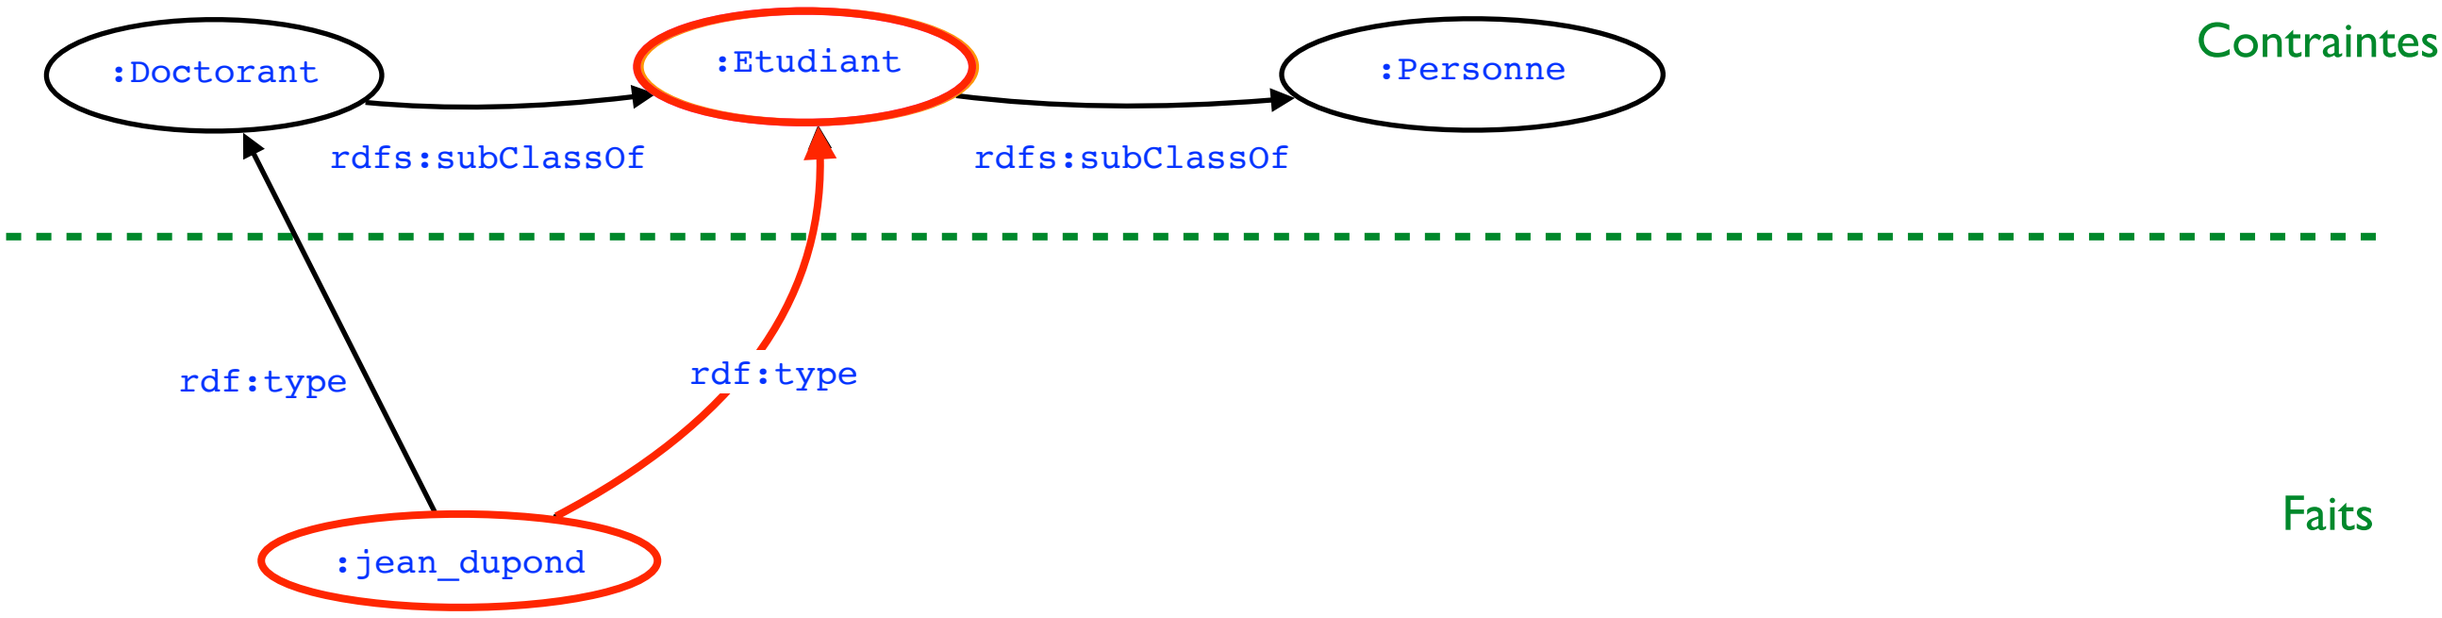


```
<:jean_dupond rdf:type :Doctorant>
<:Doctorant rdfs:subClassOf :Etudiant >
_____________________
<:jean_dupond rdf:type :Etudiant>
```

# Un autre exemple : saturation des faits et des contraintes

- F

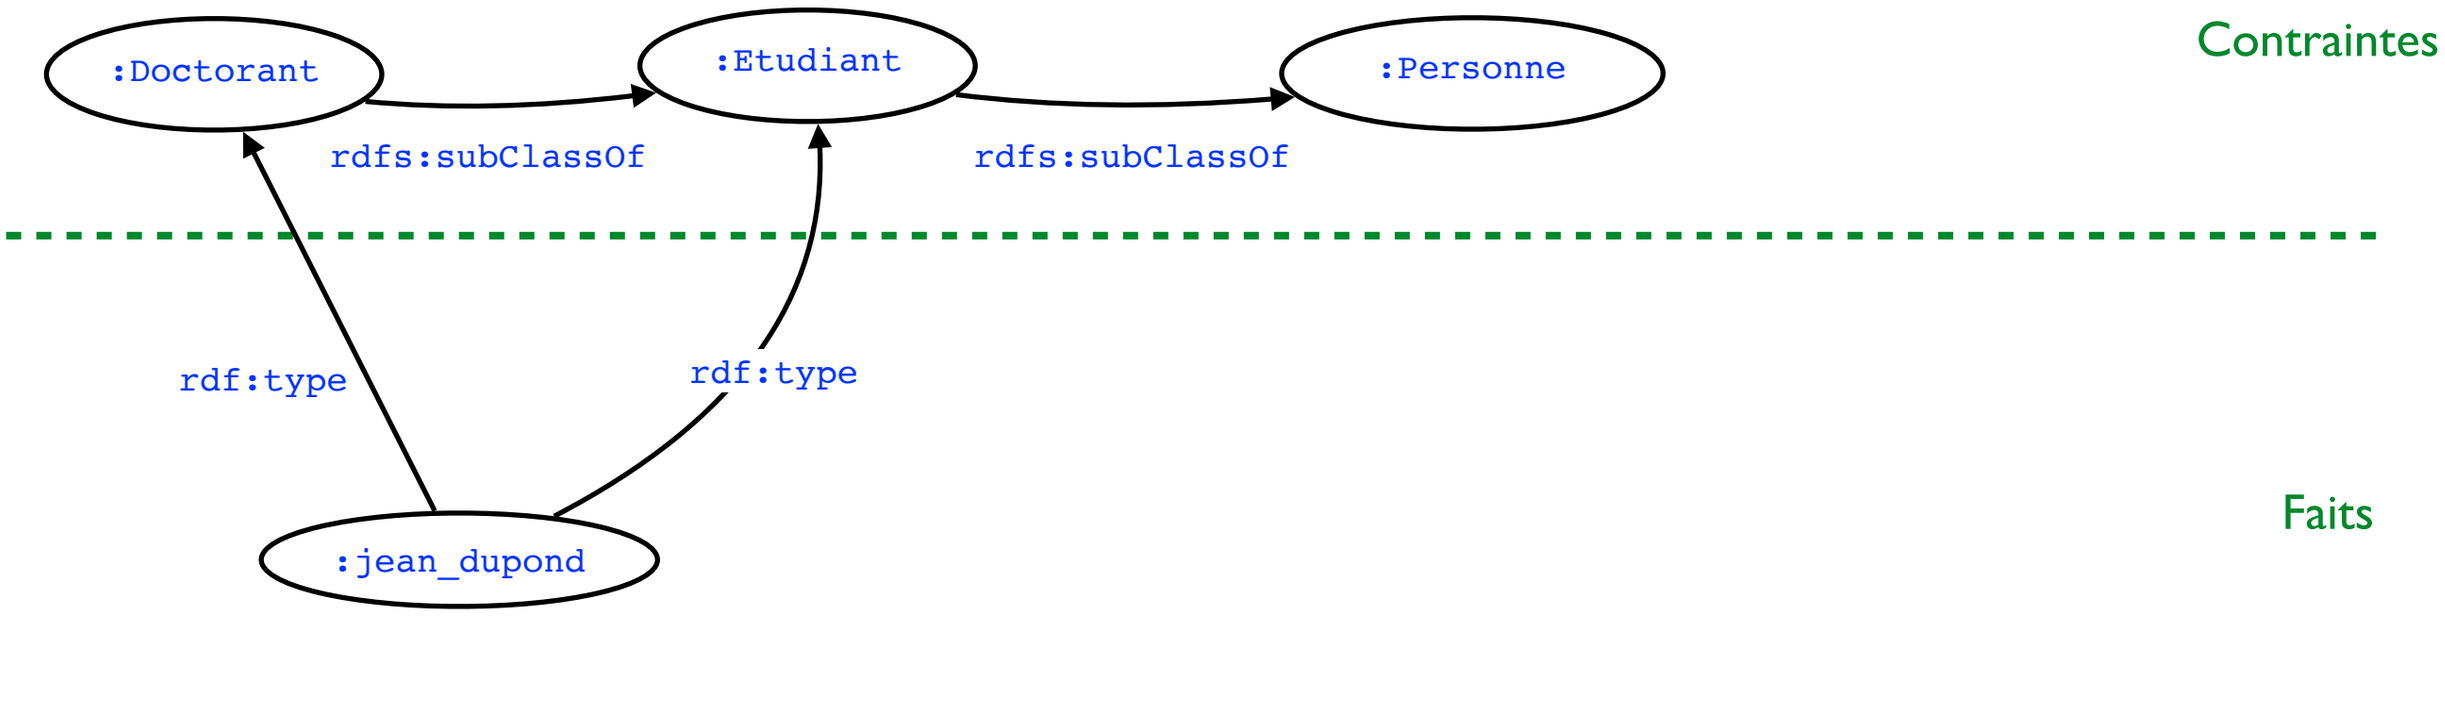

# Un autre exemple : saturation des faits et des contraintes

- F

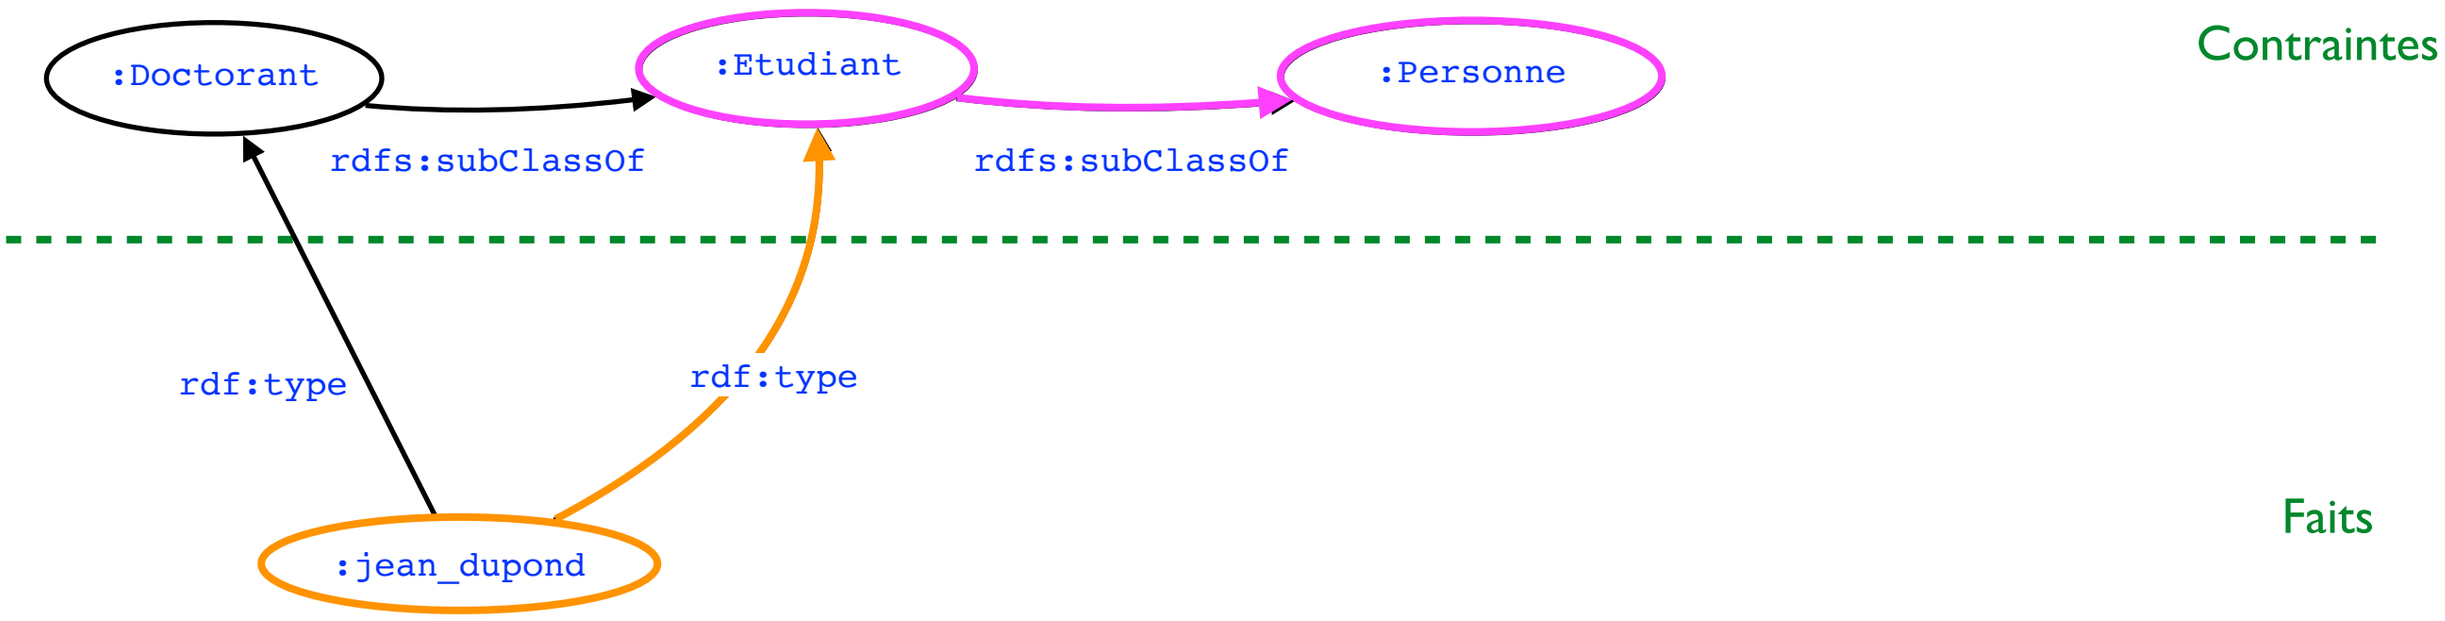


```
<:jean_dupond rdf:type :Etudiant>
<:Etudiant rdfs:subClassOf :Personne >
_____________________
<:jean_dupond rdf:type :Personne>
```

# Un autre exemple : saturation des faits et des contraintes

- F

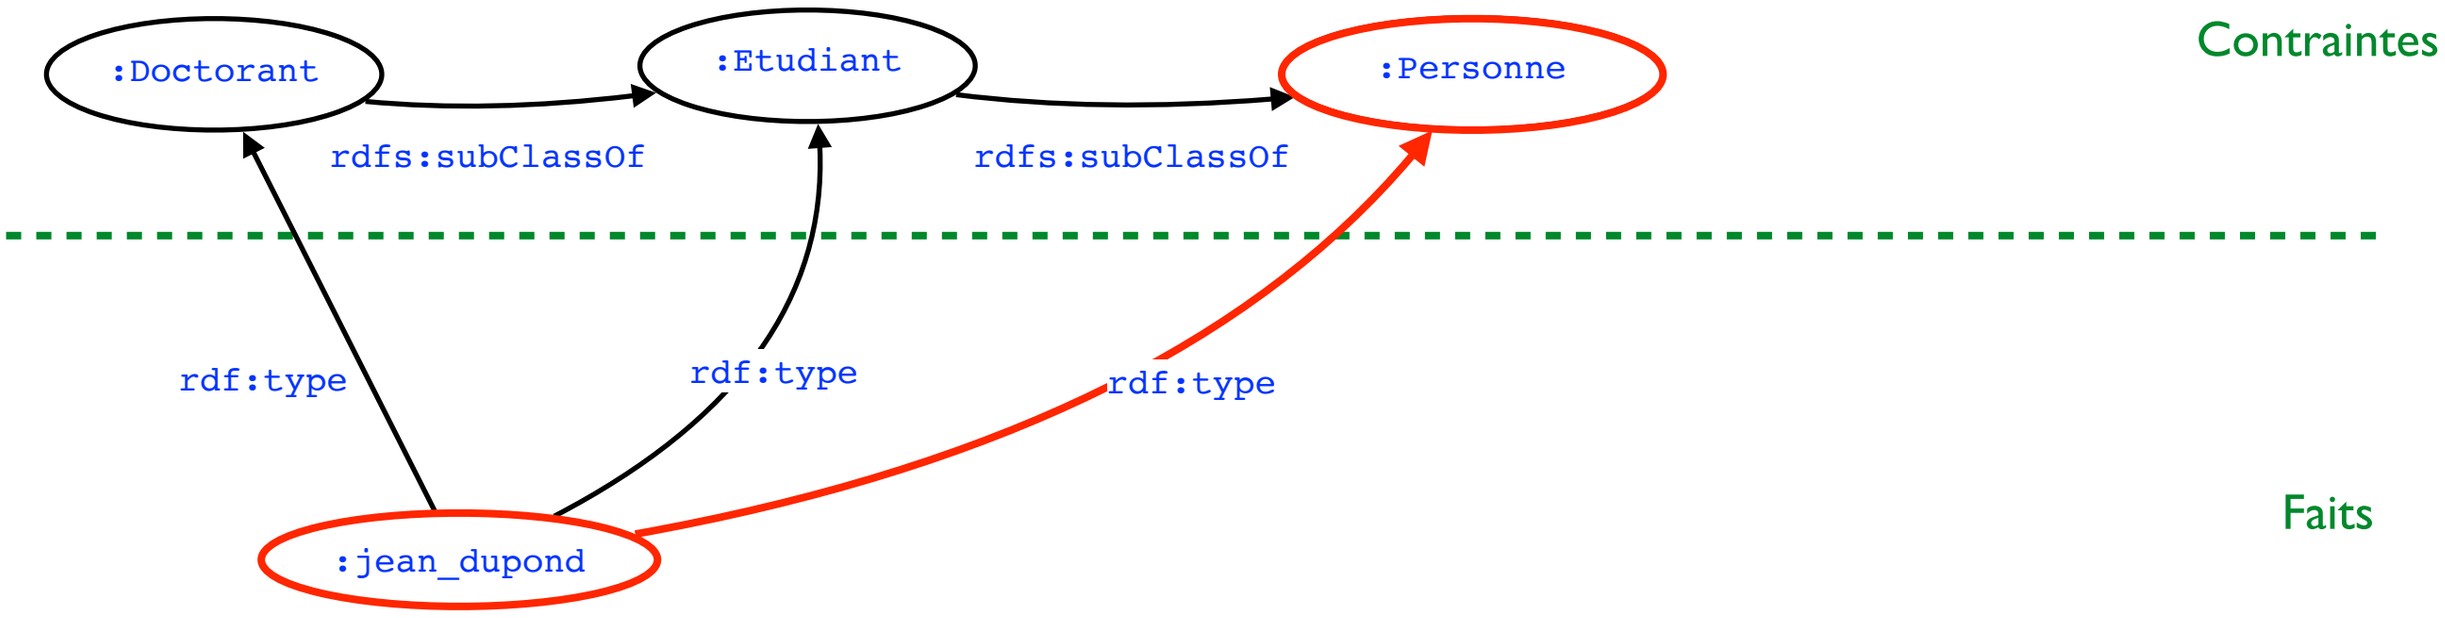


```
<:jean_dupond rdf:type :Etudiant>
<:Etudiant rdfs:subClassOf :Personne >
_____________________
<:jean_dupond rdf:type :Personne>
```

# Un autre exemple : saturation des faits et des contraintes

- F

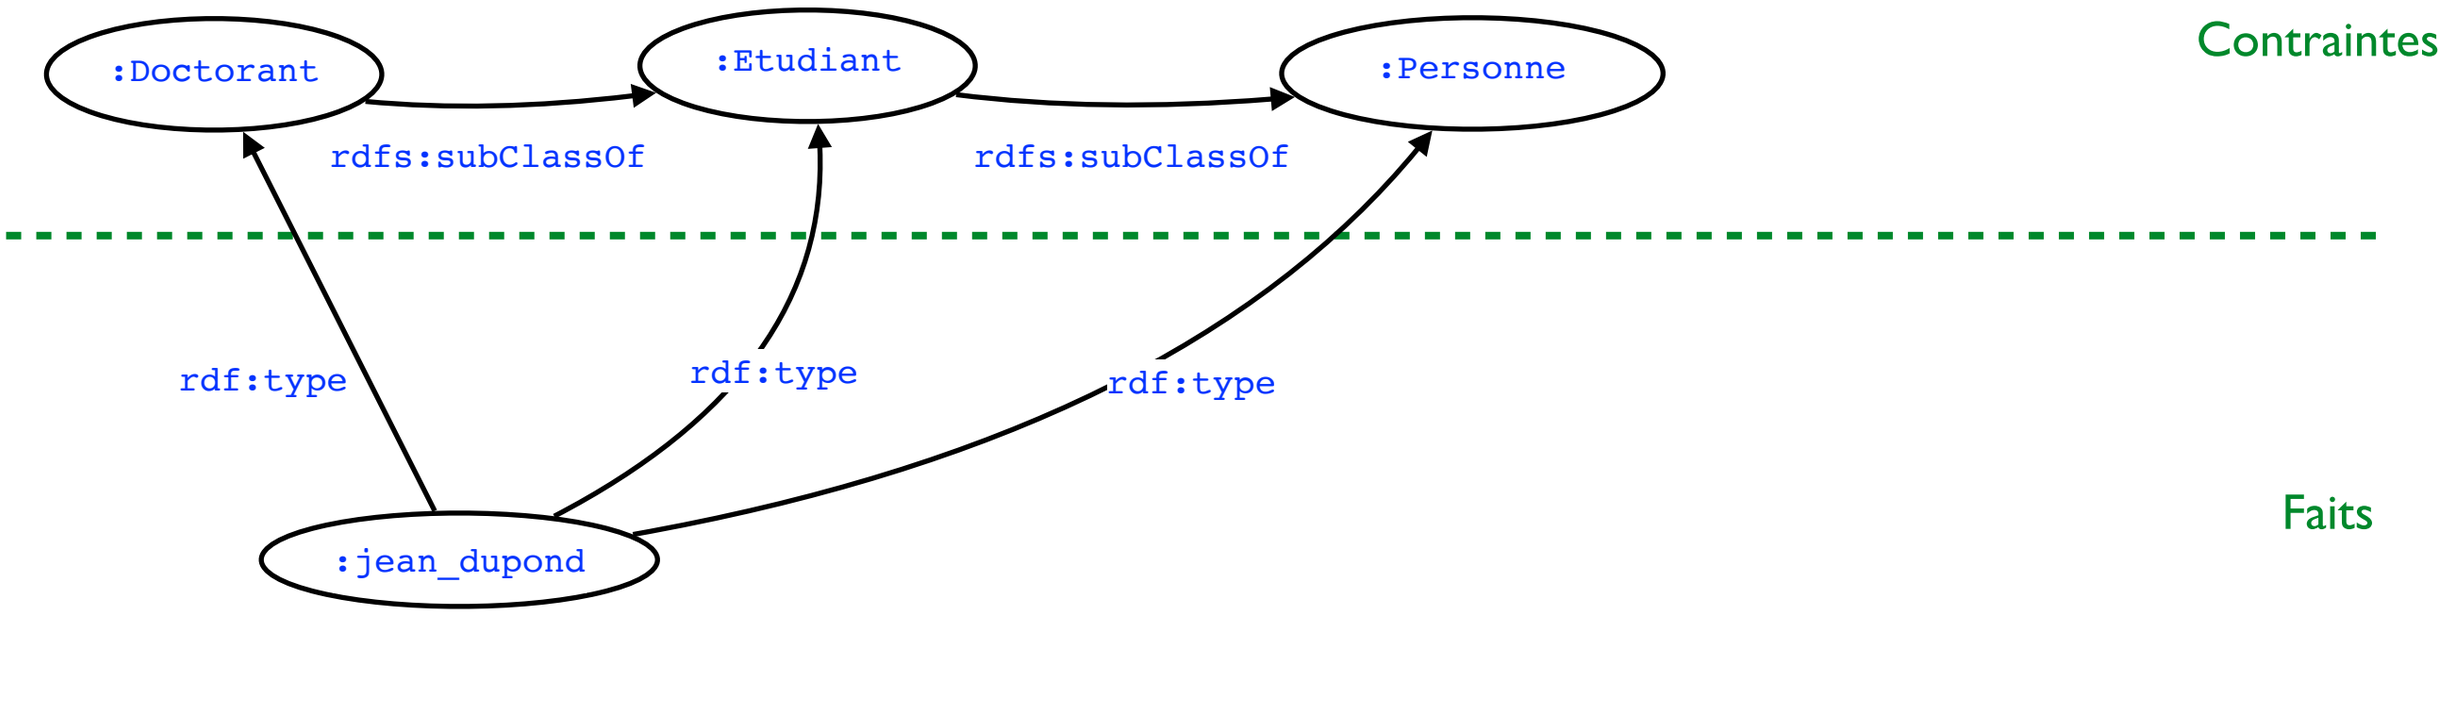

# Un autre exemple : saturation des faits et des contraintes

- F

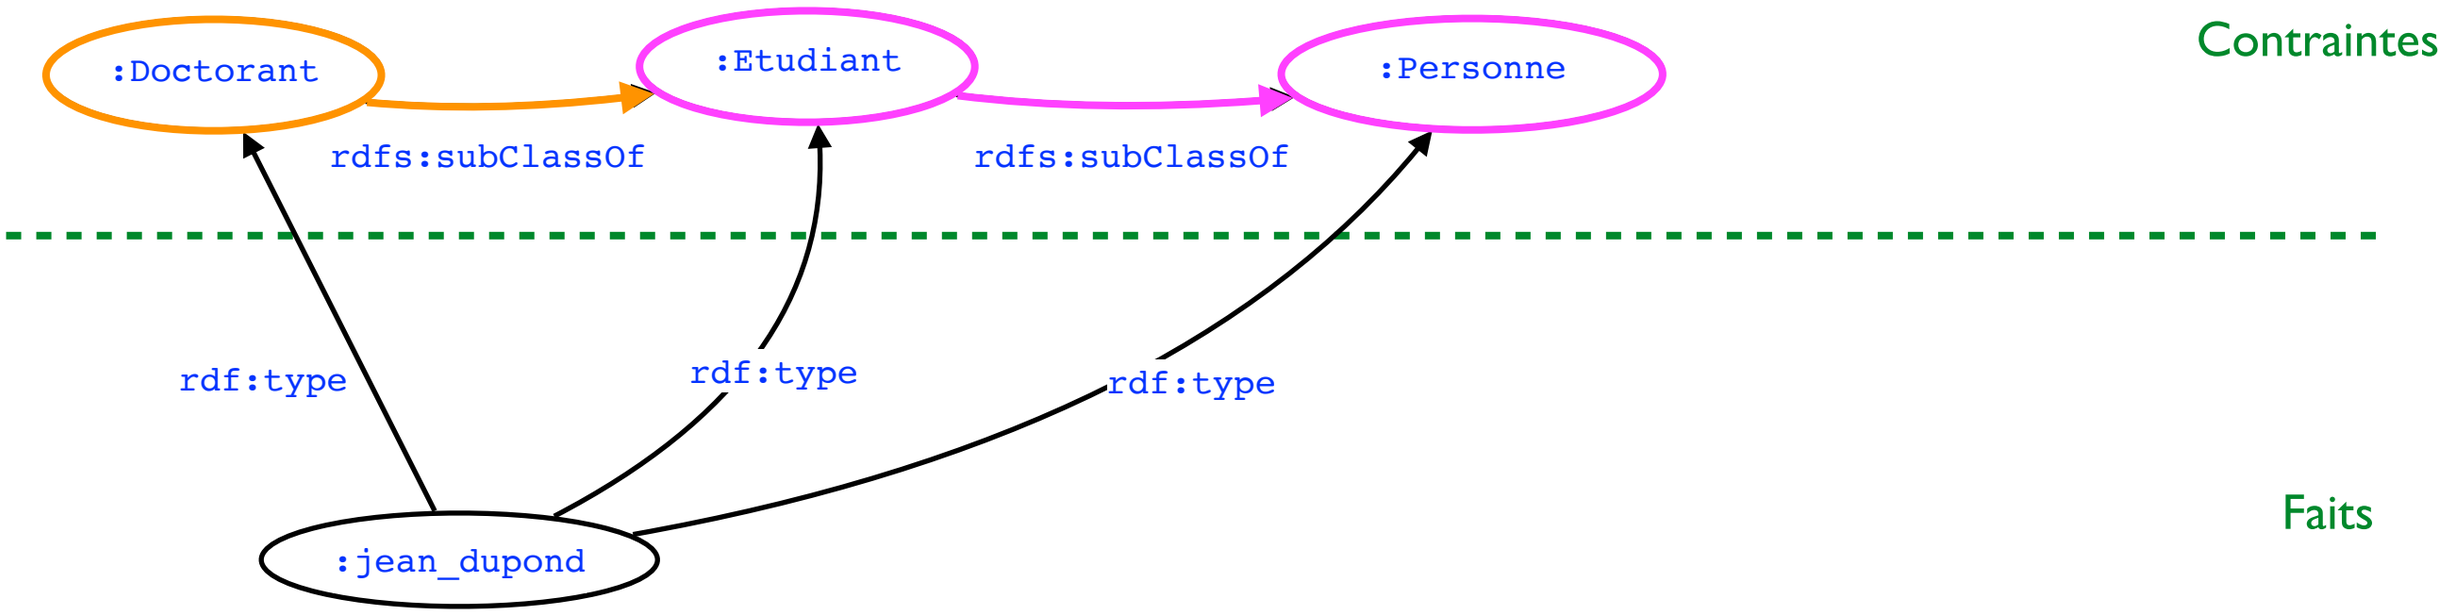


```
<:Doctorant rdfs:subClassOf :Etudiant>
<:Etudiant rdfs:subClassOf :Personne >
_____________________
<:Doctorant rdfs:subClassOf :Personne>
```

# Un autre exemple : saturation des faits et des contraintes

- F

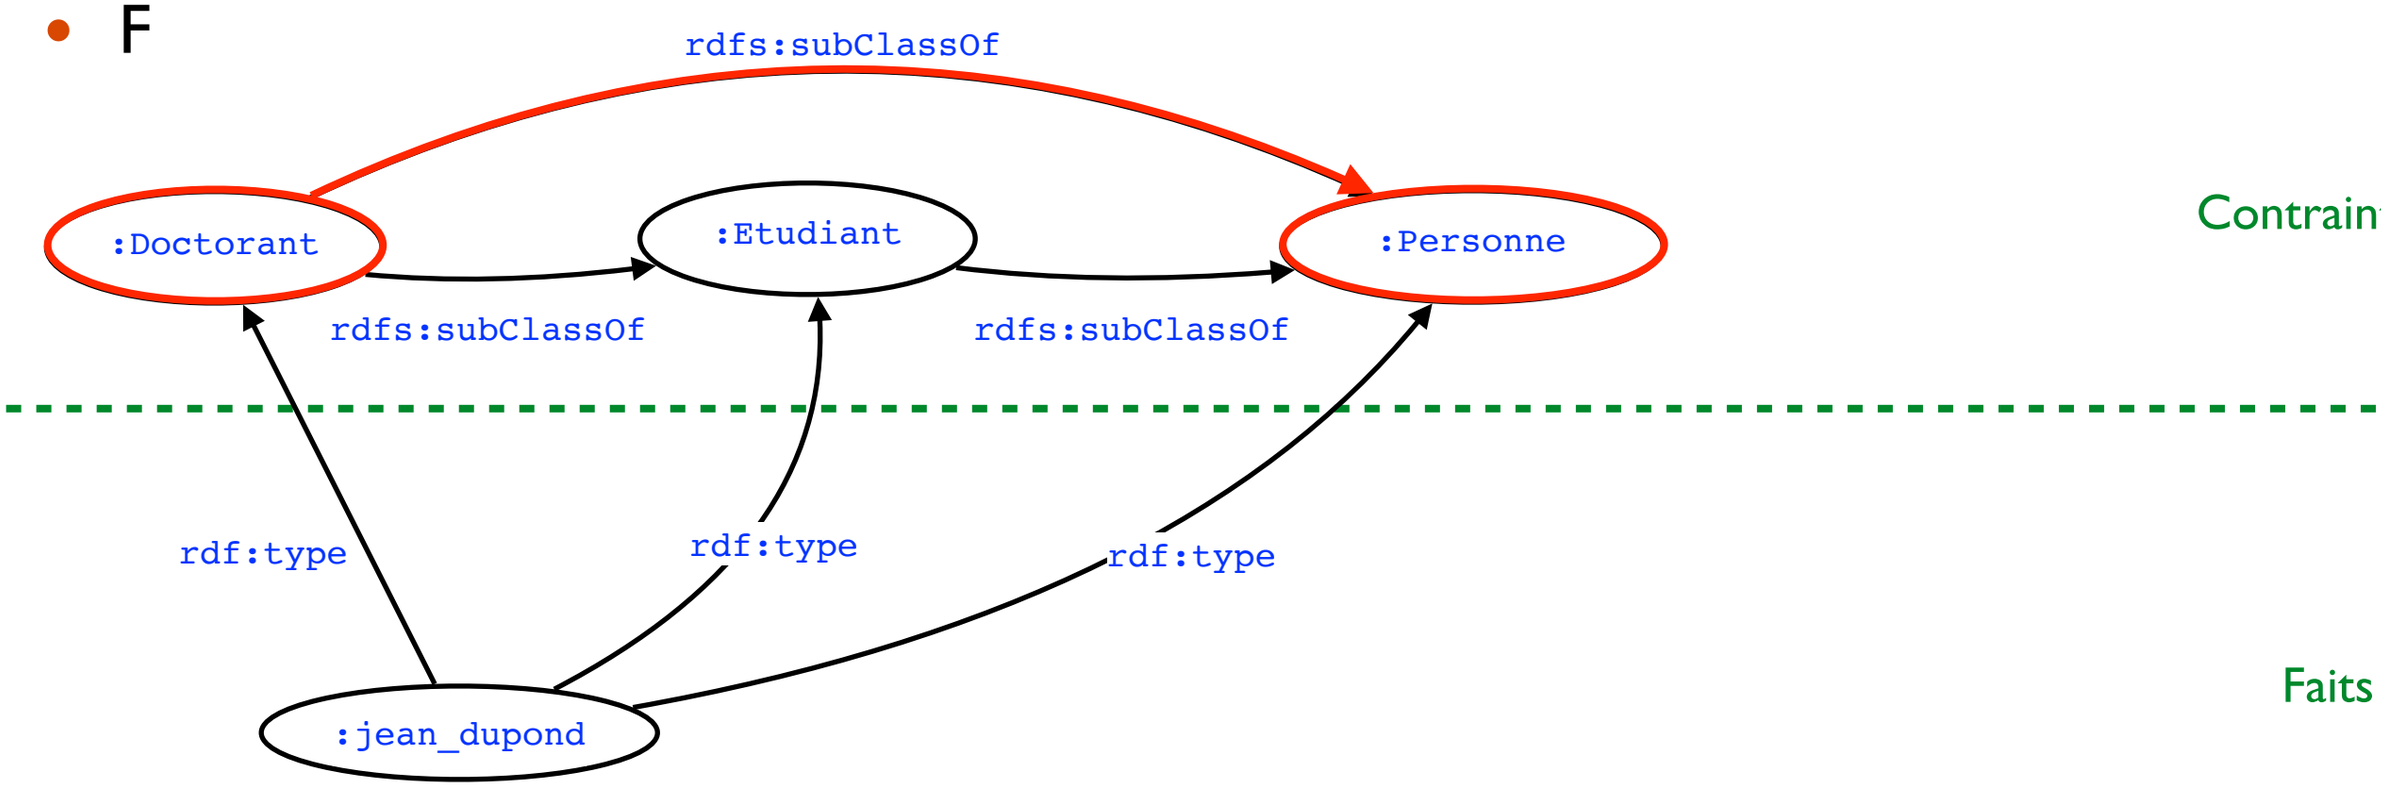


<:Doctorant rdfs:subClassOf :Etudiant>
<:Etudiant rdfs:subClassOf :Personne >

<:Doctorant rdfs:subClassOf :Personne>

# Un autre exemple : saturation des faits et des contraintes

- F

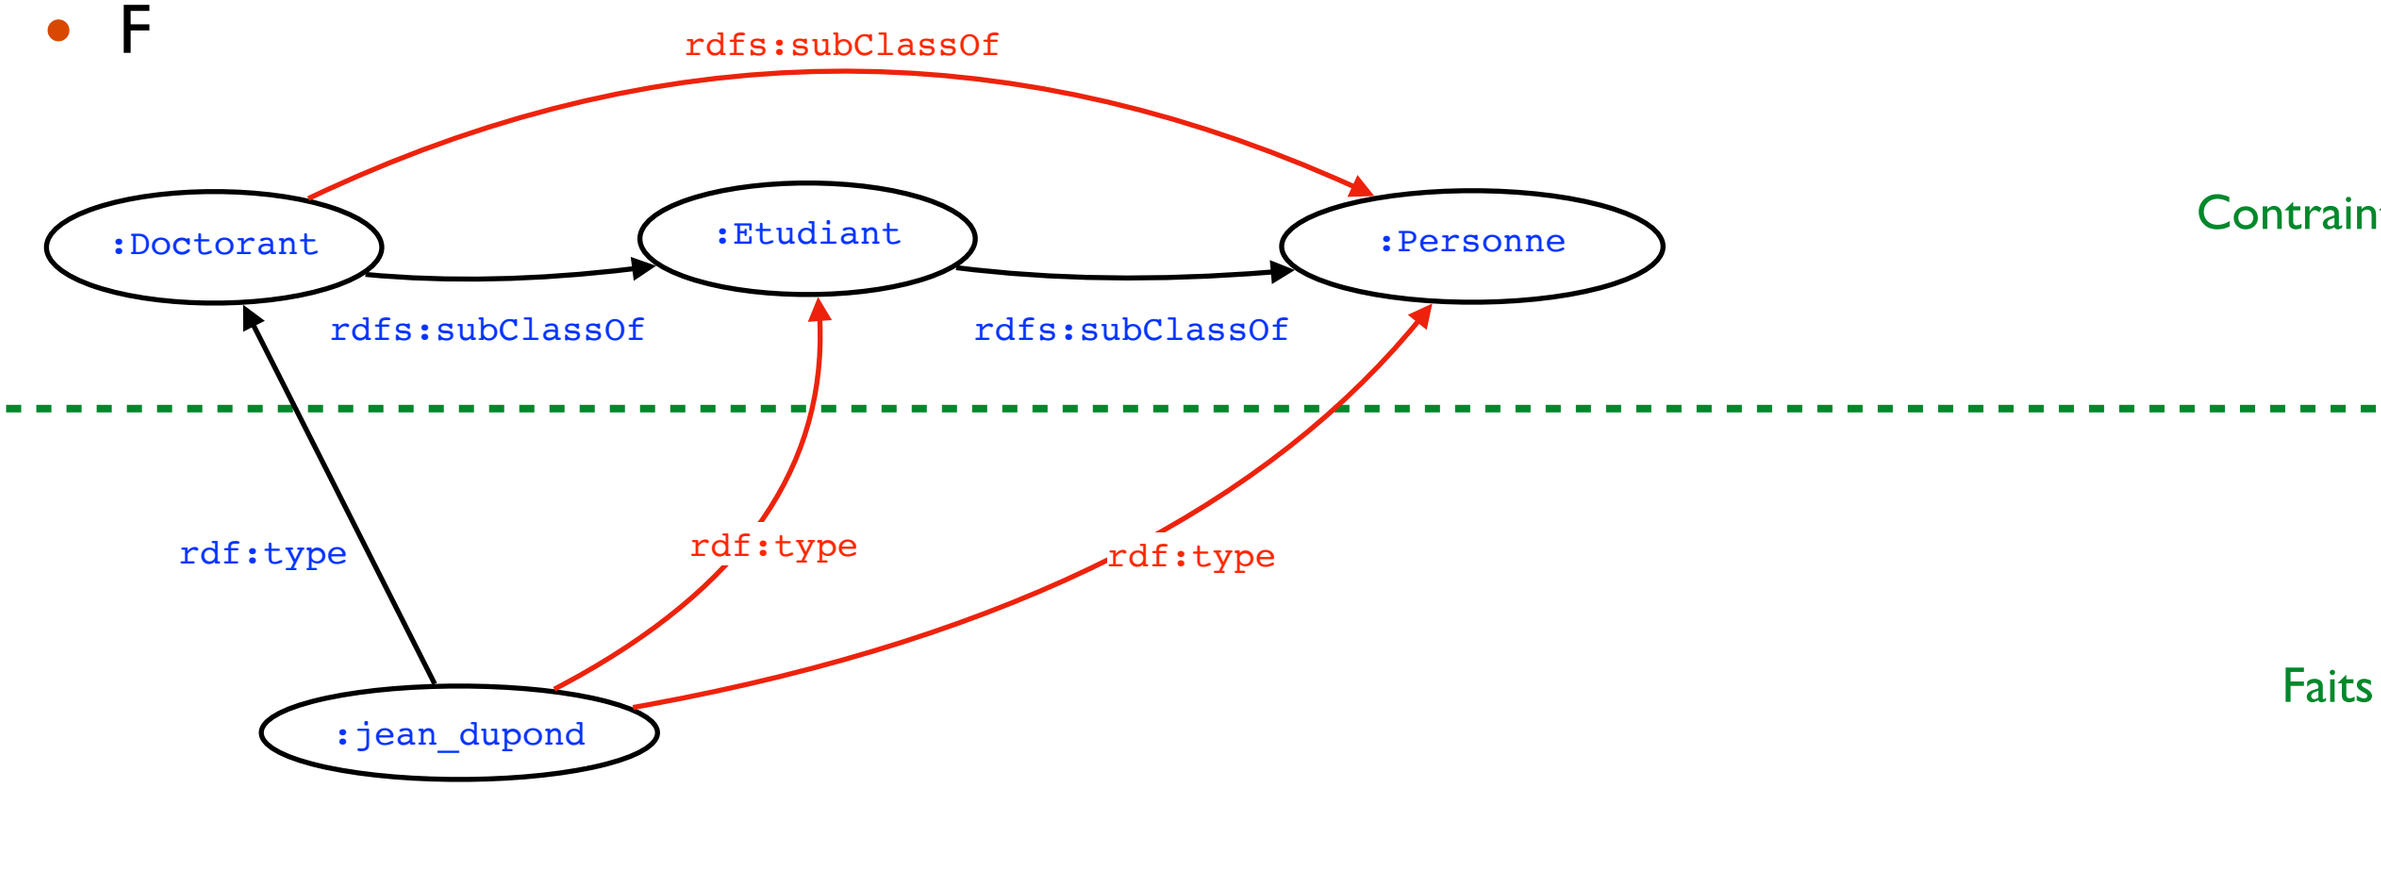

# Un autre exemple : saturation des faits et des contraintes

- F

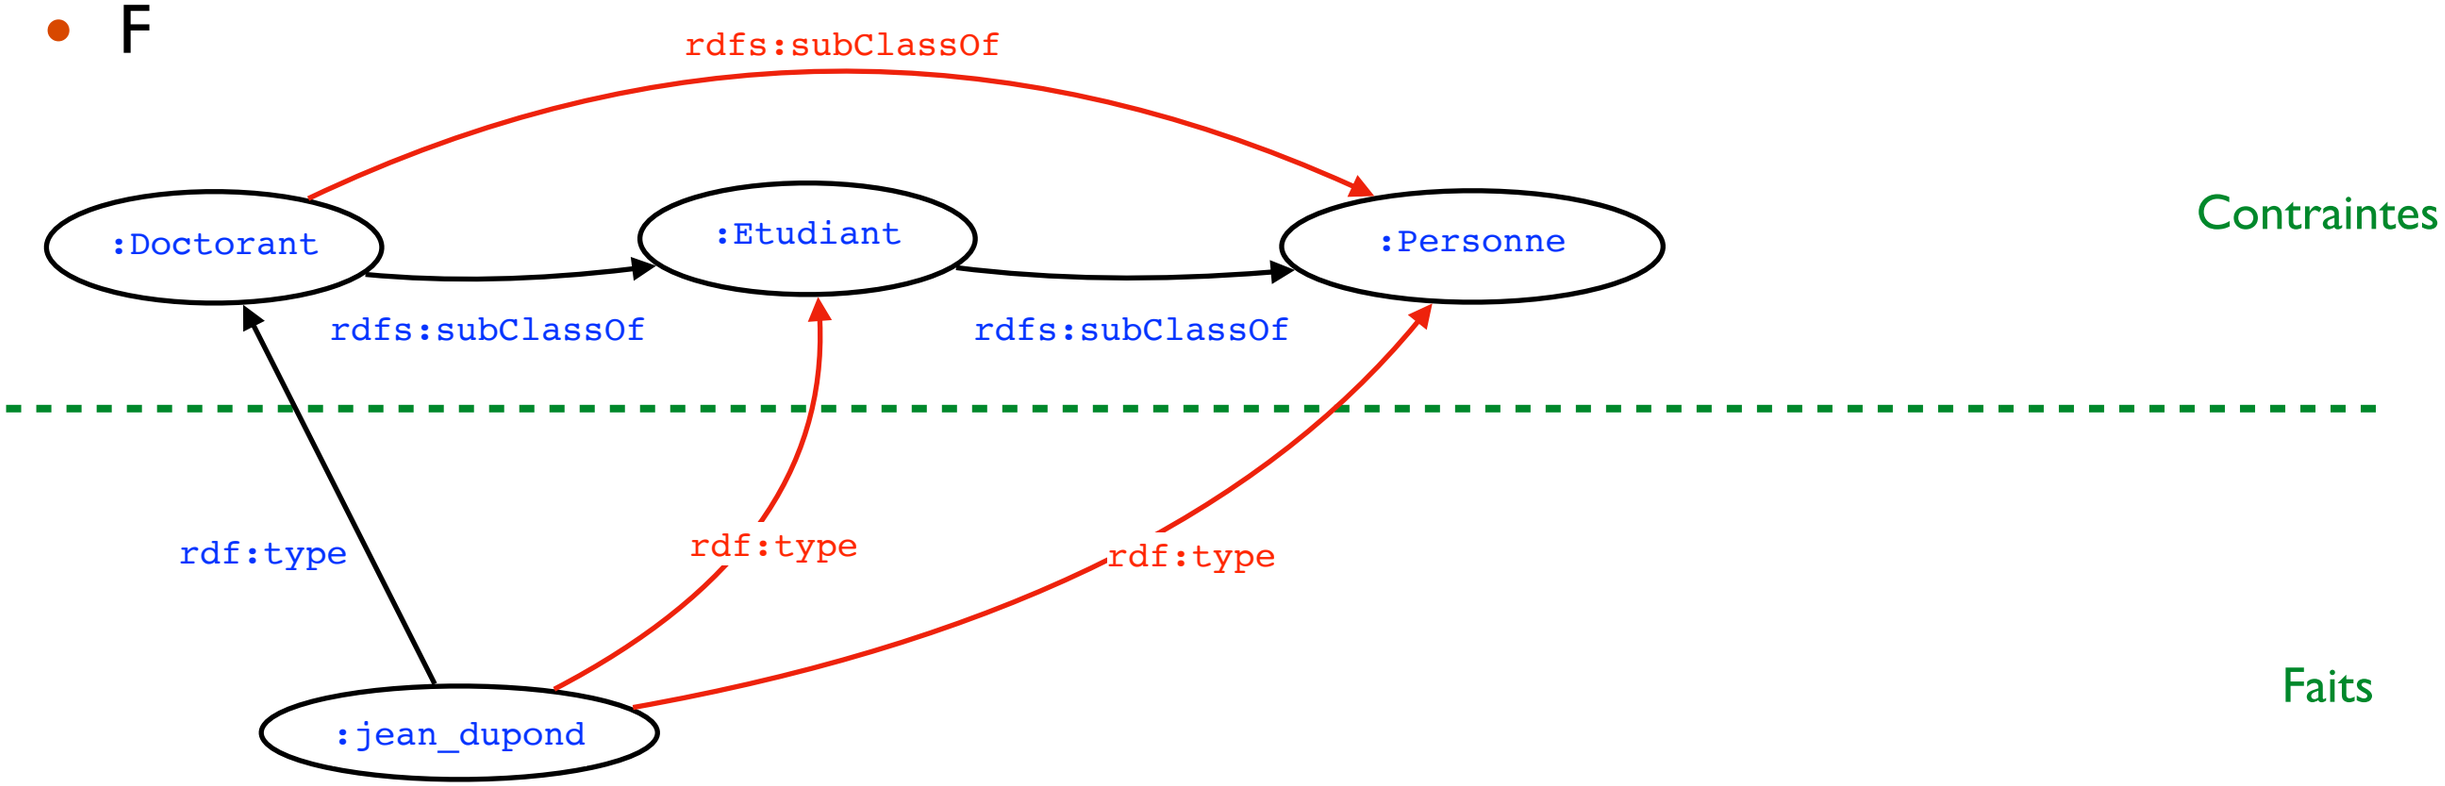


Plus aucune règles n'est applicable. **Saturation terminée. On a dérivé en F toutes les consequences** (de type fait ou contrainte)

(remarque : à la fois des règle de $\Gamma_A$ et de $\Gamma_T$ étaient applicables donc on a dérivé à la fois de nouveaux faits et de nouvelles contraintes (en rouge))

(on fait omission des triplets réflexifs)

# Graphe saturé (ou cloture)

Le graphe **F** obtenu par saturation du graphe K d'origine est appelé **graphe saturé** ou **cloture de K**

- dénoté $\mathbf{K}^{\infty}$

- ou $\mathbf{K}^{\Gamma\infty}$ pour rendre explicite l'ensemble des règles de derivation $\Gamma$ utilisées pour saturer

- Quand $\Gamma$ est l'ensemble de toutes les règles RDFS on écrira $\mathbf{K}^{\mathbf{RDFS}\infty}$

# Algorithme de saturation RDFS : complexité

- Dans toutes les contraintes RDFS la tête (conclusion) contient uniquement des variables qui apparaissent dans le corps (condition).
- Exemple :

```
<r rdf:type A>
<A rdfs:sublclassOf B>
_________________
<r rdf:type B>
```

(appelées “full TGDS”)

- Ce qui explique que les nouveaux triplets inférés peuvent utiliser seulement des ressources déjà présentes dans l’ontologie (A ∪ T)
- Cela garantit que l’algorithme de saturation termine toujours
- De plus seulement un nombre polynomial de nouveau triplets peut être dérivé (polynomial en le nombre de ressources de A ∪ T)
- => L’algorithme de saturation est PTIME (en la taille | A ∪ T| de l’ontologie)

# Interrogation de bases de connaissances RDFS

# Interrogation de données RDF : hypothèse de monde fermée

- Sémantique par défaut des langages d'interrogation RDF (par ex. SPARQL) :
  - Spécifie quel est le résultat d'une requête évaluée sur un graphe RDF, sans aucune inférence : uniquement les triplets explicites sont interrogés
  - Le graphe RDF peut contenir des faits et des contraintes (RDFS), mais il n'est pas vu comme une ontologie, simplement comme un ensemble de triplets RDF
  - Appelé hypothèse de monde fermé ( ou "*simple entailement regime*" dans le standard W3C) - la base de triplets est considérée "complete"

# Interrogation de données RDF : hypothèse de monde fermée

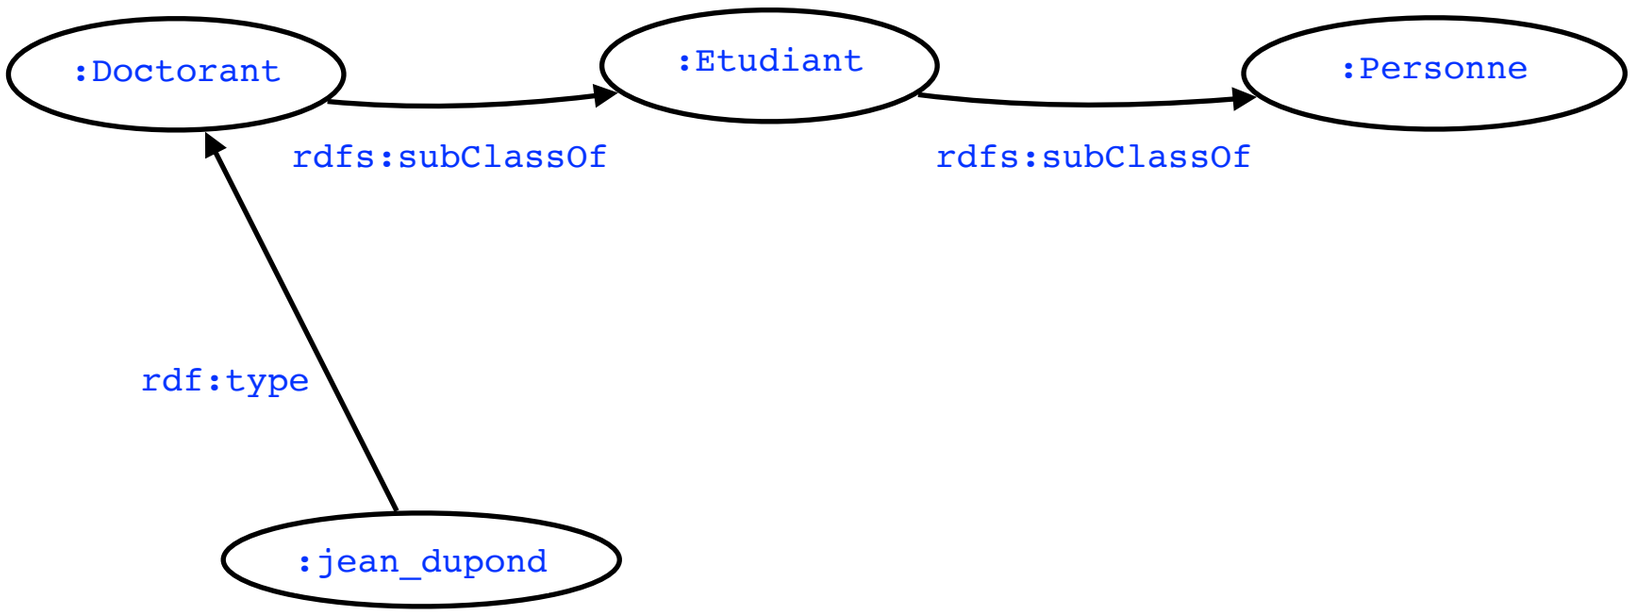


```
Select ?x

Where (:jean_dupond rdf:type ?x)
```

Retourne uniquement

| x |
| --- |
| :Doctorant |

# Interrogation de données RDF : hypothèse de monde fermée

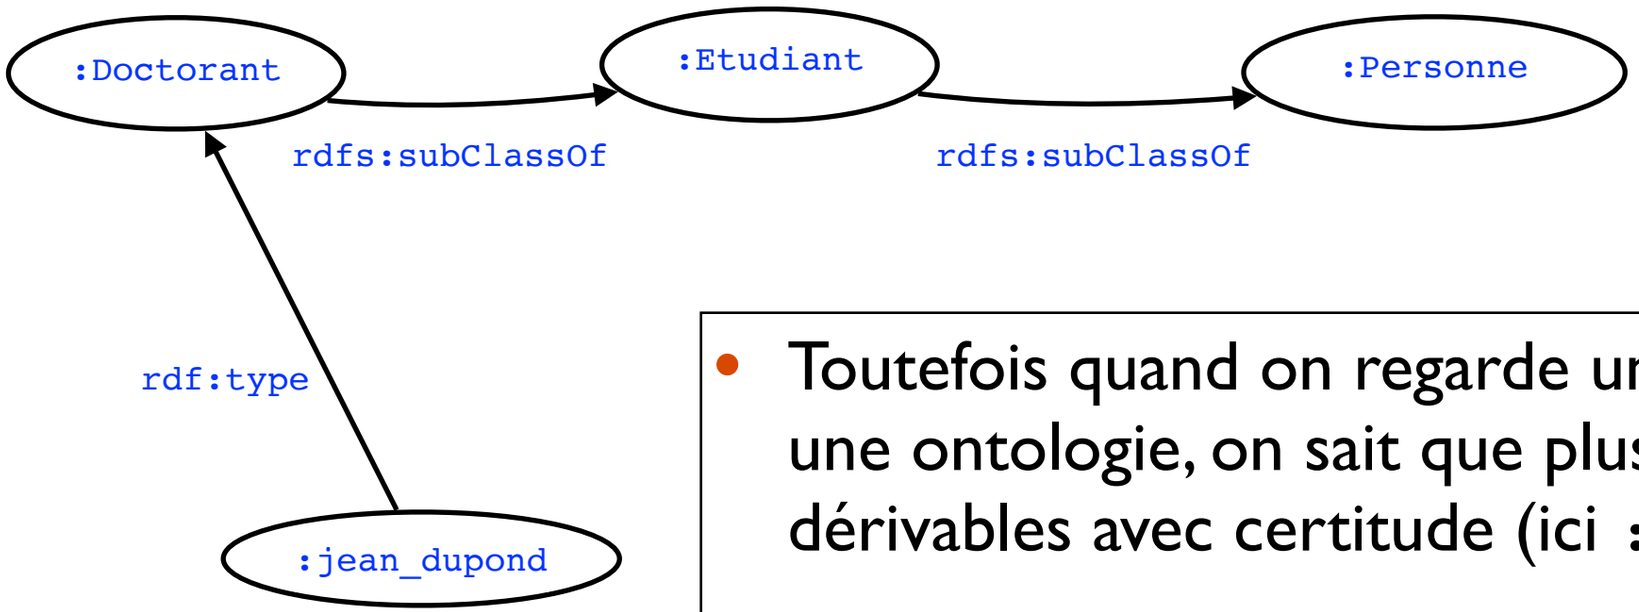


- Toutefois quand on regarde un graphe RDF/S comme une ontologie, on sait que plus de réponses sont dérivables avec certitude (ici `:Etudiant`, `:Personne`)
  - On souhaiterait que les réponses aux requêtes tiennent compte de ces nouvelles connaissances

```
Select ?x

Where (:jean_dupond rdf:type ?x)
```

Retourne uniquement

| x |
| --- |
| :Doctorant |

# Interrogation d'ontologies : hypothèse de monde ouvert

- Interroger une ontologie est une tâche plus complexe qu'interroger une base de faits considérée "complète"
  - Intuitivement : toute réponse à une requête derivable implicitement par les faits et contraintes du graphe interrogé doit être prise en compte
  - Appelée hypothèse de **monde ouvert** : la base de faits à interroger ne se limite pas aux faits explicitement représentés
  - Dans le standard W3C SPARQL 1.1 on parle de ***entailement regimes*** : un *entailement regime* spécifie quelle est la sémantique d'un requête SPARQL quand on autorise une forme de raisonnement
    - Plusieurs *entailement regimes* ont été spécifiés, selon l'ensemble de règles d'inférence $\Gamma$ qu'on autorise pour raisonner (RDF, RDFS, OWL etc)
    - Introduits uniquement dans la version 1.1 !!

# Interrogation de données RDF : hypothèse de monde fermée

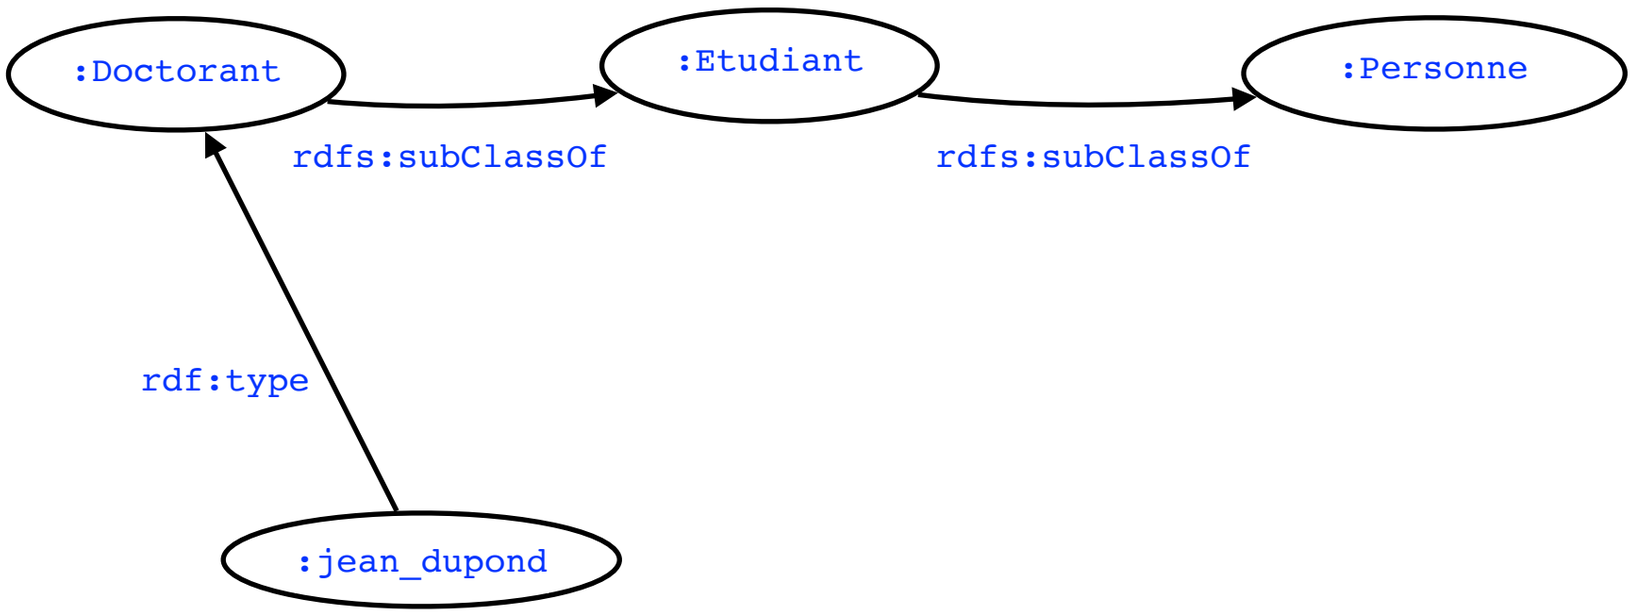


```
Select ?x

Where (:jean_dupond rdf:type ?x)
```

Response attendue **sous RDFS entailement regime**

| x |
|---|
| :Doctorant |
| :Etudiant |
| :Personne |

# Remarques

- Pas tous les systèmes commerciaux implémentent les *entailement regimes* (cela n'est pas rendu obligatoire par le W3C)
- Activer un mode d'évaluation SPARQL par *entailement regime* n'est pas toujours immédiat
  - En Jena par exemple :
    - La commande `sparql` implémente le *simple entailement regime* (pas d'inférence)
    - pas d'outils en ligne de commande equivalents à la commande `sparql` pour adopter un autre *entailement regime*
    - Mais facilement implémentable dans un programme Java par la bibliothèque ARQ de Jena

# La théorie et la pratique

- Les entailment regimes sont définis dans le standard W3C uniquement pour les BGP (forme simple de requêtes positives) !!
  - Bien que SPARQL possède des mécanismes complexe de negation!
- Cela veut dire qu'il n'y a pas accord sur ce qu'une requête avec negation devrait retourner quand on veut tenir compte des  inférences
  - chaque système commercial implémente sa propre sémantique
- Sujet de recherche très actif !
- Nous nous limiterons aux BGP dans ce cours…

# Sémantique des BGP en presence d'inférence

- On denote $Q(K)$ l'évaluation directe de Q sur un graphe RDF K (pas d'inférence)
- Sous un ensemble $\Gamma$ de règles d'inférence autorisées (i.e. l'*entailement regime*) on denote $Q^{\Gamma}(K)$ la réponse attendue de Q en presence de l'inférence $\Gamma$
  - Si $\Gamma$ est l'ensemble des règles RDFS on écrira $Q^{RDFS}(K)$
- Rappel : on denote $K^{\Gamma\infty}$ la saturation de K par les règles d'inférences $\Gamma$
- Pour les BGP le standard W3C en gros* définit $Q^{\Gamma}(K)$ comme :

$$Q^{\Gamma}(K) := Q(K^{\Gamma\infty})$$

* plus compliqué que cela en presence de blank nodes, extensions des BGP avec OPTIONAL,…

# Sémantique des BGP en presence d'inférence

K

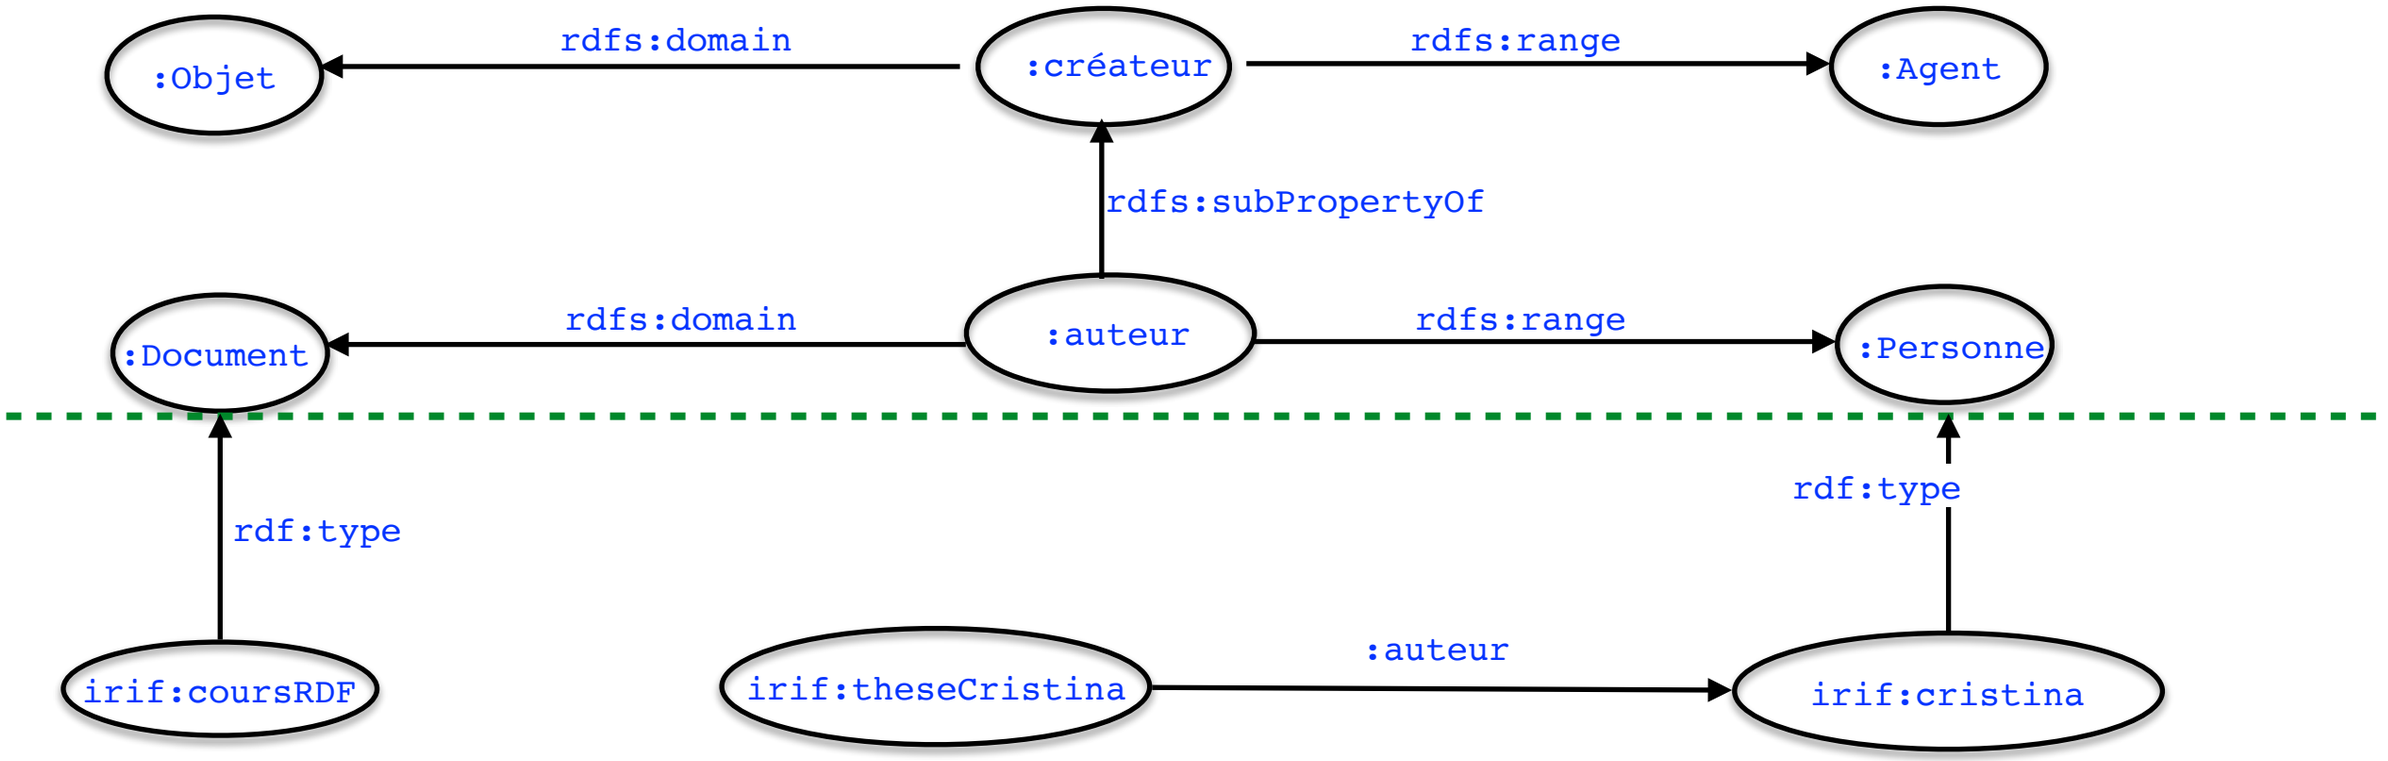


Q

```
Select ?x
Where {
   ?x rdf:type :Object .
   ?x :createur irif:cristina .
}
```

Q(K) vide
(résultat de la commande `sparql`)

# Sémantique des BGP en presence d'inférence

F = $K^{RDFS\infty}$ (restraints aux faits)

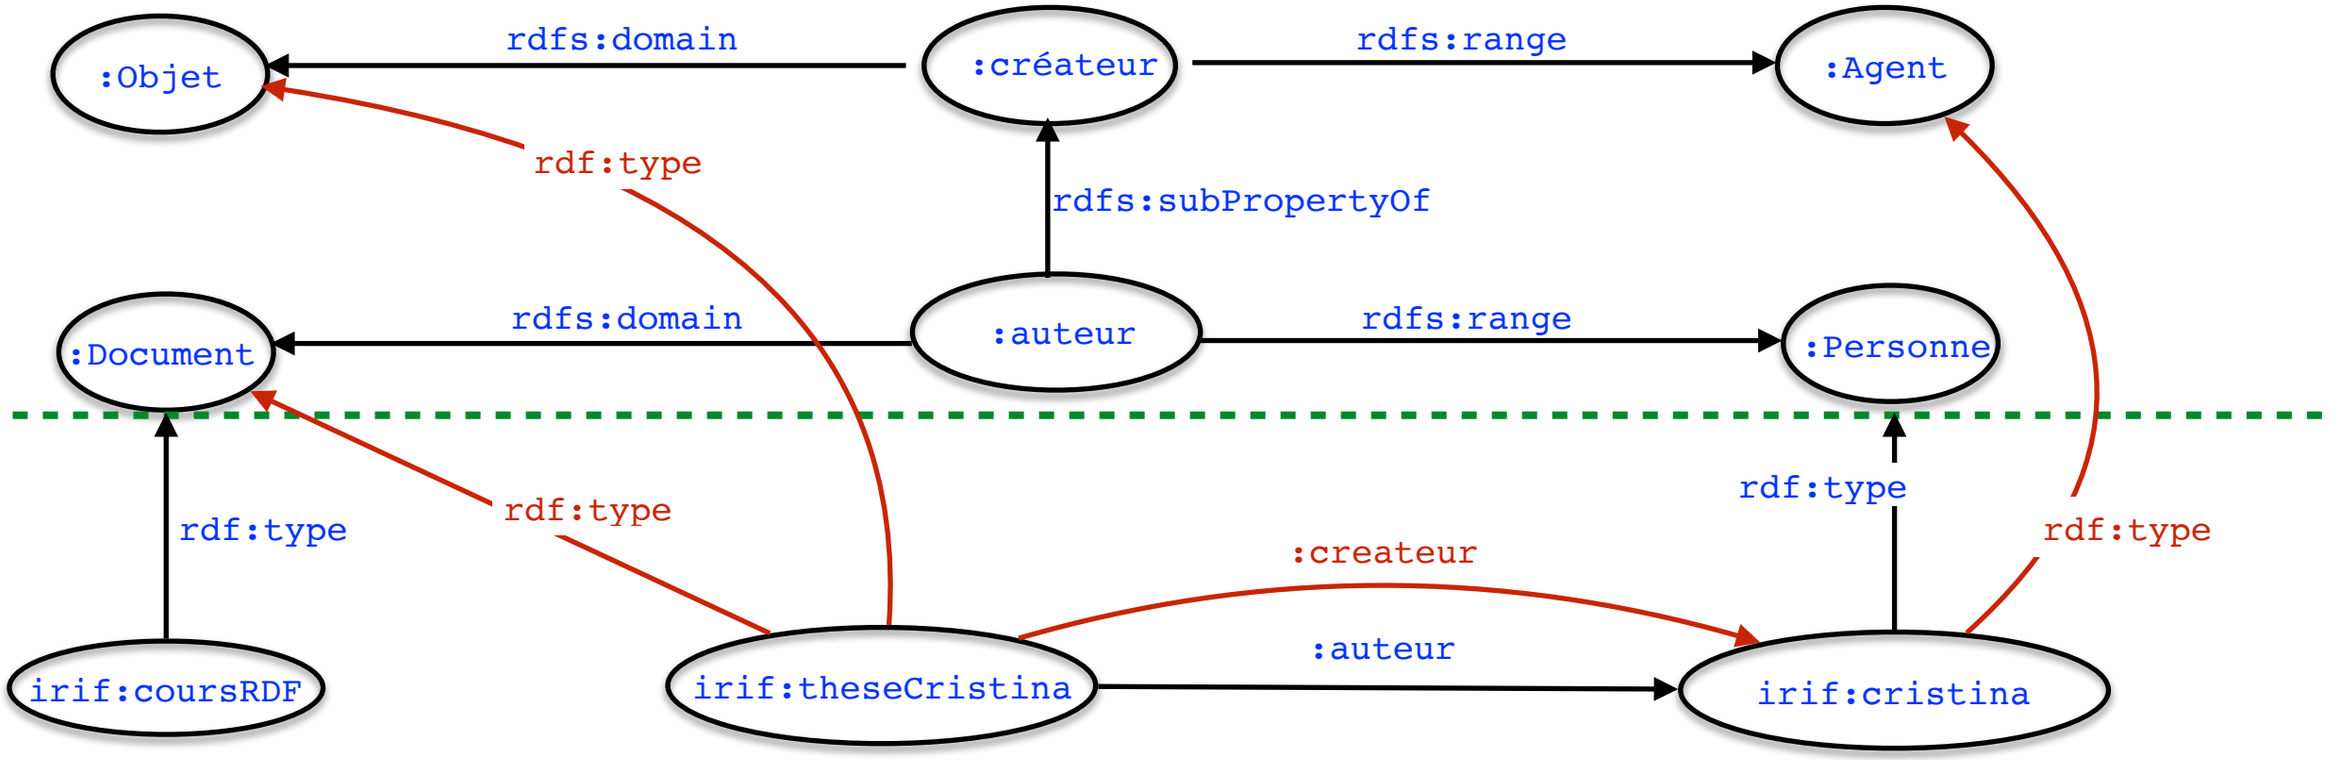


Q

```
Select ?x
Where {
   ?x rdf:type :Object .
   ?x :createur irif:cristina .
}
```

$Q^{RDFS}(K) = Q(F)$

| x |
| --- |
| :irifTheseCristina |

# Calcul des réponses en présence d'inférence

- **Approche saturation :**
  - Le graphe saturé est calculé plus ou moins entièrement pour y évaluer les requêtes
- Approche réécriture
  - Pas de calcul d'inférences : la requête es re-écrite pour "simuler" la présence des faits dérivés

# Calcul des réponses en presence d'inférence : approche saturation

- Approche saturation : évaluer la requête sur le graphe saturé $\mathbf{K}^{\Gamma\infty}$
- Demande un moteur de deduction entre le système de stockage et le système d'evaluation de requête

- Deux approches :
  - **Forward chaining**
  - **Backward chaining**

# Forward chaining

## I) Forward chaining

- Appliquer l'algorithme de saturation pour deriver les consequences (le graphe saturé $\mathbf{K}^{\Gamma\infty}$) progressivement à partir des faits connus et materialiser les consequences au fur et à mesure
- Evaluer la requête sur $\mathbf{K}^{\Gamma\infty}$ avec des techniques standard

- Le raisonnement se fait donc *des premisses vers le conclusions* des règles : les faits ajoutés correspondent aux conclusions : ils sont stockés et réutilisés par la suite

- La matérialisation peut être faite avant l'execution de la requête (phase statique)
- Solution adoptée par la plupart des moteurs SPARQL

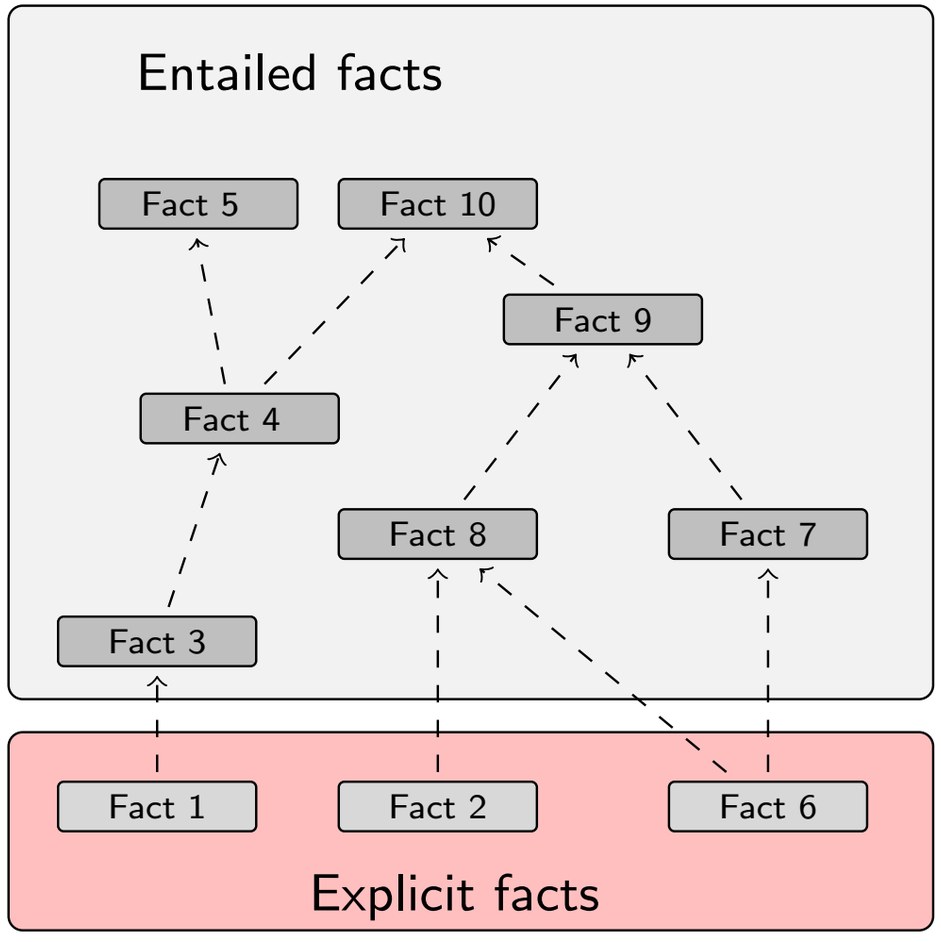

# Forward chaining

## Avantages

- Le pré-calcul et le stockage des inférence est avantageux pour les données qui sont fréquemment interrogées
  - À condition que les données soient peu dynamiques
  - Et que les inférences ne soient pas trop volumineuses : elles doivent être stockées efficacement
- Materialisation pre-calculée : optimise la phase d'évaluation de la requête, aucune inférence additionnelle n'est nécessaire au moment de l'evaluation

## Inconvénients

- L'espace de stockage utilisé
  - Il peut y avoir beaucoup d'inférences, génère de très grands graphes
- Les surcoût de la modification des données (il faut mettre à jour les inférences)
  - pas adapté aux données très dynamiques

# Backward chaining

## 2) Backward chaining

- Le raisonnement se fait *des conclusions vers les prémisses* des règles
  - On part des faits necessaries pour satisfaire la requête (les faits de la requête)
  - Quels autres faits doivent être vrais pour obtenir ces conclusions ?

- Les règles sont donc utilisées pour étendre la requête
- Raisonnement à la demande : seulement les faits dont on a besoin pour calculer une réponse sont calculés
- Ne nécessite pas de matérialisation persistante

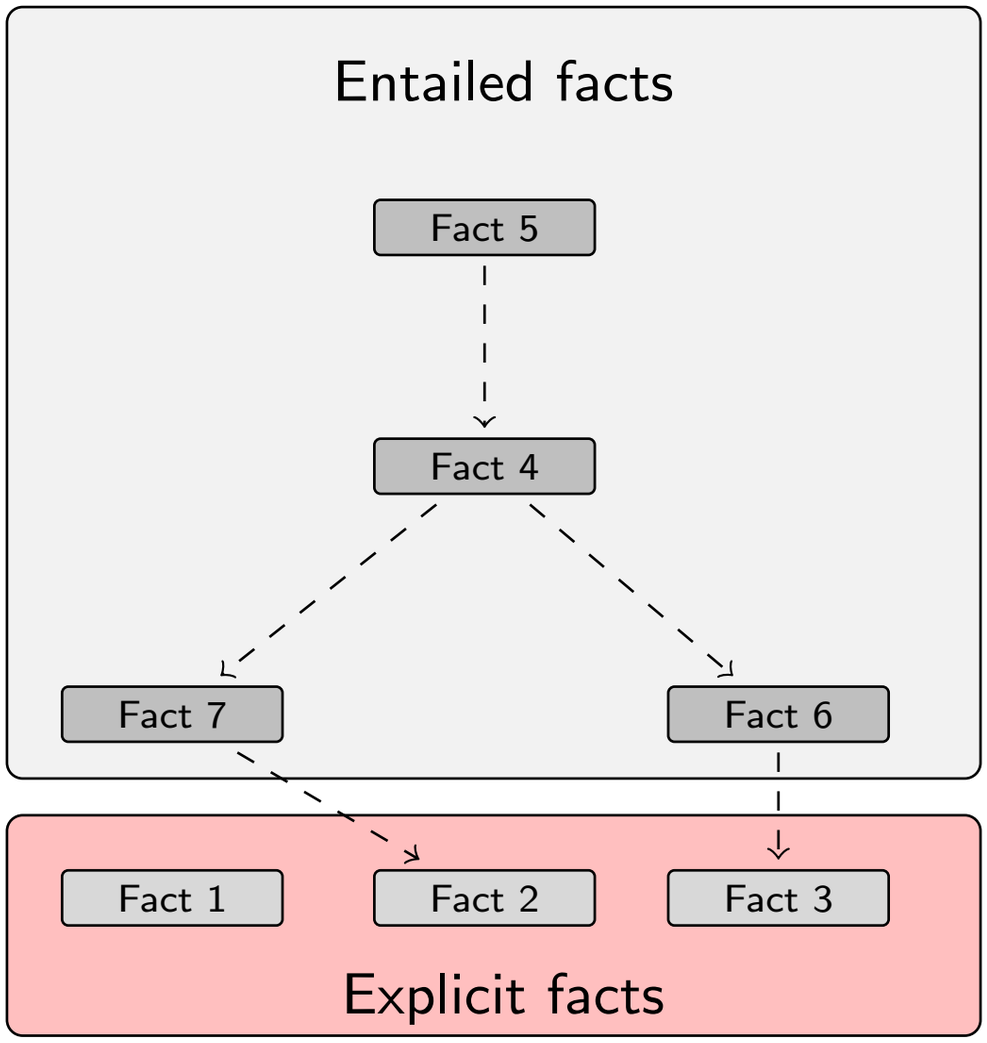

# Backward chaining : exemple

**Base de connaissance**

```
ex:Mammal rdfs:subClassOf ex:Vertebrate .
ex:KillerWhale rdfs:subClassOf ex:Mammal .
ex:Lion rdfs:subClassOf ex:Mammal .
ex:Keiko rdf:type ex:KillerWhale .
ex:Simba rdf:type ex:Lion .
```

**Requête**

```
SELECT ?x WHERE
{ ?x rdf:type ex:Vertebrate . }
```

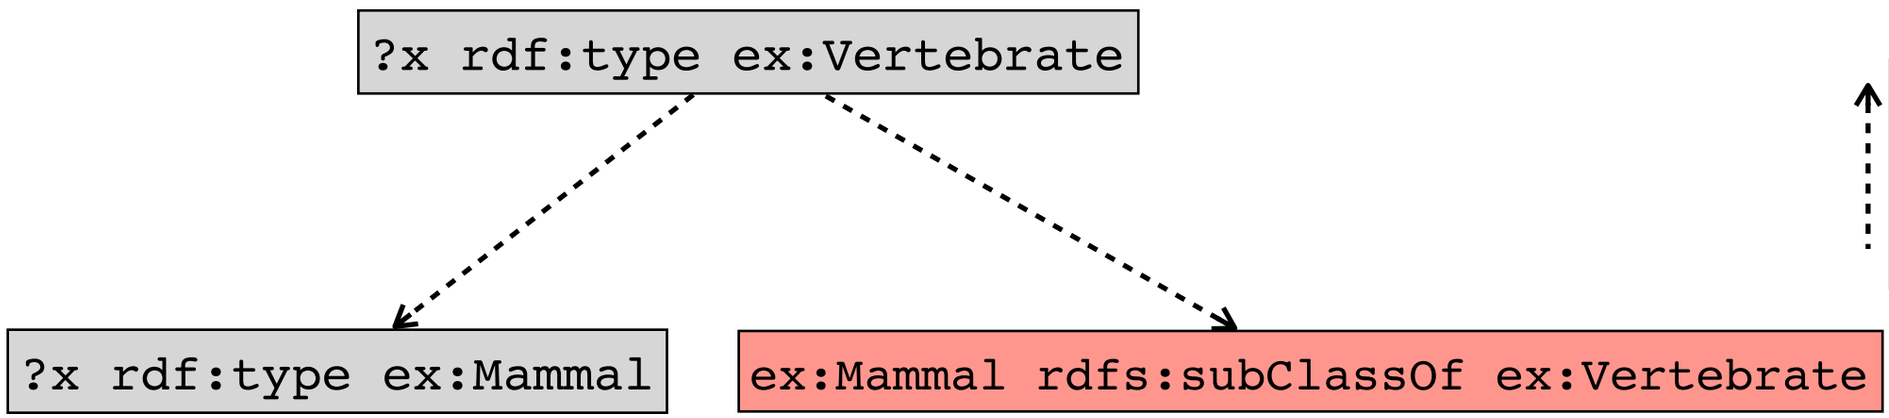


**Règle utilisée**

```
<r rdf:type A>
<A rdfs:sublclassOf B>
_____________________
<r rdf:type B>
```

# Backward chaining : exemple

**Base de connaissance**

```
ex:Mammal rdfs:subClassOf ex:Vertebrate .
ex:KillerWhale rdfs:subClassOf ex:Mammal .
ex:Lion rdfs:subClassOf ex:Mammal .
ex:Keiko rdf:type ex:KillerWhale .
ex:Simba rdf:type ex:Lion .
```

**Requête**

```
SELECT ?x WHERE
{ ?x rdf:type ex:Vertebrate . }
```

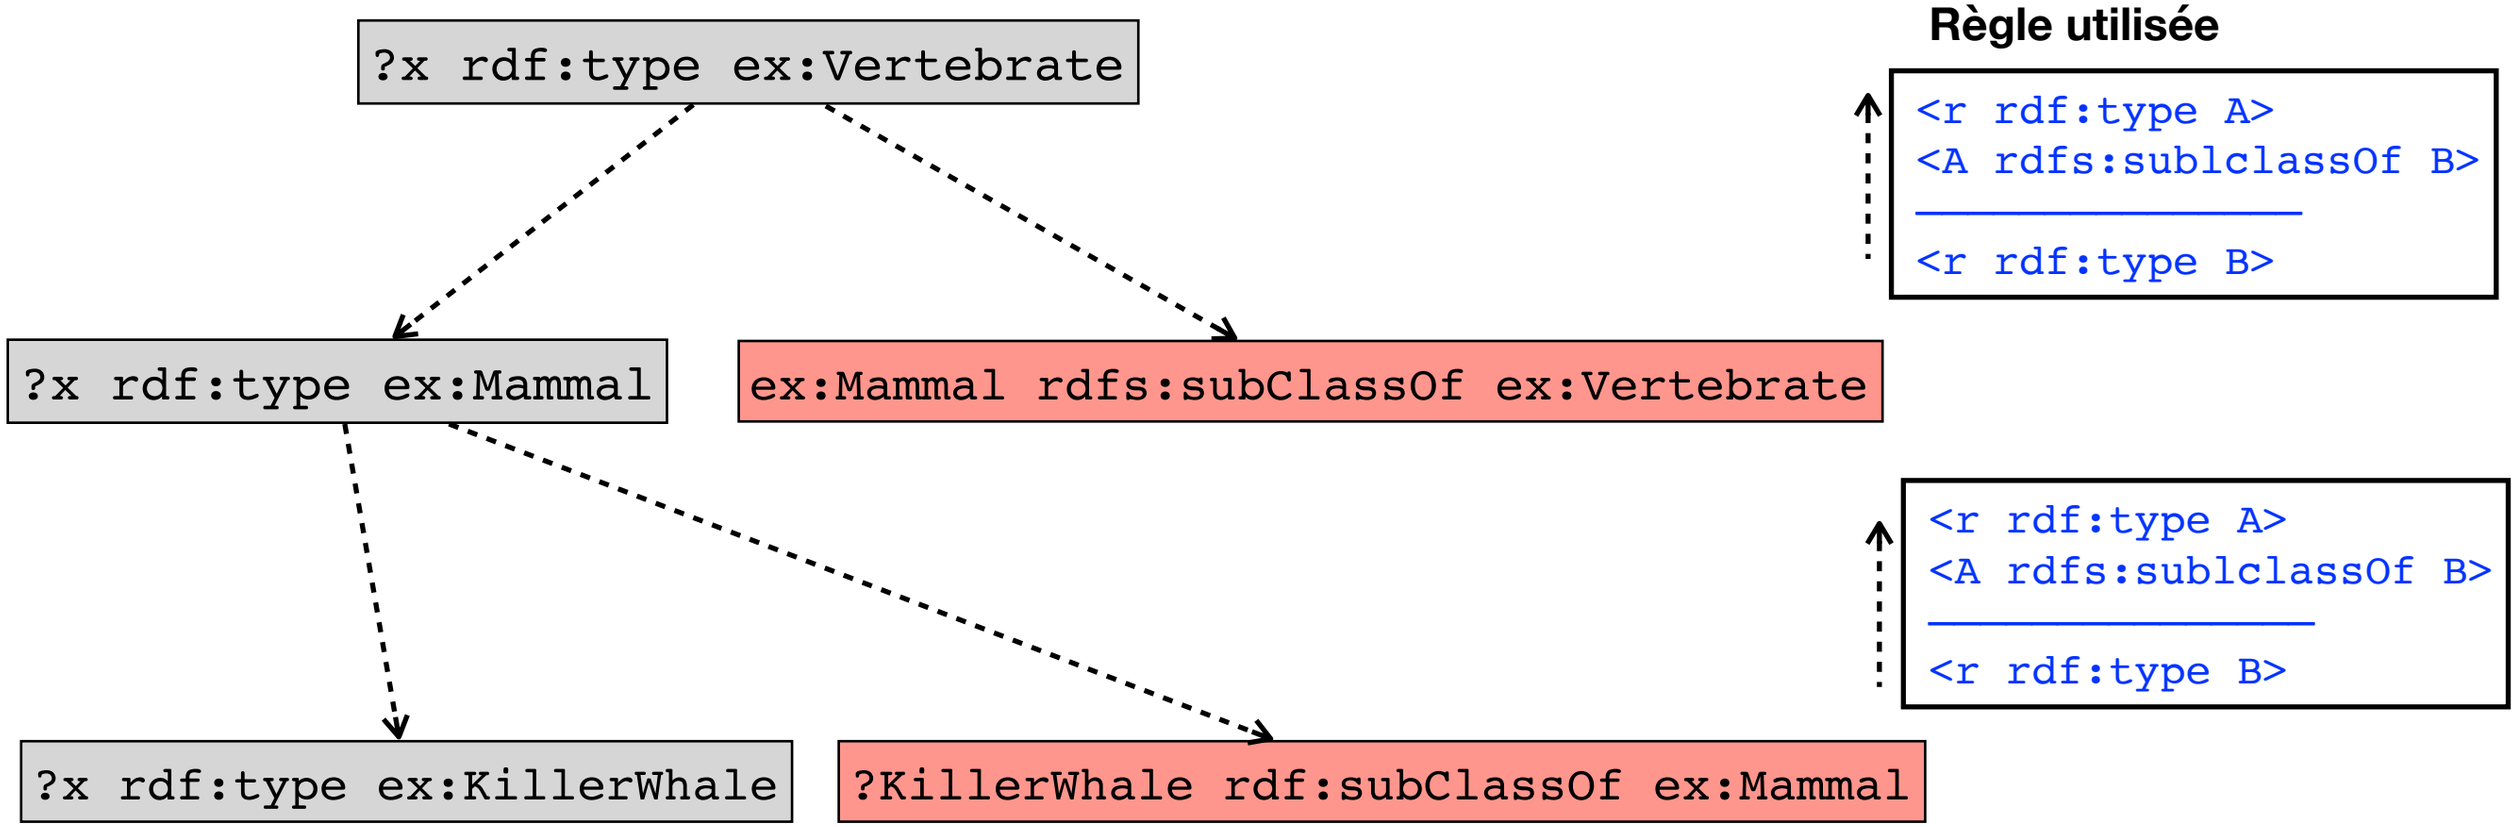

# Backward chaining : exemple

**Base de connaissance**

```
ex:Mammal rdfs:subClassOf ex:Vertebrate .
ex:KillerWhale rdfs:subClassOf ex:Mammal .
ex:Lion rdfs:subClassOf ex:Mammal .
ex:Keiko rdf:type ex:KillerWhale .
ex:Simba rdf:type ex:Lion .
```

**Requête**

```
SELECT ?x WHERE
{ ?x rdf:type ex:Vertebrate . }
```

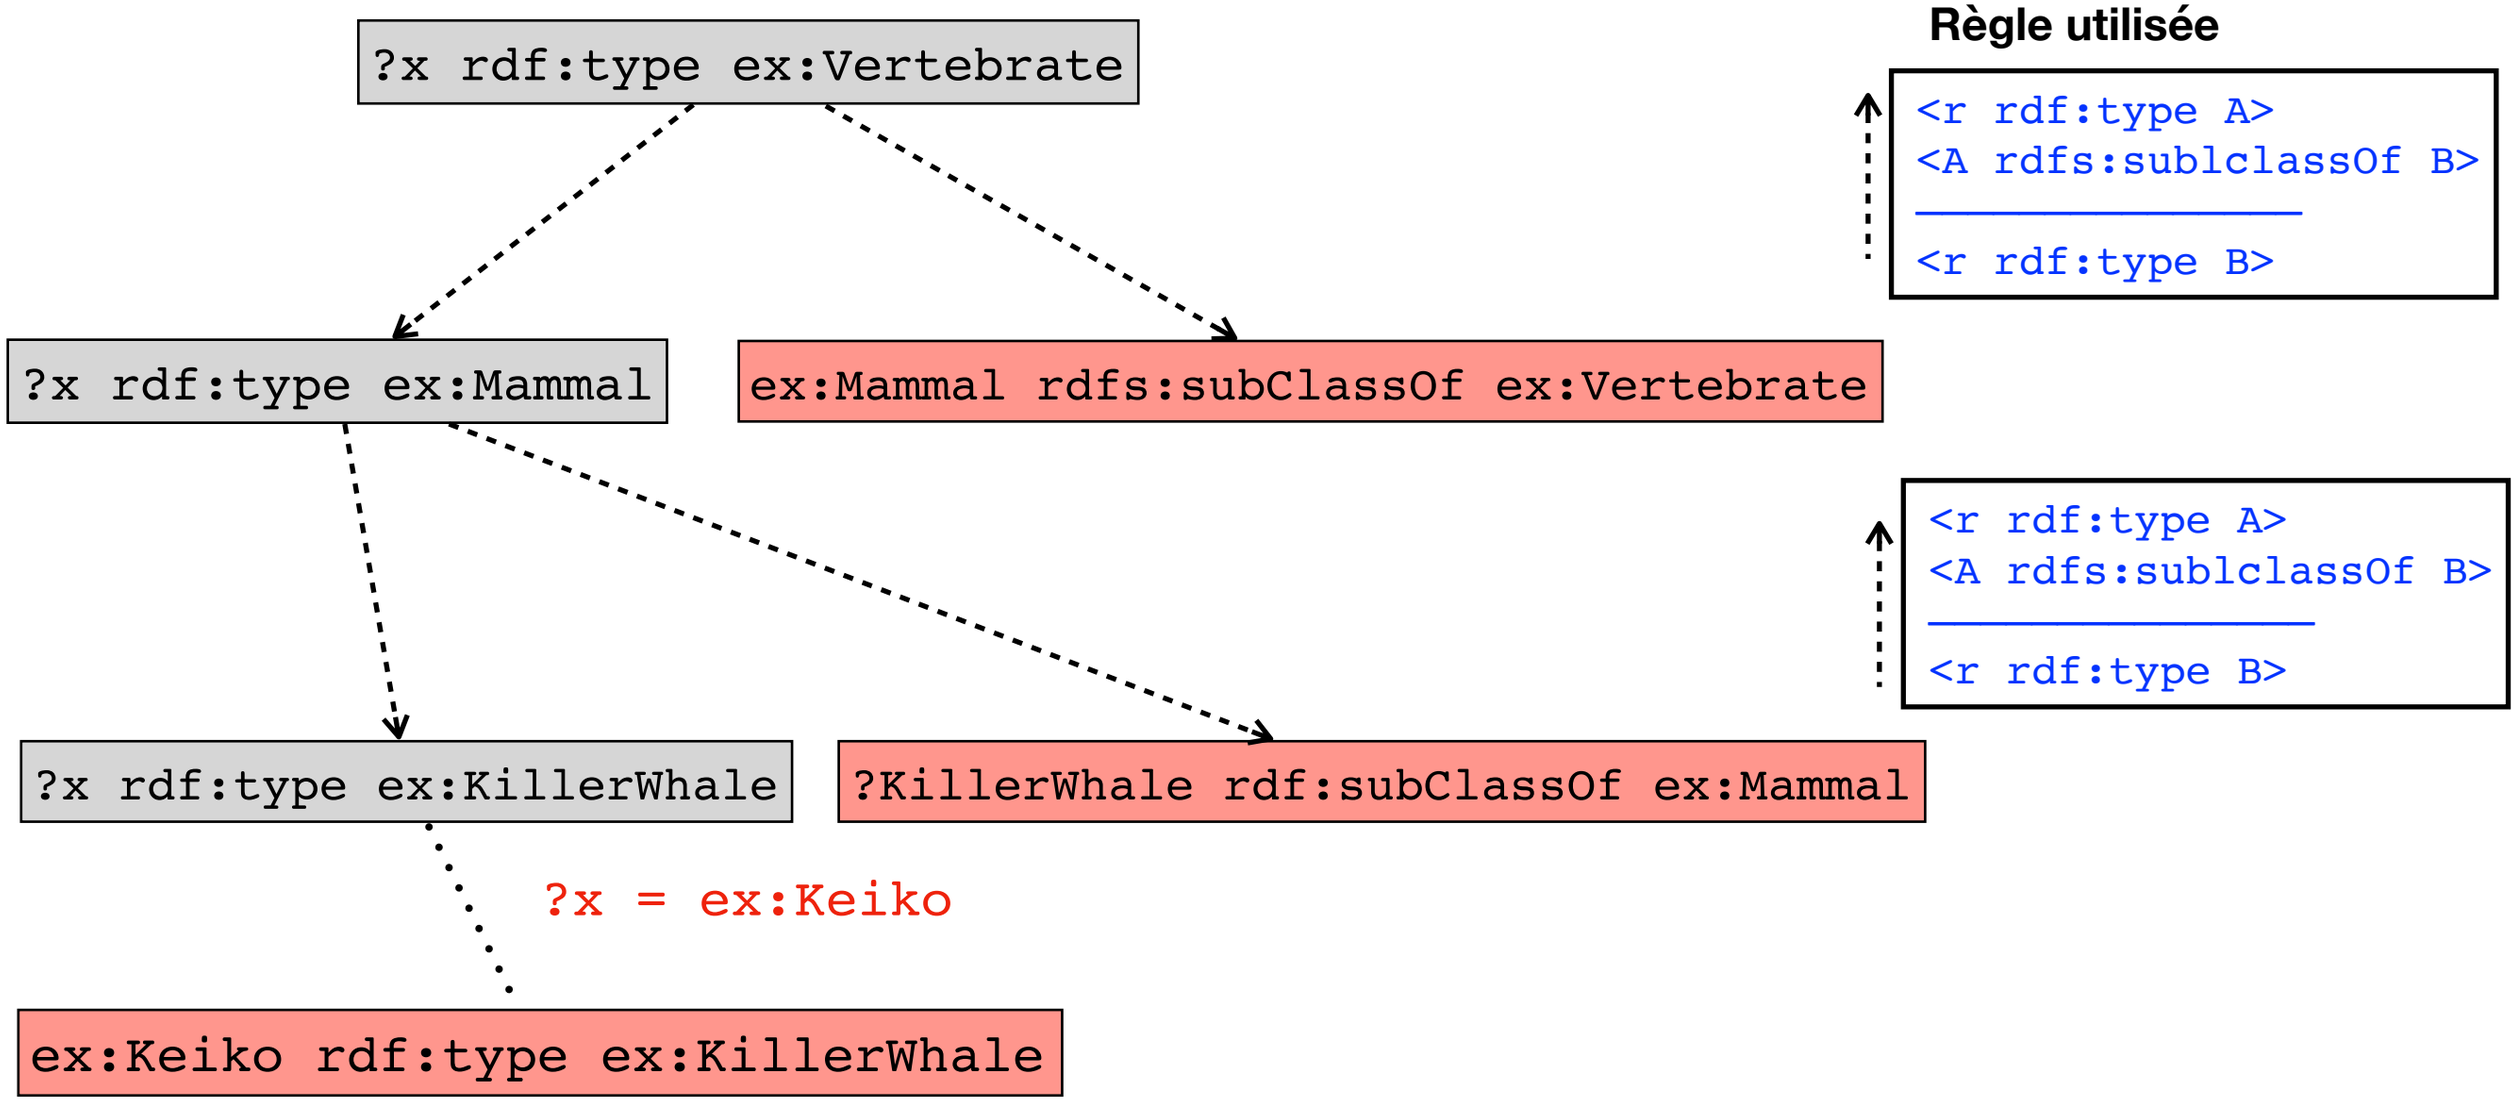

# Backward chaining : exemple

**Base de connaissance**

```
ex:Mammal rdfs:subClassOf ex:Vertebrate .
ex:KillerWhale rdfs:subClassOf ex:Mammal .
ex:Lion rdfs:subClassOf ex:Mammal .
ex:Keiko rdf:type ex:KillerWhale .
ex:Simba rdf:type ex:Lion .
```

**Requête**

```
SELECT ?x WHERE
{ ?x rdf:type ex:Vertebrate . }
```

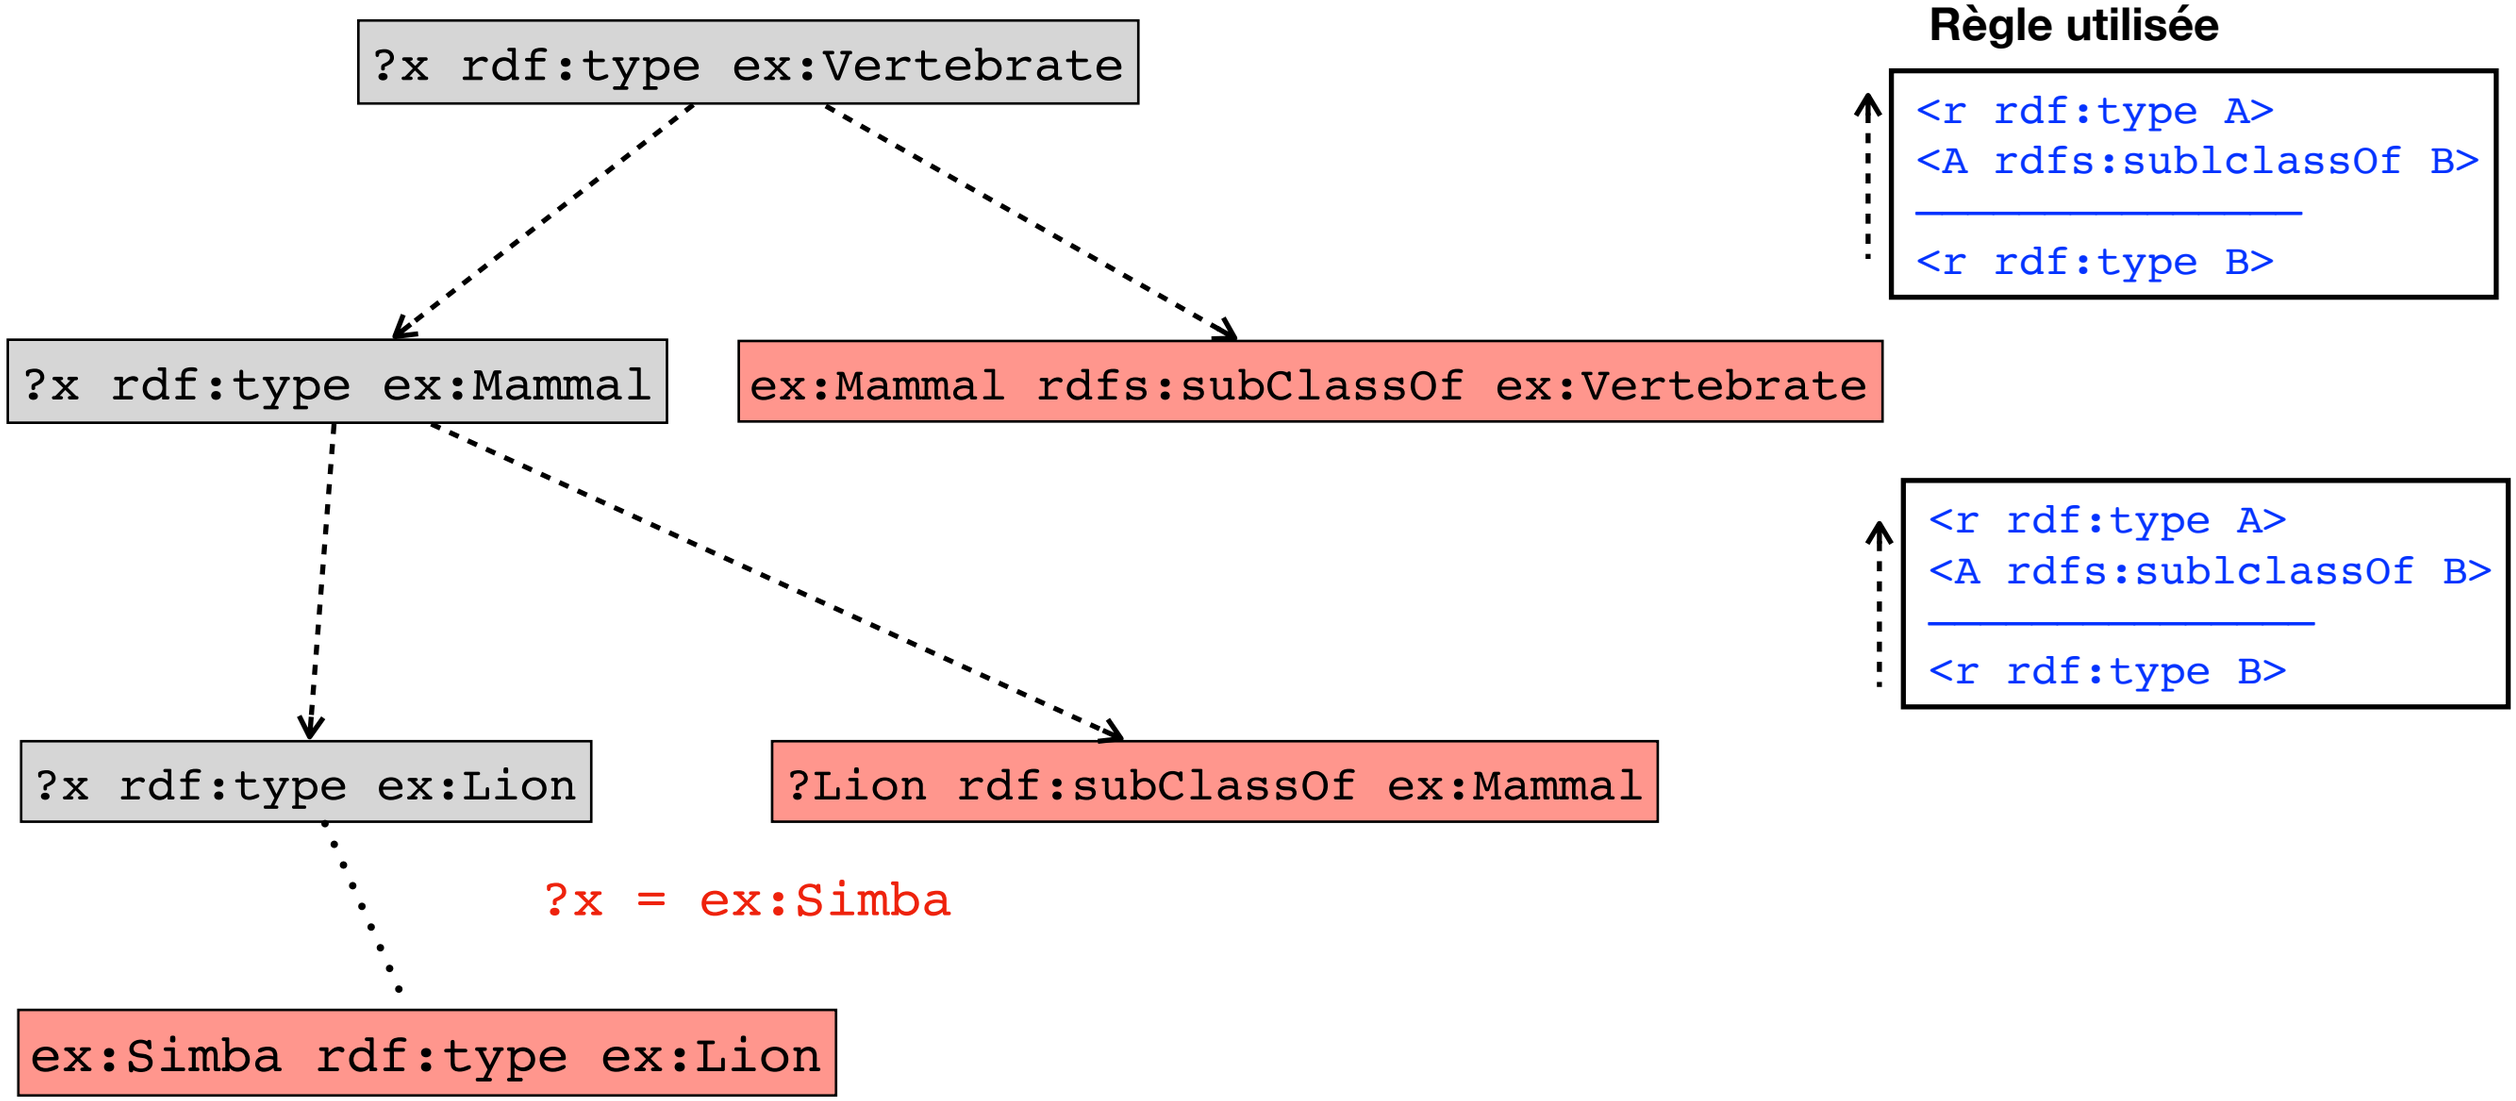

# Backward chaining

**Avantages**

- Seulement les inférences utiles sont faites, pas de mémorisation persistante
- Adapté à des sources dynamiques (pas de re-calcul des inférences nécessaire suite aux modifications des données)
- Utile quand il n'y a pas (ou il y a peu) besoin de réutiliser les reposes déjà calculées

**Inconvénients**

- Temps de calculs plus lents : les inferences doivent être faites à chaque requête
  - Caching possible pour améliorer les performances

# Calcul des réponses en présence d'inférence

- Approche saturation :
  - Le graphe saturé est calculé plus ou moins entièrement pour y évaluer les requêtes
- **Approche réécriture**
  - Pas de calcul d'inférences : la requête est re-écrite pour "simuler" la présence des faits dérivés

# Approche réécriture

- Rappel : pour calculer les réponses à une requête sur une base de connaissance K en présence d'inférence il faudrait calculer

$$Q(K^{\Gamma\infty})$$

- L'approche réécriture en revanche construit une nouvelle requête Q' telle que

$$Q(K^{\Gamma\infty}) = Q'(K) \qquad \text{pour tout } K$$

(Q' dépendant de $\Gamma$)

- Cela évite de calculer les inférences ! On interroge seulement les faits explicites

# Approche réécriture : exemple

**Q**

```
SELECT ?x WHERE { ?x rdf:type ex:Vertebrate . }
```

**Q'**

```
SELECT ?x WHERE {
{?x rdf:type ?z . ?z rdfs:subClassOf* ex:Vertebrate .}
UNION
{?x ?p ?y . ?p rdfs:subPropertyOf*/rdfs:domain/rdfs:subClassOf* ex:Vertebrate}
UNION
{?y ?p ?x . ?p rdfs:subPropertyOf*/rdfs:range/rdfs:subClassOf* ex:Vertebrate }
}
```

- Sous sémantique RDFS :

$$Q(K^{RDFS\infty}) = Q'(K) \qquad \text{pour tout } K$$

- Intuitivement les règles de derivation RDFS sont "intégrées" dans la réécriture Q'

# Approche réécriture : exemple

- La réécriture n'est pas toujours expressible en SPARQL même
- En effet pour des requêtes SPARQL Q très simples Q' demande un langage plus puissant
- Par exemple :

**Q0**
```
SELECT ?x ?y WHERE { ?x :prop ?y }
```

a une réécriture en SPARQL

**Q0'**
```
SELECT ?x ?y WHERE { ?x ?z ?y . ?z rdfs:subPropertyOf* :prop}
```

- Mais comment réécrire en SPARQL

**Q1**
```
SELECT ?x ?y WHERE { ?x :prop+ ?y }
```

**?**

# Approche réécriture : exemple

- Comment réécrire en SPARQL

**Q1**
```
SELECT ?x ?y WHERE { ?x :prop+ ?y }
```
?

- Cela n'est pas possible.
- Il faudrait pouvoir avoir l'étoile (+) au dessus d'un motif de graphe :

```
?x  (?start ?z ?end . ?z rdfs:subPropertyOf* :prop)+   ?y
```

- Mais cela n'est pas autorisé en SPARQL
- nSPARQL* : une extension de SPARQL proposée pour inclure ces formes expressions régulières "imbriquées"
  - Pourrait être utilisé internement aux moteurs de réécriture

* J. Pérez, M. Arenas, and C. Gutierrez. nSPARQL: A navigational language for RDF J. Web Sem., 8(4):255–270, 2010.

# Approche réécriture

## Avantages

- Pas de stockage d'inférences (ni en disque ni en mémoire)
- pas besoin de moteur d'inférence sur les données, tout est délégué au moteur d'évaluation de requête

## Inconvénients

- Algorithmes de réécritures et réécritures complexes (surtout au delà de RDFS)

# Back to theory : les réponses certaines

- Rappel :
  Interrogation d'une ontologie : intuitivement toute réponse derivable implicitement par les faits et contraintes du graphe interrogé doit être prise en compte
- Pour les bases de connaissance RDFS/OWL le W3C a adopté une sémantique opérationnelle pour obtenir cela :
  - Répondre à la requête comme si le graphe était saturé
- La recherche théorique a proposé en revanche  une notion d'inférence logique pour définir la sémantique d'interrogation d'ontologies :

Soit K une ontologie

On dit qu'une réponse à Q est **impliquée** par K (ou est une **réponse certaine** à Q sur K) si a est une réponse à Q(M) pour tout modèle  M de K

# Rappel : modèle

- Soit K une ontologie  RDFS avec faits A et contraintes T

un **modèle RDFS** de K est un graphe RDF dont les propriétés sont soit dans P soit des propriétés prédéfinies `rdf/rdfs,` qui :

- contient les triplets A et T et les triplets axiomatiques,
- satisfait les contraintes prédéfinies RDFS
  (cf slide "Ontologie RDFS prédéfinie - contraintes")

- Un modèle peut être défini de façon analogue quel que soit le langage d'ontologie choisi

# Responses certaines : exemple

- Exemple : K requête :“quels sont les objets créés par un agent”

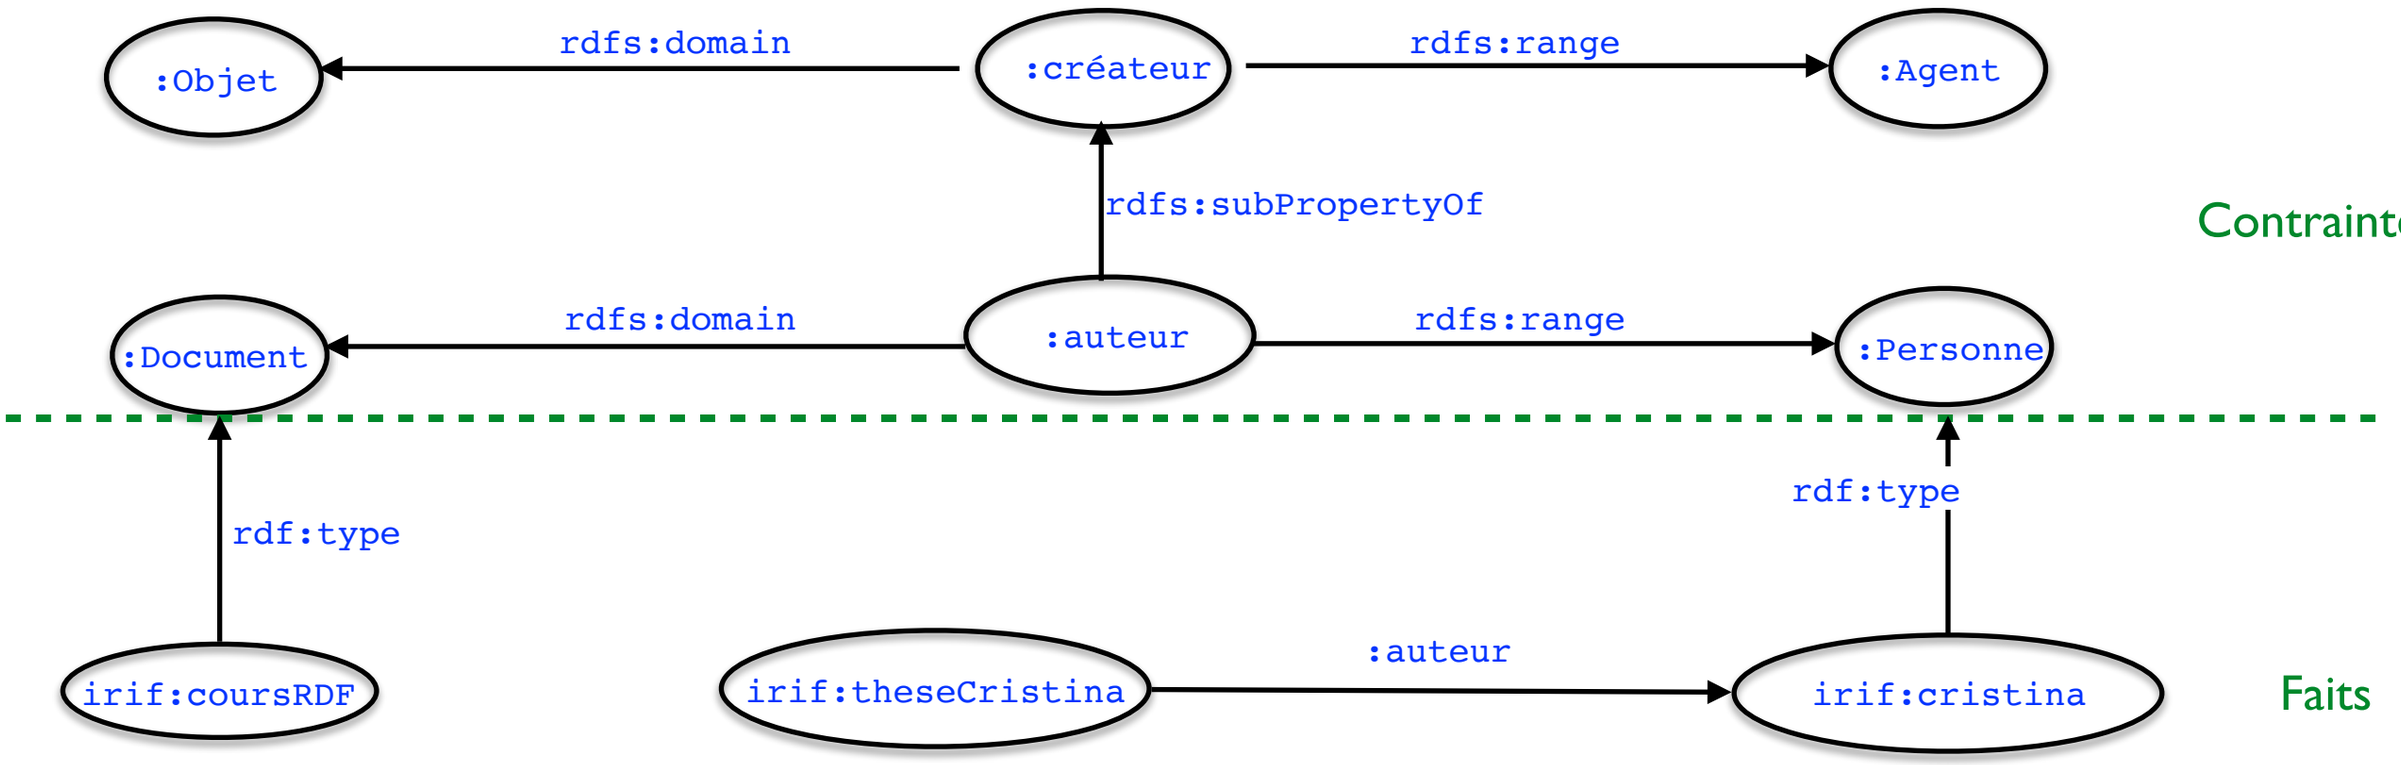


- `irif:theseCristina` est une **réponse certaine**

# Responses certaines : exemple

- Exemple : K requête :“quels sont les objets créés par un agent”

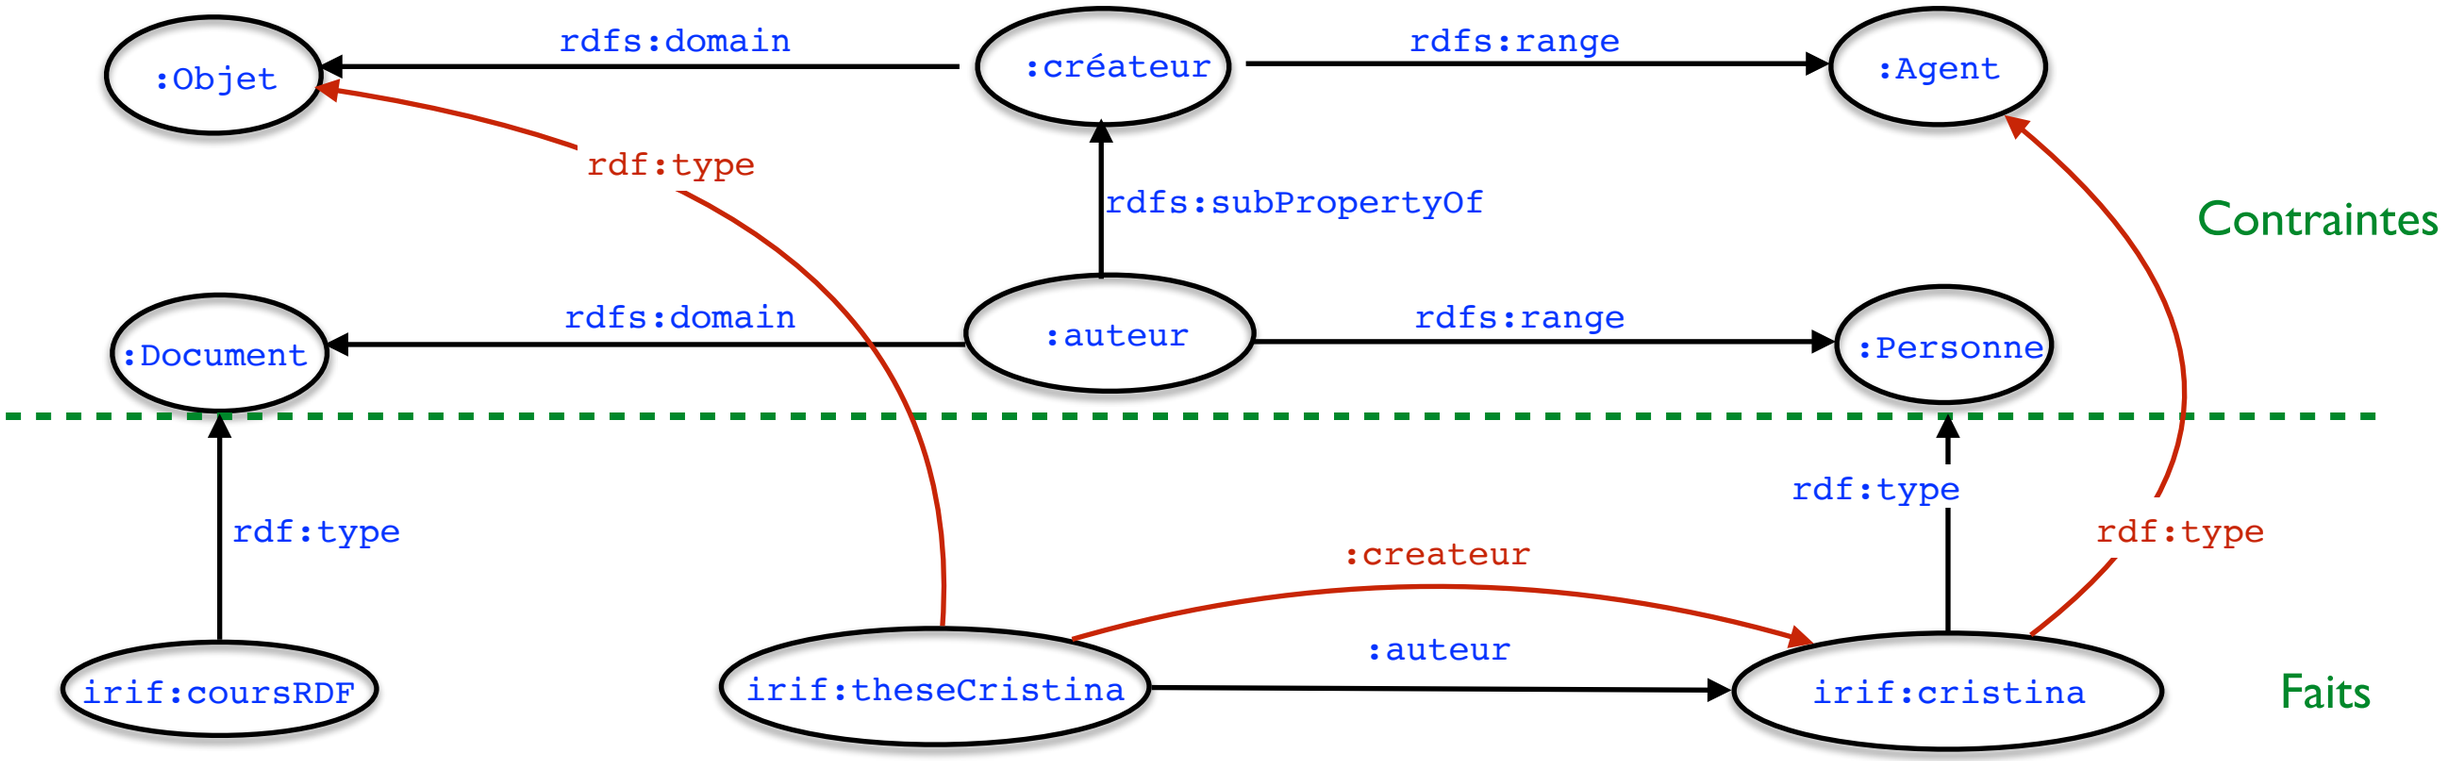


- `irif:theseCristina` est une **réponse certaine**
  - Parce que les faits en rouge ci-dessus sont présents dans tous les modèles (RDFS) de K

# Responses certaines : exemple

- Exemple : K requête :“quels sont les objets créés par un agent”

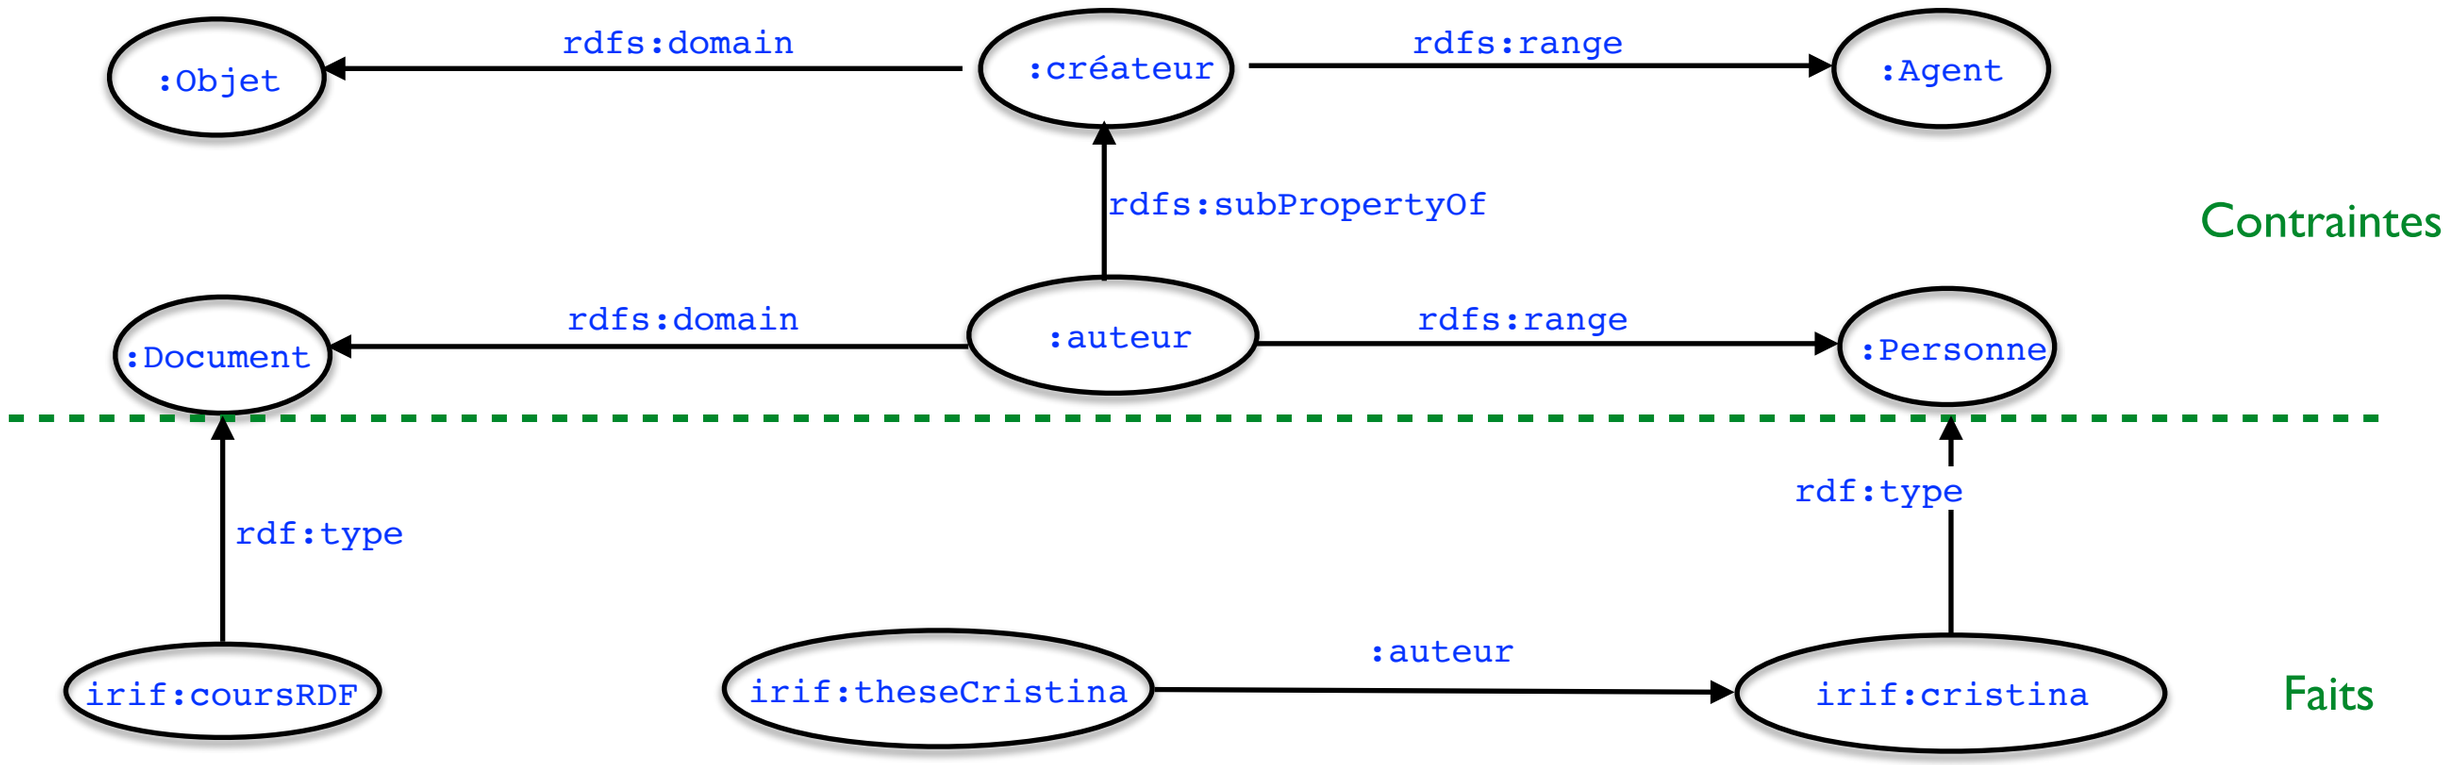


- `irif:coursRDF` n’est **pas une réponse certaine**

# Responses certaines : exemple

- Exemple : K

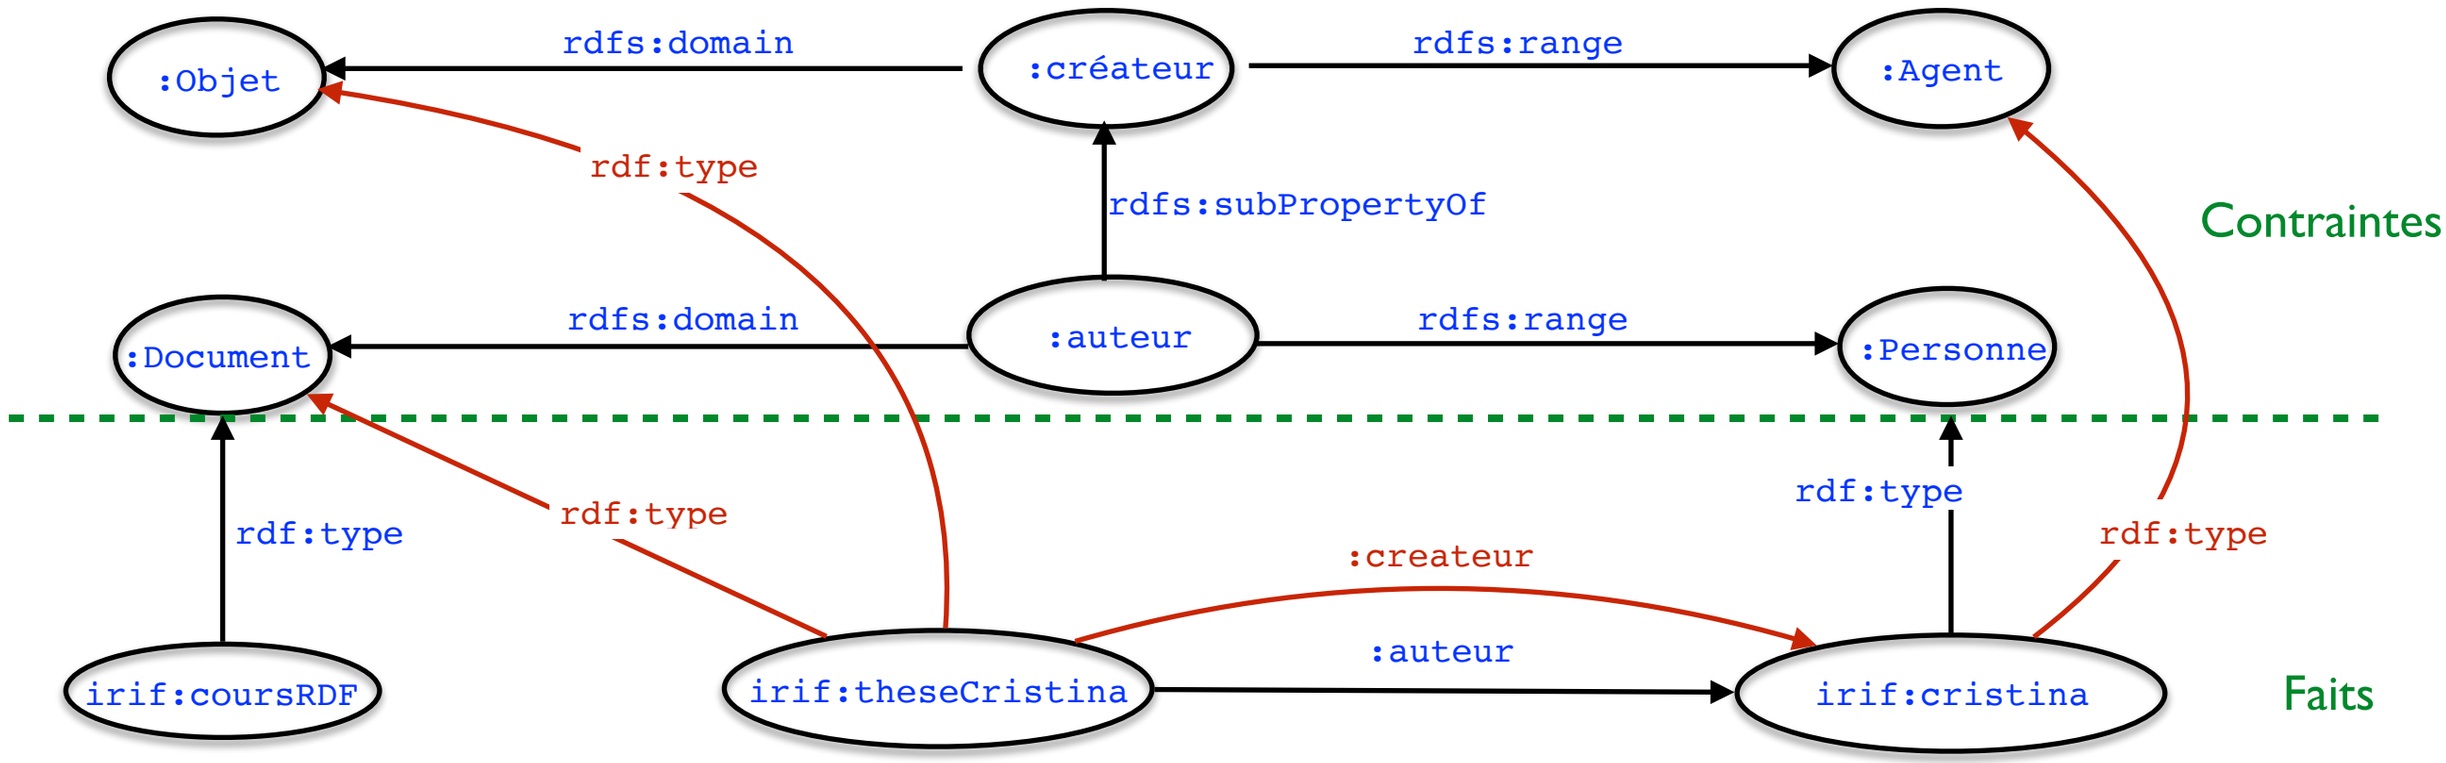


- `irif:coursRDF` n'est **pas une réponse certaine**
  - En effet il y a bien des modèles où `irif:coursRDF` n'a pas de créateur (rappel : seuls les faits en rouge sont presents dans tous les modèles RDFS)

# Réponses certaines et interrogation du graphe saturé

- Ils sont bien sûr liés !
- Le graphe saturé $\mathbf{K}^{\infty}$ est contenu dans tous les modèles de K (par definition)
- Mais il est également un modèle (satisfait les contraintes)

- **Requêtes monotones**
  - Une requête Q est monotone si Q(M') ⊆ Q(M) pour tout M' ⊆ M
  - ⇒ pour toute requête Q monotone $Q(\mathbf{K}^{\infty}) \subseteq Q(M)$ pour tout modèle M
  - ⇒ si $t \in Q(\mathbf{K}^{\infty})$ alors t est une réponse certaine
  - Mais si t est certaine alors $t \in Q(\mathbf{K}^{\infty})$ (car $\mathbf{K}^{\infty}$ est un modèle)
  - ⇒

**Pout toute requête monotone (incluant les BGP)**
**$Q(K^{\infty})$ coincide avec les réponses certaines**

# La théorie rencontre la pratique, mais jusqu'où?

**Pour toute requête monotone (incluant les BGP)**
**$Q(K^\infty)$ coincide avec les réponses certaines**

La sémantique d'interrogation recommandée par le W3C ($Q(K^\infty)$) coincide avec l'approche implication logique

- Mais cela n'est pas garanti au delà des requêtes monotones !
- Fragment SPARQL monotone
  - BGP plus UNION, . , FILTER positif, expressions de chemin, et dans une certaine mesure OPTIONAL
- En presence de negation $Q(K^\infty)$ ne calcule pas les réponses certaines
  - A-t-il encore du sens d'adopter $Q(K^\infty)$ comme sémantique d'interrogation ?
  - Le W3C ne s'est pas encore officiellement posé la question…
  - …attendons SPARQL 1.2 !